Ukazatele polohy a variability

Kapitola 3

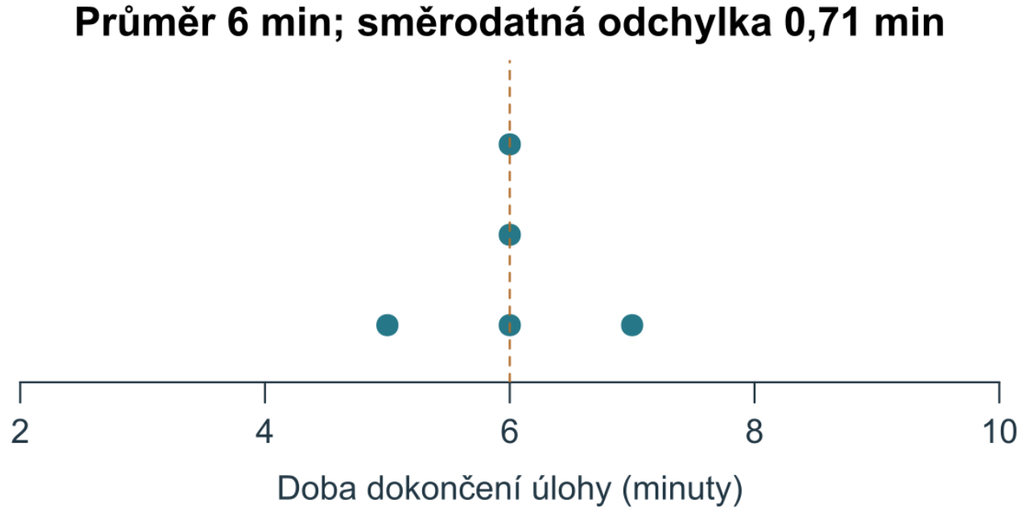
Stejný průměr, jiná variabilita

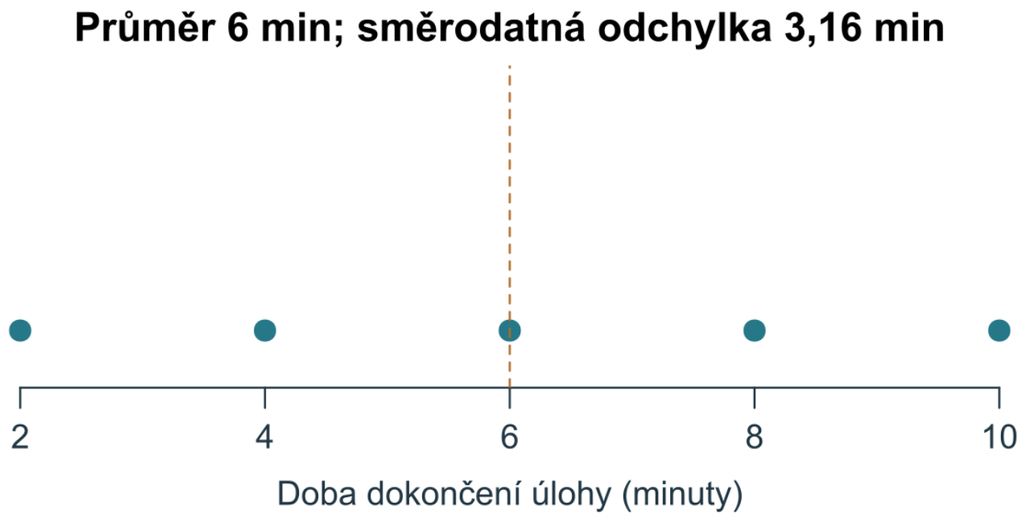
Kde data leží a jak se navzájem liší

Ukazatele polohy: kde se rozdělení na škále nachází

Ukazatele variability: jak se hodnoty navzájem liší

Statistika popisuje soubor dat, parametr populaci nebo model





Dva modelové soubory dob dokončení úlohy v minutách

Modus: nejčastější hodnota

4	**5**	**5**	6	10	minut

Modus = 5 minut

Hodnota nebo kategorie s nejvyšší četností; lze jej určit i u nominálních dat

Nejčastější neznamená většinový: 5 minut mají 2 z 5 osob (40,0 %)

Modů může být více; u jemně měřených veličin bývá málo informativní

Průběžný příklad: doby dokončení úlohy pěti modelových účastníků

Medián: prostřední poloha

4	5	**5**	6	10	minut

Medián = 5 minut: prostřední hodnota seřazené řady

Sudý počet hodnot: průměr dvou prostředních; 4, 5, 6, 10 → 5,5 minuty

Alespoň polovina hodnot je nejvýše rovna mediánu a alespoň polovina nejméně

Ordinální kategorie: kódy neprůměrujeme, uvedeme obě prostřední kategorie

Aritmetický průměr

4	**5**	**5**	**6**	**10**	minut

$$m = \frac{1}{n}\sum_{i=1}^{n} x_i$$

$$m = \frac{4+5+5+6+10}{5} = \frac{30}{5} = 6\ \text{minut}$$

Součet rozdělený rovnoměrně mezi všechny případy

Využívá velikost každé hodnoty; nemusí být pozorovanou hodnotou

n = počet pozorování, x s indexem i = hodnota i-tého pozorování, m = výběrový průměr

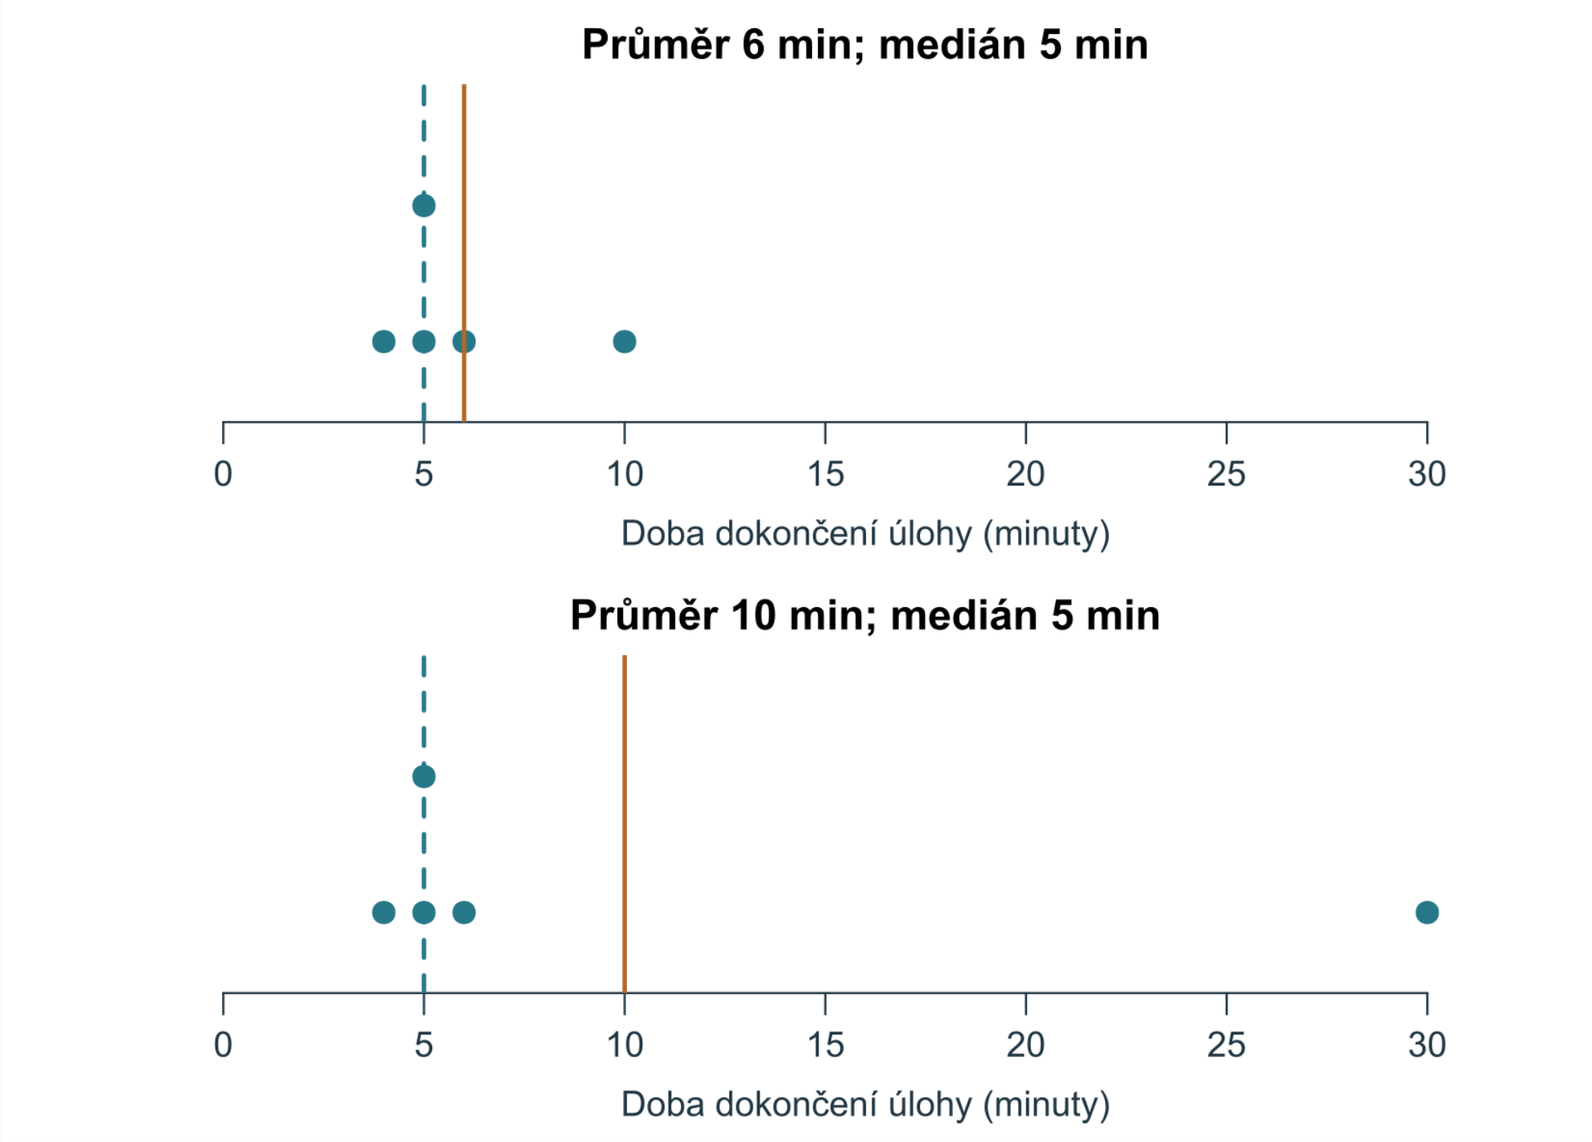
Jedno vzdálenější pozorování

Dobu 10 minut nahradíme 30 minutami

Průměr: 6 → 10 minut

Medián a modus: stále 5 minut

Žádný výsledek není chybný; každý odpovídá na jinou otázku



Tři středy, tři otázky

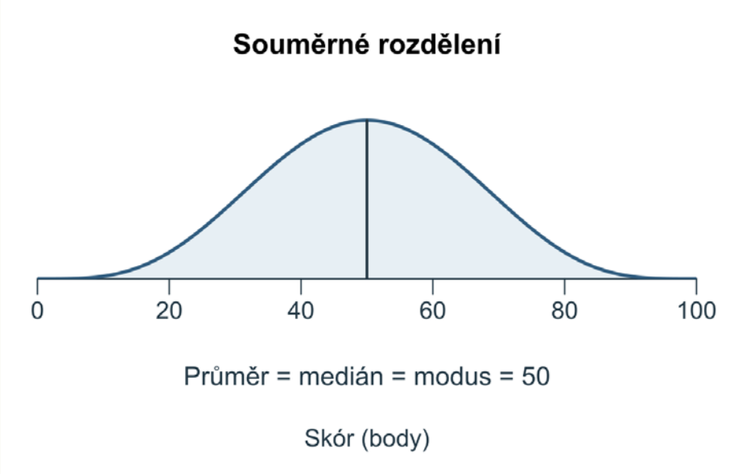
Volíme podle otázky, úrovně měření a tvaru rozdělení

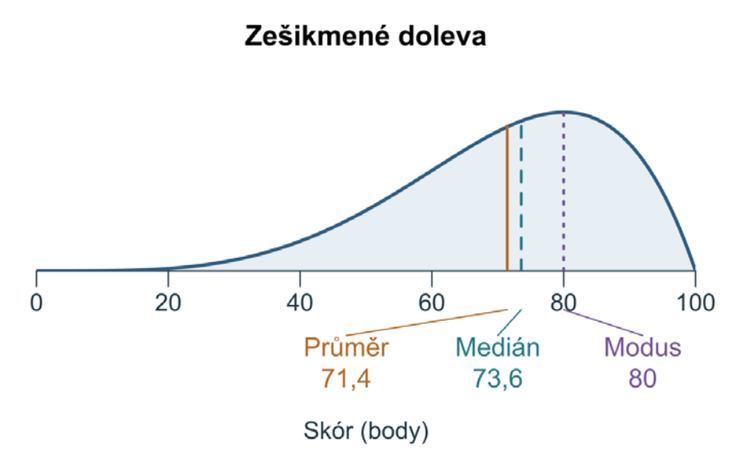
Ukazatel	Na co odpovídá	Na co dát pozor
Modus	Co se vyskytuje nejčastěji?	Nemusí být jediný ani většinový
Medián	Kde leží prostředek seřazených hodnot?	Nezachytí změny mimo prostředek řady
Průměr	Kolik připadá na jeden případ?	Reaguje i na jedinou vzdálenou hodnotu

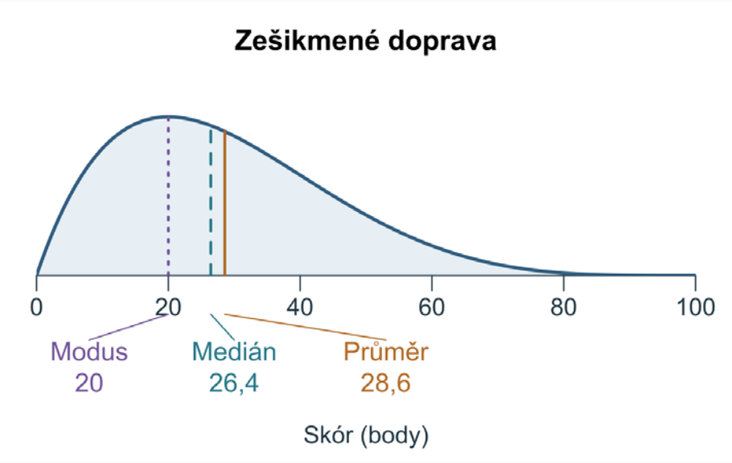
V příkladu 4, 5, 5, 6, 10 minut: modus 5, medián 5, průměr 6 minut

Střed a tvar rozdělení

Směr zešikmení určuje delší chvost







Vzdálené hodnoty v chvostu táhnou průměr za sebou; medián se posune méně

Pořadí průměru, mediánu a modu je vodítko, ne test šikmosti

Vlastní modelová rozdělení testových skórů, nikoli naměřená data

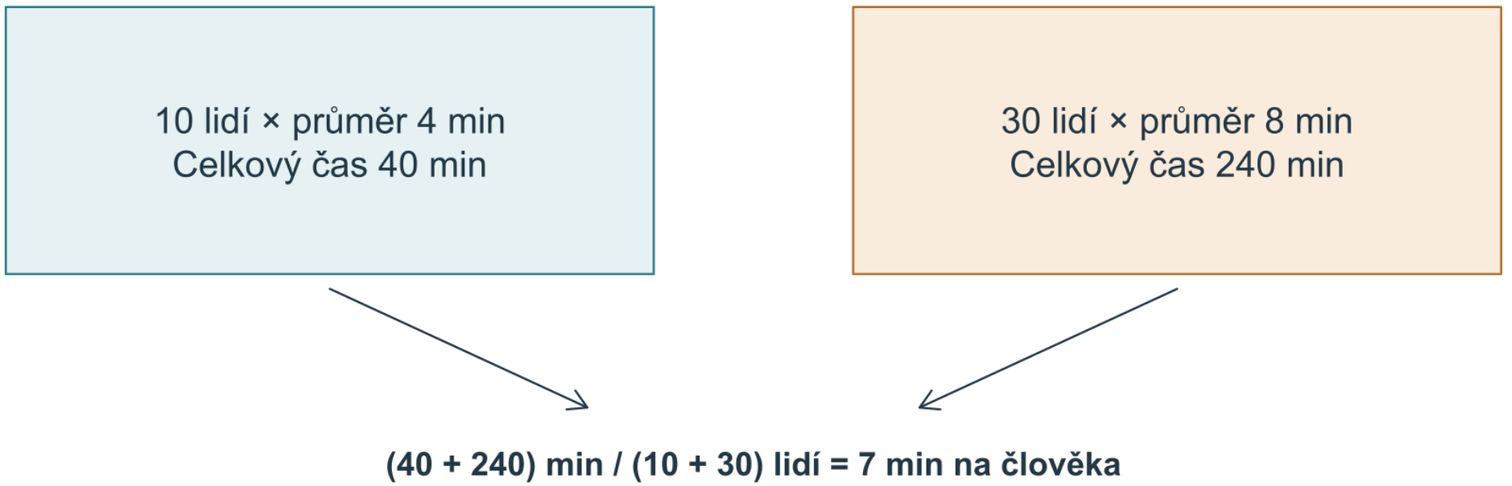
Průměr více skupin

Skupiny 10 a 30 osob, průměry 4 a 8 minut

(10 × 4 + 30 × 8) / 40 = 7 minut

Prostý průměr (4 + 8) / 2 = 6 odpovídá na jinou otázku

Ze skupinových mediánů společný medián neurčíme





Větší skupina má při průměrování všech lidí větší váhu.

Kvantily, percentily a kvartily

Kvantil q_p: hodnota na škále pro zvolenou úroveň p

Úroveň p	0,25	0,50	0,75
Percentil	25. percentil	50. percentil	75. percentil
Kvartil	1. kvartil	2. kvartil = medián	3. kvartil
Příklad 4, 5, 5, 6, 10	5 minut	5 minut	6 minut

Kvartil je hraniční hodnota na škále, ne čtvrtina lidí

Číselná data: konvence funkce PERCENTIL.INC s lineární interpolací

Výpočet kvantilu s interpolací

pozice = 1 + (n − 1) × p

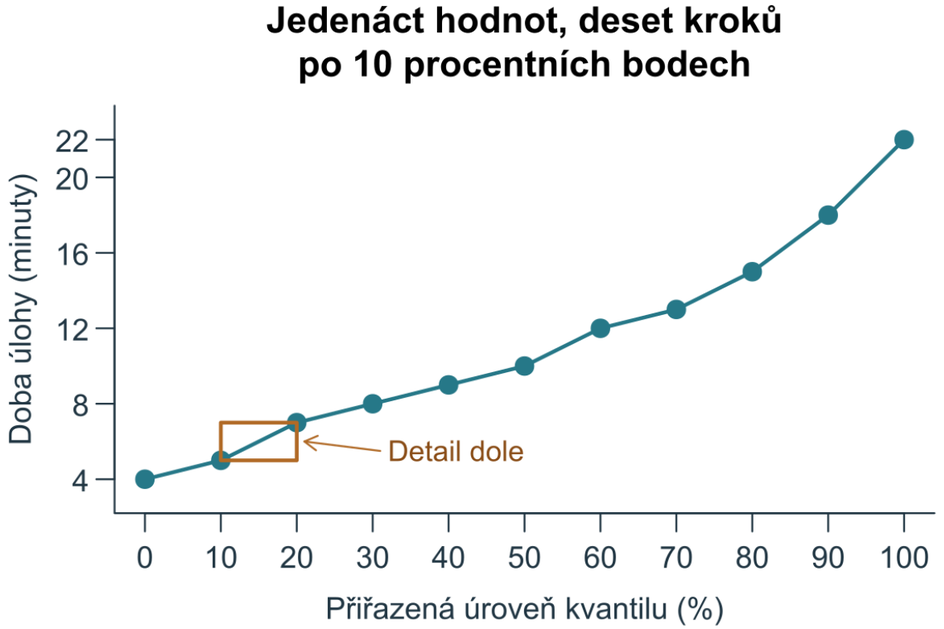
Jedenáct časů, 17. percentil:
pozice = 1 + 10 × 0,17 = 2,7

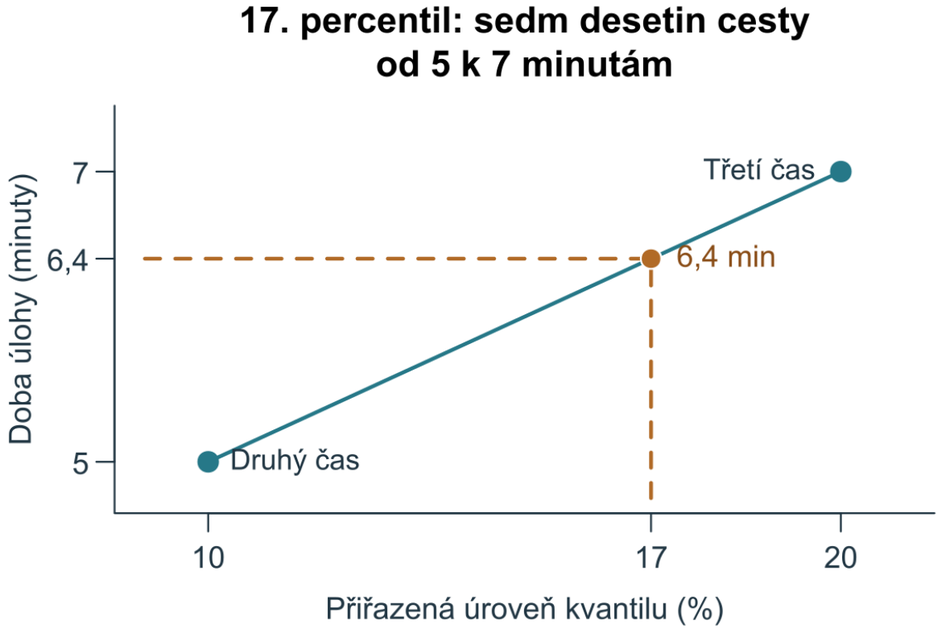
Leží mezi 2. hodnotou (5 minut)
a 3. hodnotou (7 minut), v sedmi desetinách cesty

$q_{0,17}$ = 5 + 0,7 × (7 − 5) = 6,4 minuty

Výsledek nemusí být pozorovanou hodnotou

Seřazené časy: 4, 5, 7, 8, 9, 10, 12, 13, 15, 18, 22 minut





Percentil a percentilové pořadí

Dvě opačné otázky

Percentil: známe úroveň, hledáme hodnotu. 50. percentil = 5 minut

Percentilové pořadí: známe hodnotu, hledáme podíl hodnot nejvýše rovných 5 minutám: 3 z 5, tedy 60

Ordinální kategorie: první kategorie, u níž kumulativní podíl dosáhne úrovně p

Otázka: Jaký je 50. percentil?

Hledáme hodnotu v minutách.



Medián = 5 minut

Otázka: Jaké pořadí má čas 5 minut?

Počítáme všechny časy nejvýše 5 minut.



3 / 5 = 60 %
Percentilové pořadí 60

Stejných pět časů: 4, 5, 5, 6 a 10 minut. Každý kruh je jeden čas.

Rozpětí celku a prostřední části

4	5	5	6	10	minut

Variační rozpětí = maximum − minimum = 10 − 4 = 6 minut

Využívá jen dvě krajní hodnoty; po změně 10 → 30 vzroste na 26 minut

Mezikvartilové rozpětí = $q_{0,75} - q_{0,25}$ = 6 − 5 = 1 minuta

Šířka prostřední části rozdělení; změna 10 → 30 ji zde nezmění

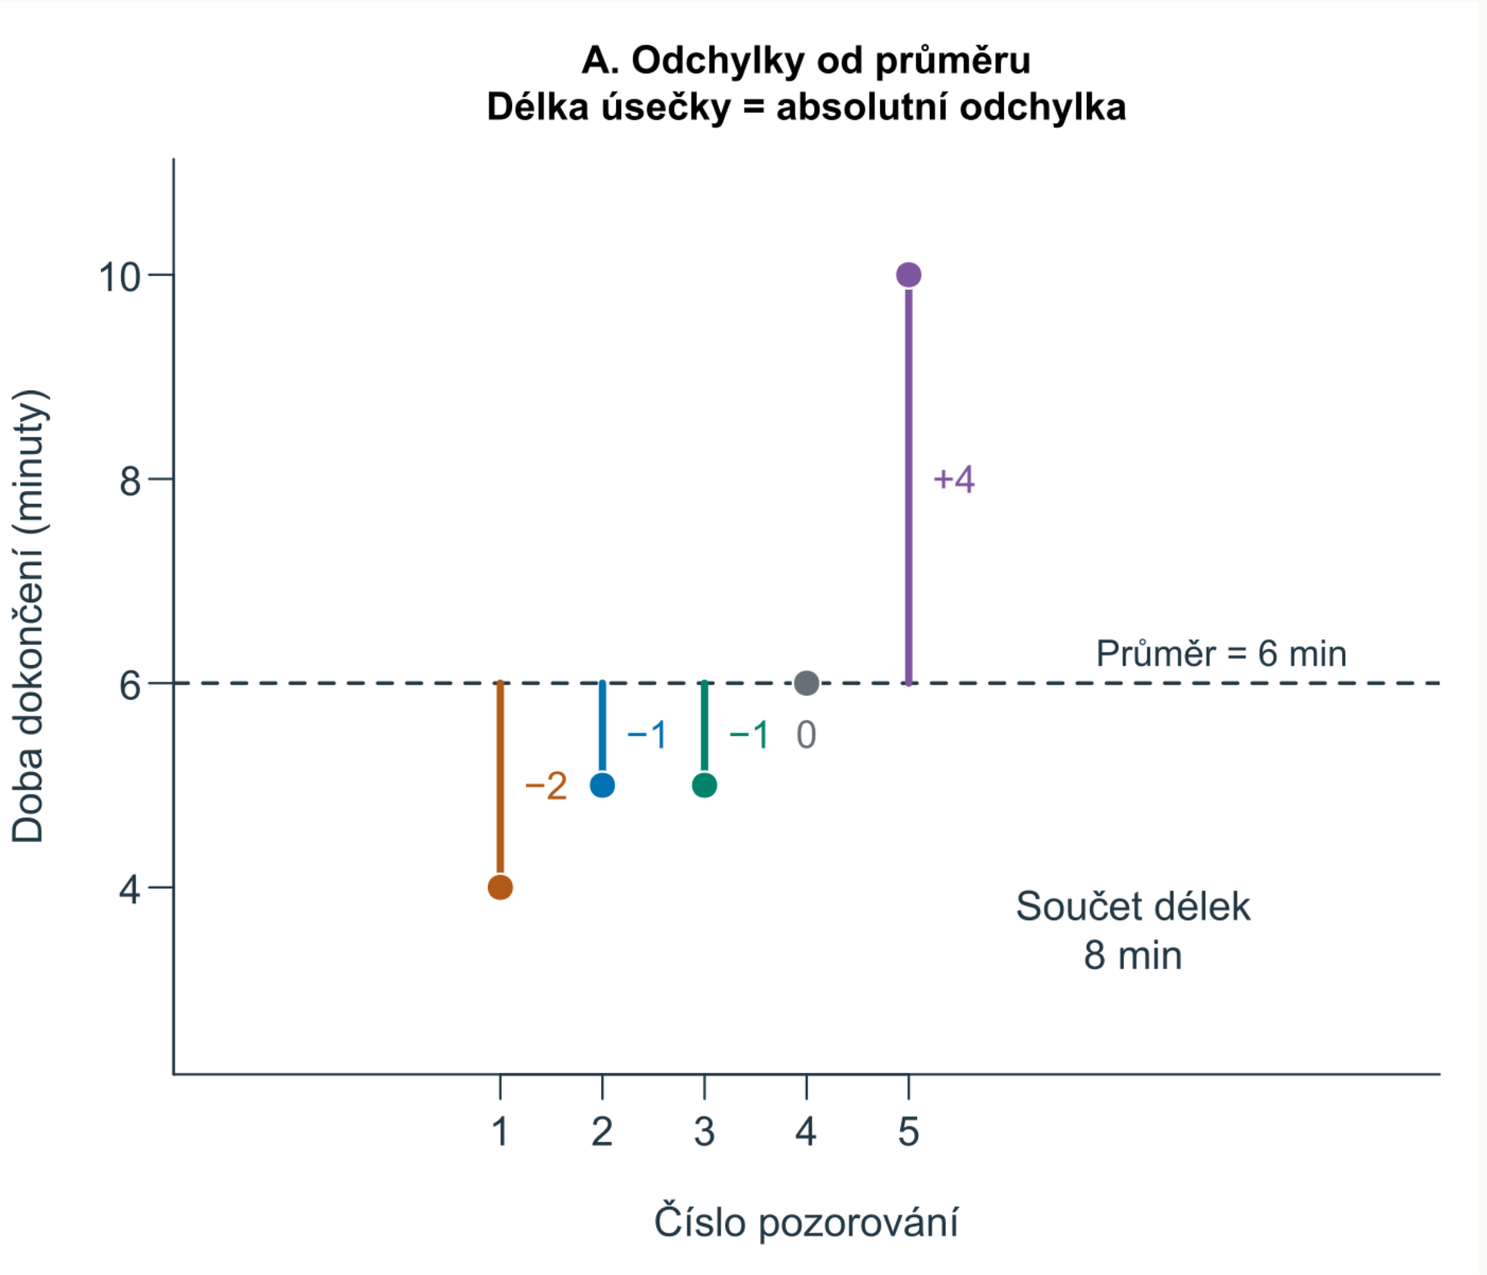
IQR (interquartile range) je běžná zkratka mezikvartilového rozpětí

Odchylky od průměru

Doba (min)	Odchylka	Absolutní odchylka
4	−2	2
5	−1	1
5	−1	1
6	0	0
10	4	4
Součet	0	8

Součet odchylek od průměru je vždy 0

Průměrná absolutní odchylka:
8 / 5 = 1,6 minuty



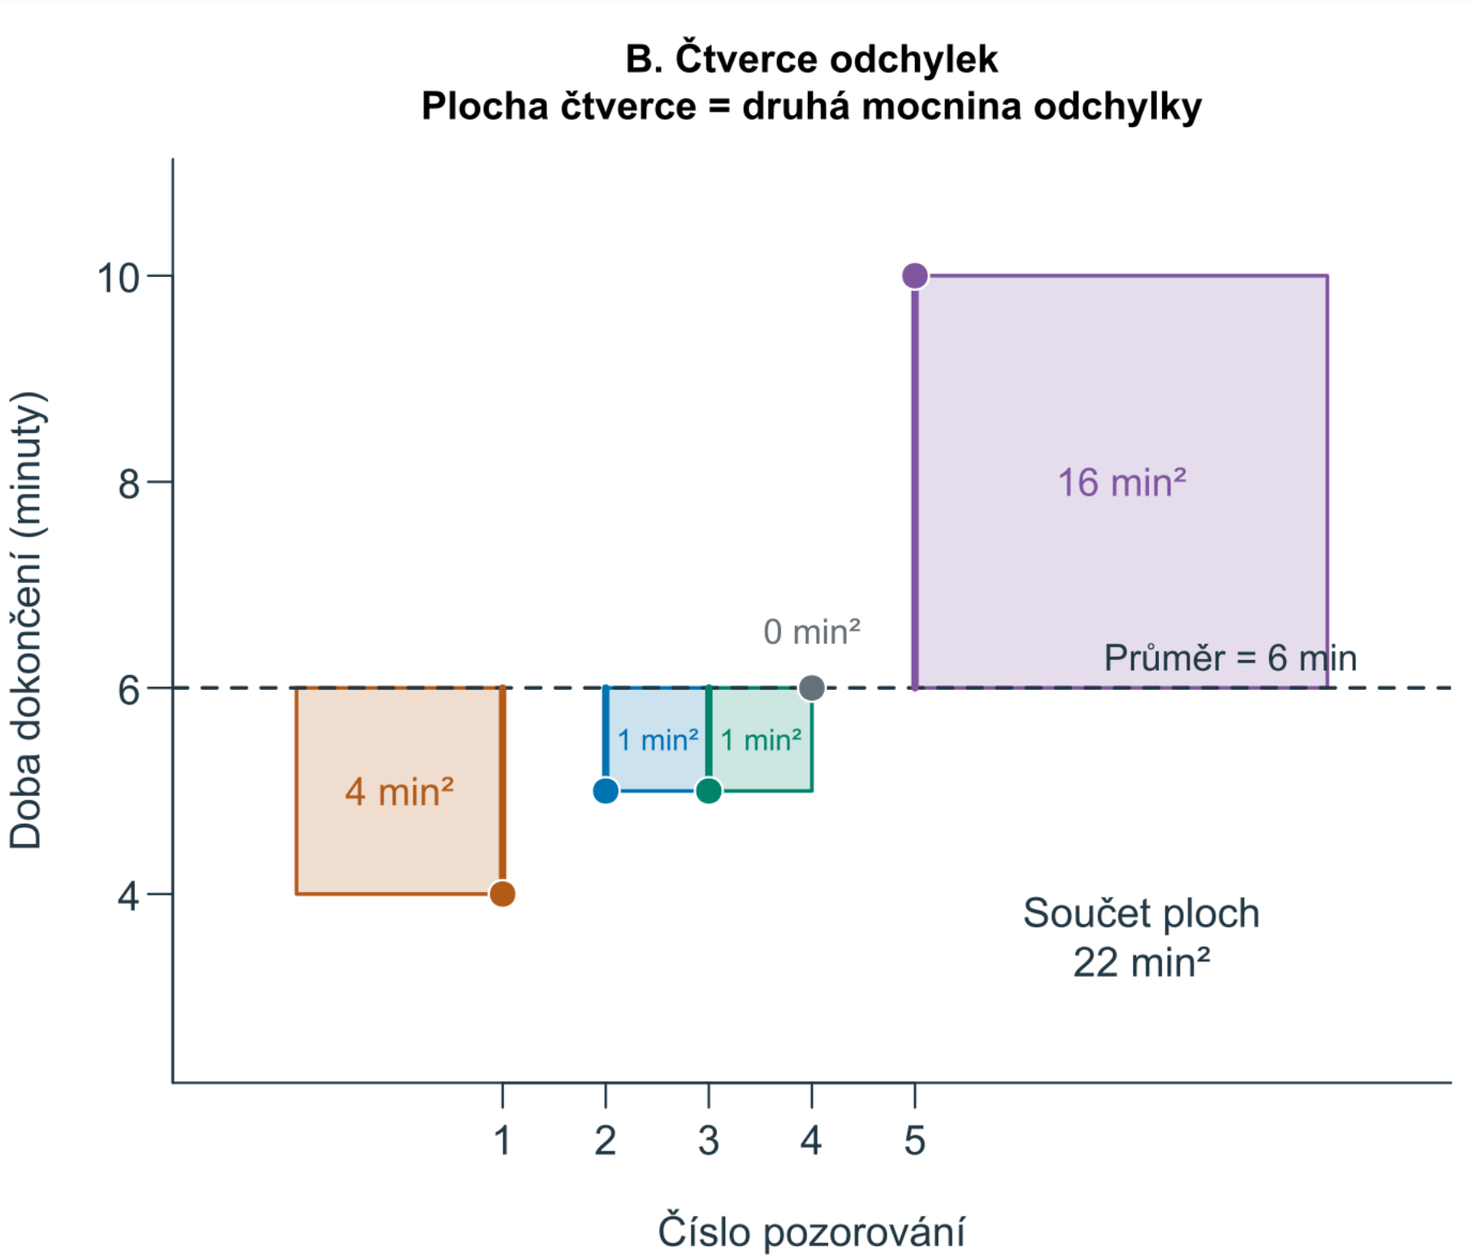
Čtverce odchylek a rozptyl

Součet čtverců odchylek: 4 + 1 + 1 + 0 + 16 = 22 min²

Průměr čtverců těchto pěti hodnot: 22 / 5 = 4,4 min²

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - m)^2}{n - 1}$$

Výběrový rozptyl: s^2 = 22 / 4 = 5,5 min²



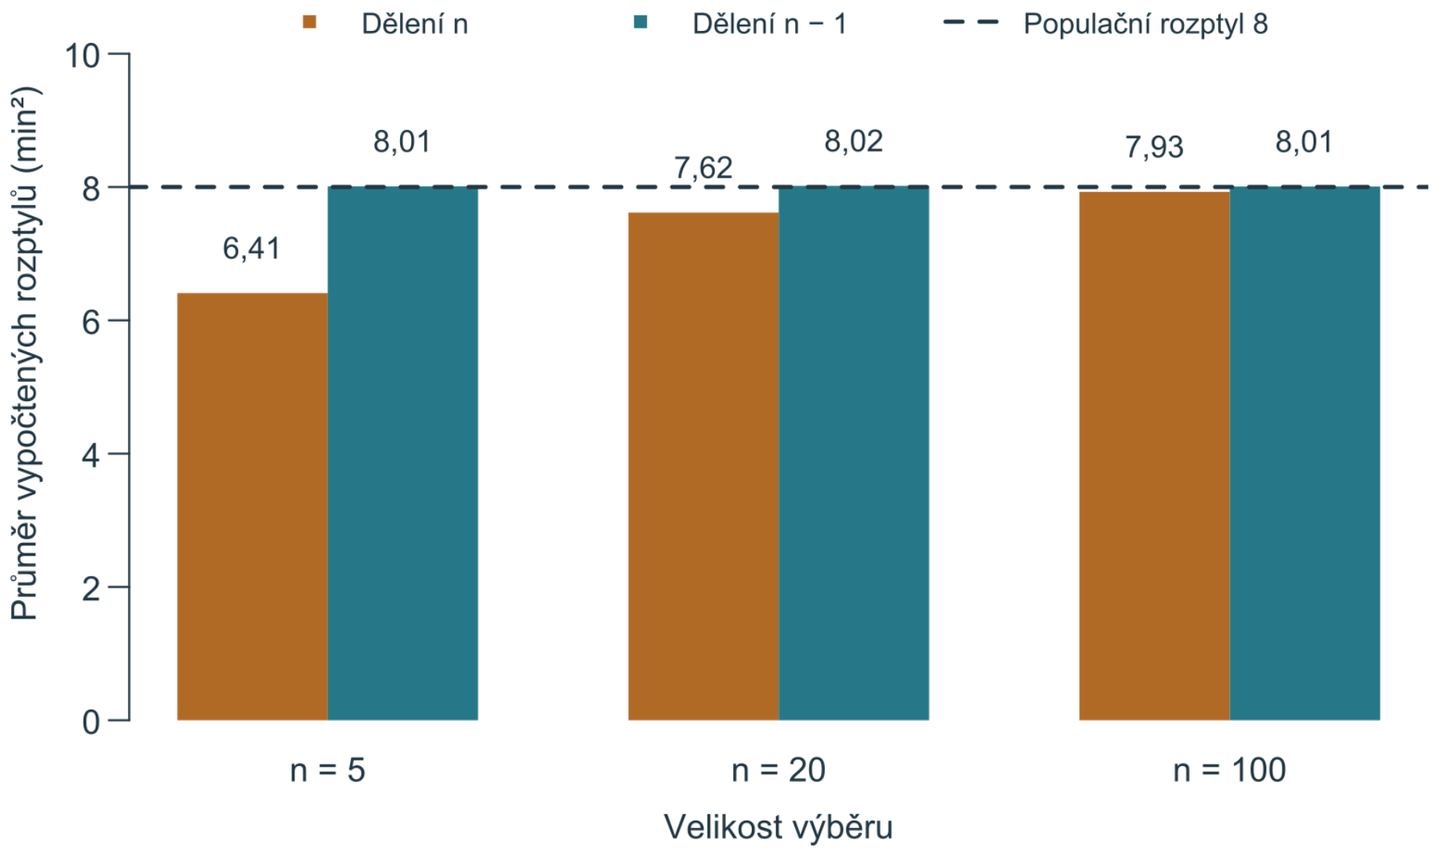
Proč dělíme n − 1

Průměr je přizpůsoben týmž datům

Variabilita kolem výběrového průměru vychází soustavně o něco menší než kolem populačního

Dělení n − 1 toto podhodnocení odstraňuje: nestranný odhad

Stupně volnosti: odchylky dávají součet 0, volně lze určit jen n − 1 z nich



Simulace: 20 000 náhodných výběrů pro každé n z modelové populace s rozptylem 8 min^2

Směrodatná odchylka

4	**5**	**5**	**6**	**10**	minut

$$s = \sqrt{s^2} = \sqrt{5{,}5} \doteq 2{,}35 \text{ minuty}$$

Odmocnina vrací původní jednotky: minuty místo min^2

Není totožná s průměrnou absolutní odchylkou (1,6 minuty)

Neříká, že se každý liší od průměru právě o 2,35 minuty

Bez předpokladu o tvaru rozdělení neurčuje podíl hodnot mezi m − s a m + s

Odolnější shrnutí

Když nemá rozhodovat několik krajních hodnot

MedAD, medián absolutních odchylek od mediánu: pro 4, 5, 5, 6, 10 je 1 minuta

Ořezání 10 %: krajní hodnoty vynecháme; 47 / 8 ≐ 5,88 minuty

Winsorizace 10 %: krajní hodnoty nahradíme; 59 / 10 = 5,9 minuty

Pravidlo volíme předem; původní data uchováme



Deset časů: 2, 3, 4, 5, 5, 6, 7, 8, 9, 31 minut; běžný průměr 8 minut

Krabicový graf

Krabice: 1. kvartil 40, medián 50, 3. kvartil 60

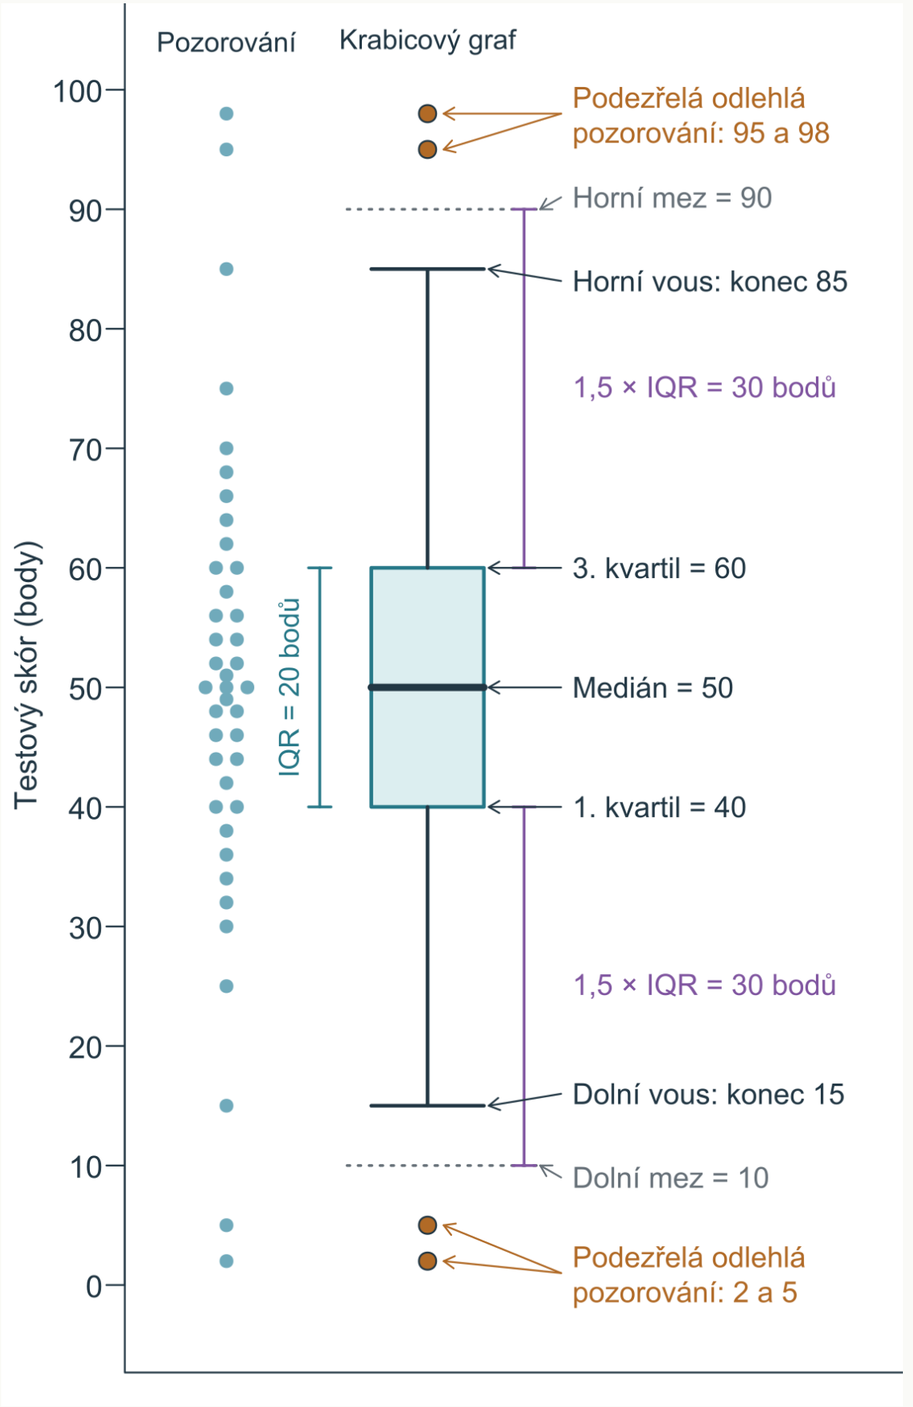
Mezikvartilové rozpětí 20 bodů; 1,5 × 20 = 30 bodů

Pomocné meze: 40 − 30 = 10 a 60 + 30 = 90

Vousy končí na pozorováních uvnitř mezí: 15 a 85

Body za mezemi (2, 5, 95, 98): podezřelá odlehlá pozorování, ne důkaz chyby

41 modelových testových skórů v bodech



Posun a změna jednotek

$$y_i = a + bx_i$$

Ukazatel	Původní data	Přičteme 2 minuty	Převod na sekundy (× 60)
Průměr	6 min	8 min	360 s
Medián	5 min	7 min	300 s
Směrodatná odchylka	2,35 min	2,35 min	140,71 s
Rozptyl	5,5 min²	5,5 min²	19 800 s²

Posun mění polohu, ne variabilitu. Násobení mění obojí; rozptyl se násobí b^2

Jak vybrat a sdělit statistiky

Otázka → význam měření → graf → souhrn

Otázka a data	Užitečný popis
Které strategie učení lidé uvádějí?	Četnosti, podíly, modus; případně entropie
Jak lidé hodnotí odpočatost slovními kategoriemi?	Četnosti, kumulativní podíly, prostřední kategorie
Kolik času připadá v průměru na člověka?	Průměr, směrodatná odchylka a graf
Jak vypadá prostřední část silně zešikmených dob?	Medián, 1. a 3. kvartil; ukázat i chvost

Stejný průměr a směrodatná odchylka neurčují tvar rozdělení; souhrn doplňujeme grafem

Ukazatele v Excelu

Ukazatel	Český vzorec	Anglický název funkce	Výsledek
Průměr	=PRŮMĚR(A2:A6)	AVERAGE	6
Medián	=MEDIAN(A2:A6)	MEDIAN	5
3. kvartil	=PERCENTIL.INC(A2:A6;0,75)	PERCENTILE.INC	6
Výběrový rozptyl	=VAR.S(A2:A6)	VAR.S	5,5
Směrodatná odchylka	=SMODCH.VÝBĚR.S(A2:A6)	STDEV.S	2,35

U funkce PERCENTIL.INC zadáváme úroveň jako podíl: 0,75, nikoli 75

Sešit ke kapitole 3, list Priklad: časy 4, 5, 5, 6, 10 minut v buňkách A2:A6

Úloha 1: Průměr větší než medián

Sestavte malý soubor dat, například sedm dob řešení úlohy v minutách, v němž je průměr větší než medián.

Jaký tvar má rozdělení vašich dat?

Leží u dat zešikmených doprava průměr nad mediánem, nebo pod ním? Proč?

Howell (2013), s. 60, úlohy 2.30–2.31. Česká adaptace.

Úloha 2: Stejný průměr a medián, jiný modus

Sestavte soubor dat s jedním vrcholem, v němž se průměr rovná mediánu, ale modus má jinou hodnotu.

Je vaše rozdělení souměrné?

Co z toho plyne pro posuzování souměrnosti podle shody průměru a mediánu?

Howell (2013), s. 60, úloha 2.32. Česká adaptace s doplňujícími otázkami.

Úloha 3: Průměr a medián z četností

Patnáct potkanů se učilo probíhat přímou uličkou. Tabulka uvádí, kolik pokusů potřebovali k dosažení předem stanoveného kritéria.

Počet pokusů	18	19	20	21	22	23	24
Počet potkanů	1	0	4	3	3	3	1

Určete průměr a medián počtu pokusů. Který ukazatel souvisí s celkovým počtem pokusů všech potkanů?

Howell (2013), s. 60, úloha 2.33. Česká adaptace s doplňující otázkou.

Úloha 4: Odečtení a násobení konstantou

Soubor A: 8, 7, 12, 14, 3, 7. Od každé hodnoty odečtěte 5 a ukažte, co se stane s průměrem, mediánem a modem.

Soubor B: 8, 3, 5, 5, 6, 2. Každou hodnotu vynásobte 3 a ukažte totéž.

Předpovězte bez výpočtu: jak se v obou případech změní směrodatná odchylka?

Howell (2013), s. 61, úlohy 2.34–2.35. Česká adaptace; otázka na směrodatnou odchylku doplněna.

Úloha 5: Průměr 8,6 a stupně volnosti

Sestavte soubor deseti čísel, jehož průměr je přesně 8,6.

Kolik čísel jste mohli zvolit zcela libovolně?

Jak to souvisí se stupni volnosti při výpočtu výběrového rozptylu?

Howell (2013), s. 61, úloha 2.36. Česká adaptace.

Úloha 6: Kdy transformace změní tvar rozdělení

Za jakých podmínek změní transformace dat tvar jejich rozdělení?

Uveďte příklad převodu, který tvar zachová.

Uveďte příklad převodu, který tvar změní, a popište, co se stane se stejně velkými rozdíly mezi hodnotami.

Howell (2013), s. 62, úloha 2.54. Česká adaptace s doplňujícími pokyny.

Práce v Excelu: doprovodný sešit

kapitola_03_poloha_a_variabilita_cviceni.xlsx

Listy U1_stred až U5_orezani: výrok „a potom…“ při vyprávění filmu u 50 dětí a 50 dospělých; jeden úkol na list, stejná data

List U6_transformace: osm hodnot a převod na směrodatnou odchylku 1

Na každém listu: zadání, žlutá pracovní oblast a řešení po krocích. Funkce Excelu slouží až ke kontrole

Howell (2013), s. 55–56 a 62, úlohy 2.1, 2.4, 2.40–2.46 a 2.51. Česká adaptace.