# Normální rozdělení a standardní skóry

Kapitola 4

# Obsah přednášky

1. Kde leží výsledek: z-skór
2. Normální rozdělení jako model
3. Od hodnoty k podílu a zpět
4. Standardní skóry v psychologii
5. Je normální model přiměřený?
6. Procvičování

# Kde leží výsledek: z-skór

# Výsledek posuzujeme vůči skupině

## 60 bodů: vysoký, nebo nízký výsledek?

**Hrubý skór:** výsledek před převodem, například počet správných odpovědí

**Referenční skupina:** skupina, vůči níž výsledek posuzujeme; u testů **normativní soubor**

Ve skupině s průměrem 50 je 60 bodů nad průměrem, ve skupině s průměrem 70 pod ním

Stejná odchylka znamená něco jiného při malé a velké variabilitě

# Z-skór: vzdálenost v jednotkách směrodatné odchylky

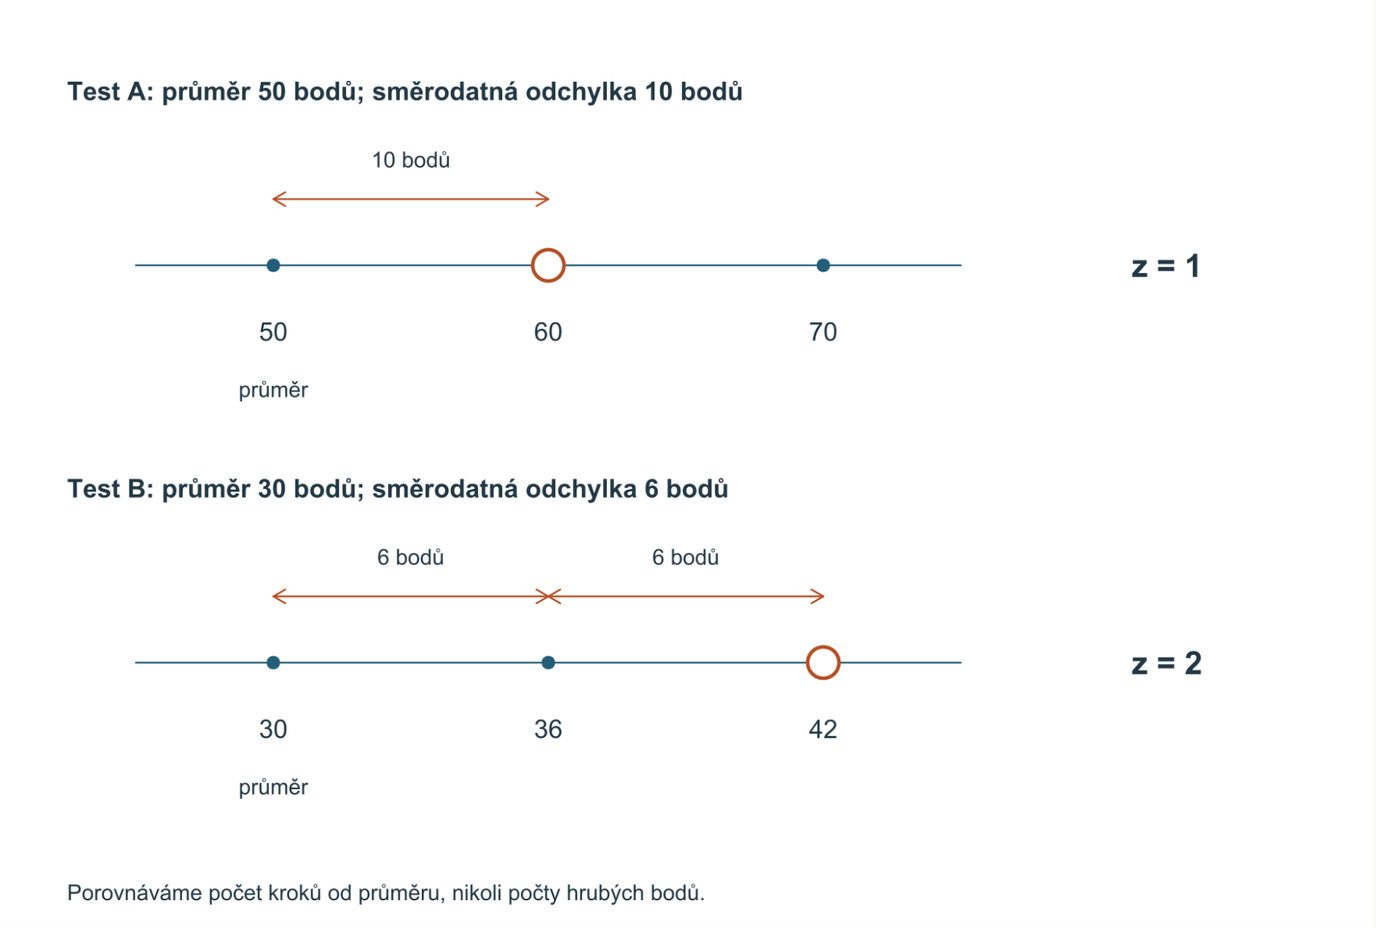
$$z_i = \frac{x_i - m}{s}$$

Test A: (60 − 50) / 10 = **1**

Test B: (42 − 30) / 6 = **2**

Znaménko udává směr, velikost vzdálenost; z nemá jednotku

Zpět: $x_i = m + s \times z_i$




Ilustrační testy A a B

# Standardizace nemění tvar rozdělení

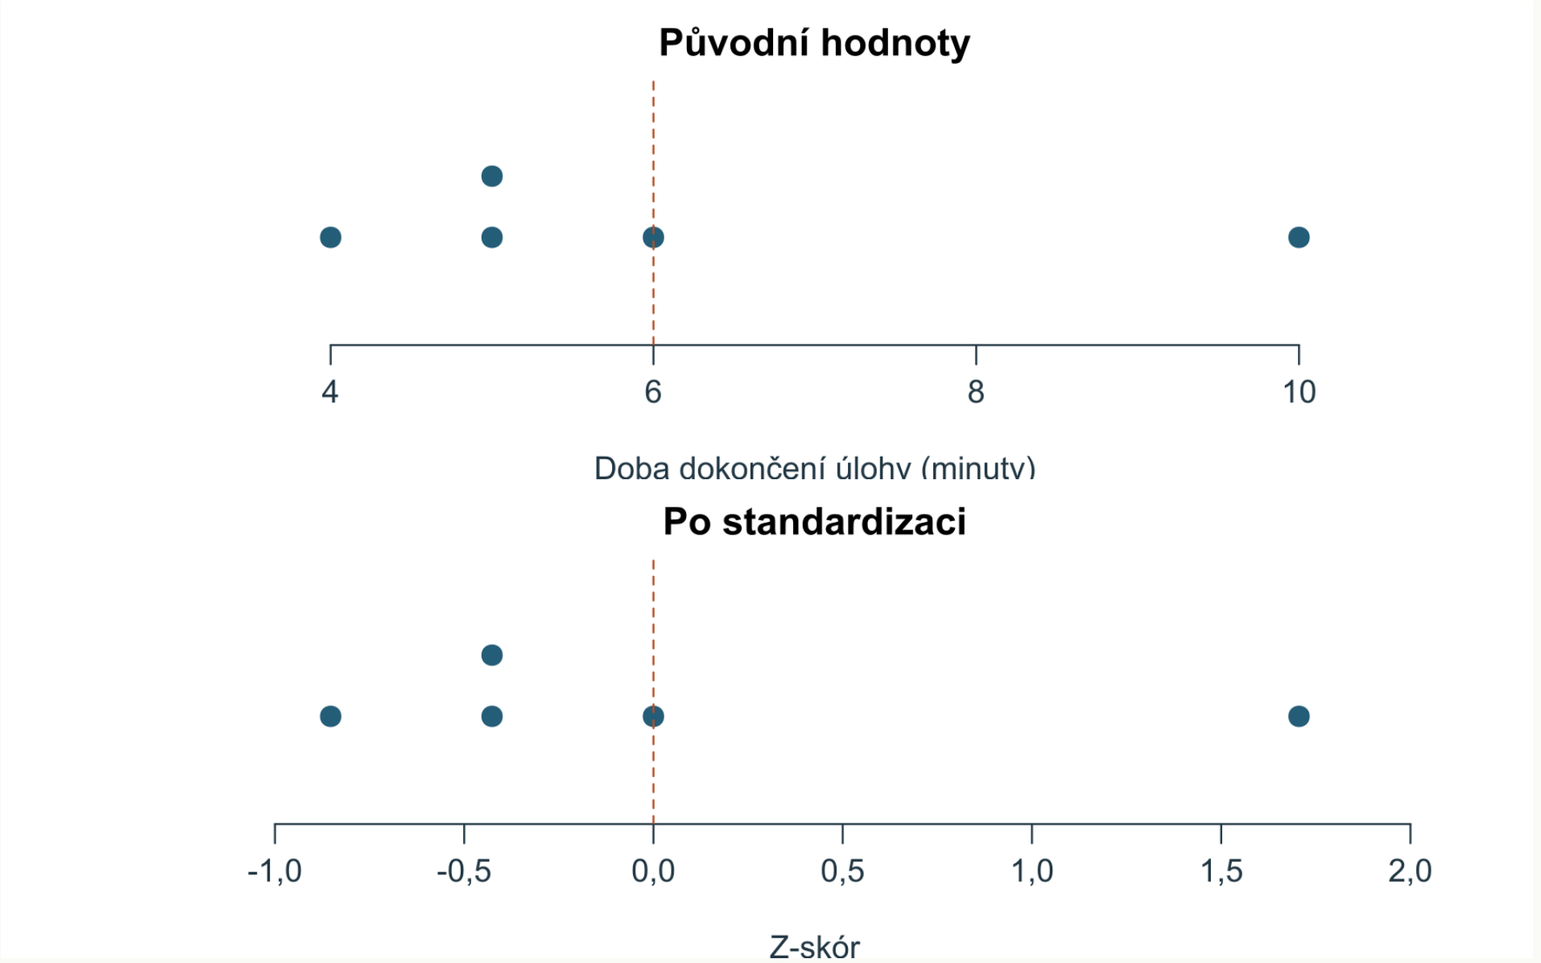
**Standardizace:** lineární převod na zvolený průměr a směrodatnou odchylku

Z-skóry souboru mají průměr 0 a směrodatnou odchylku 1

Zachová pořadí, poměry rozdílů i tvar

*Šikmé rozdělení zůstane šikmé*

Z-skór sám neurčuje percentilové pořadí




Doby 4, 5, 5, 6 a 10 minut z kapitoly 3

# Normální rozdělení jako model

# Normální rozdělení je model, ne data

Matematický model **spojité** veličiny: jeden vrchol, souměrnost

Průměr, medián a modus se shodují

Čím dál od průměru, tím vzácnější hodnoty; **chvosty** pokračují neomezeně

Skór 0–100 nemůže být přesně normální, střed může model dobře přibližovat

„Normální“ = název tvaru, ne zdraví ani žádoucnost

# Dva parametry: N(μ, σ)

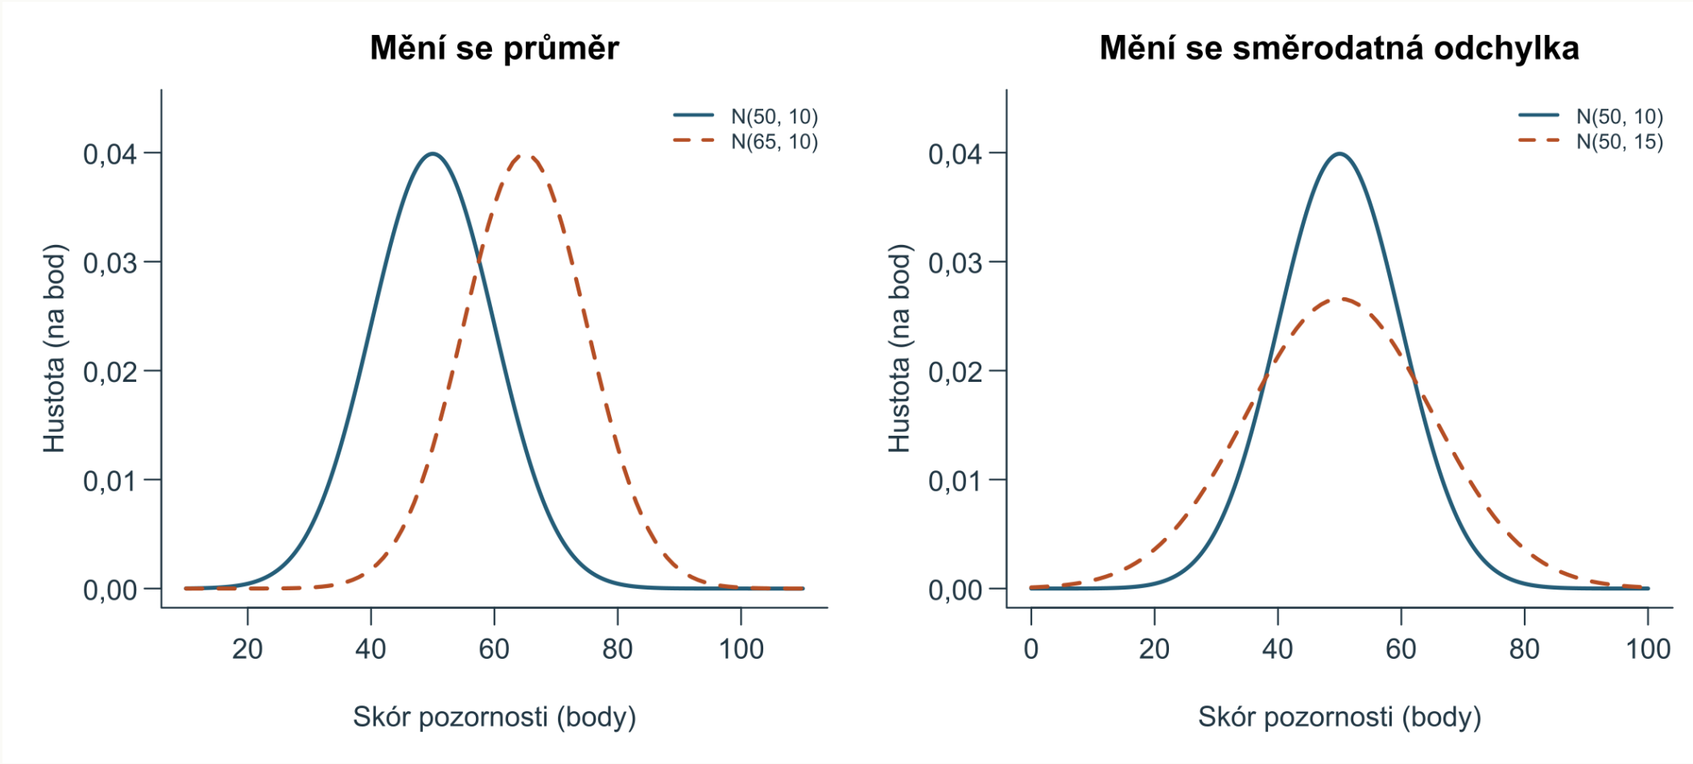
μ: modelový průměr, poloha středu

σ: modelová směrodatná odchylka, šířka

*m* a *s* počítáme z dat; mohou μ a σ odhadovat

**N(50, 10)**

Druhý údaj je zde **směrodatná odchylka**; jinde často rozptyl: N(50, 100)



# Podíl výsledků je plocha, ne výška křivky

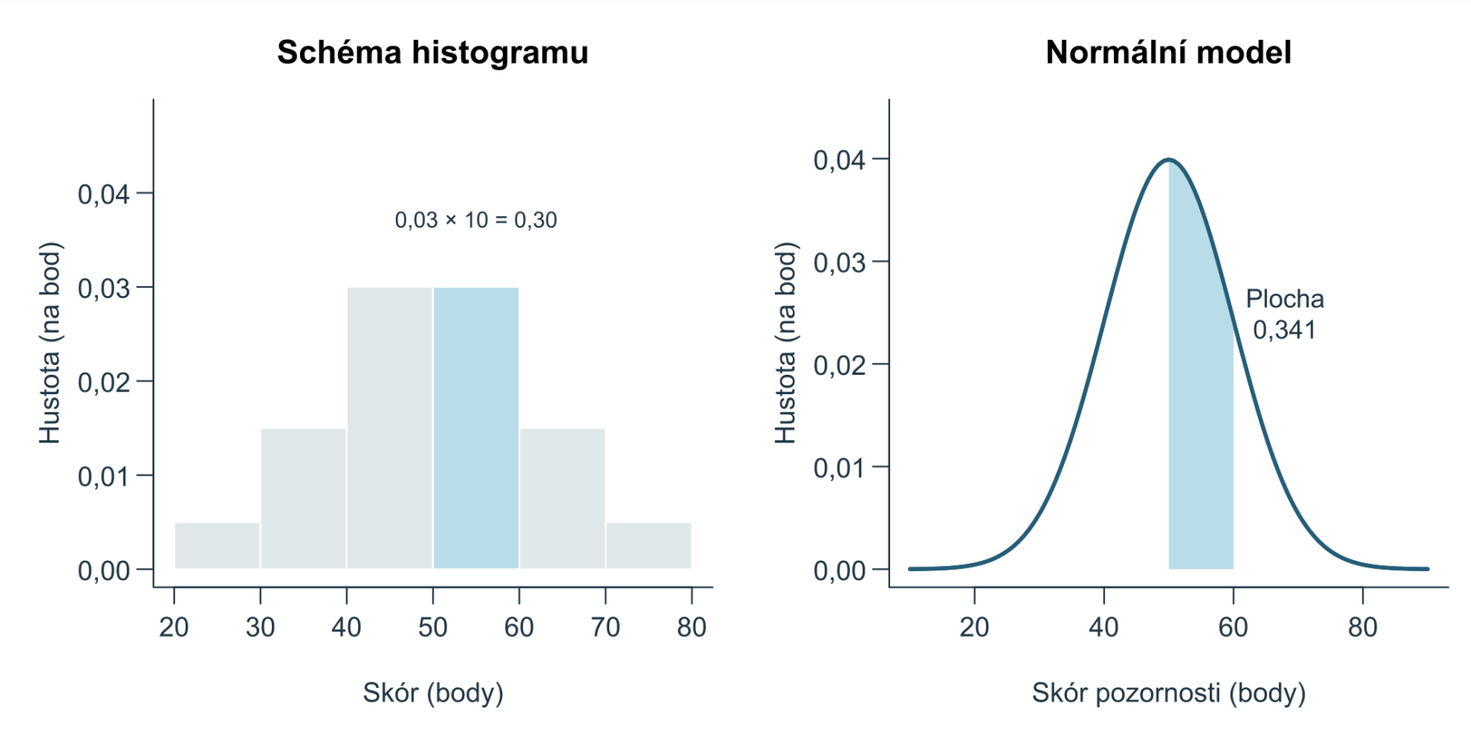
Histogram s plochou: výška = podíl / šířka

30 % v intervalu 10 bodů: výška 0,03 na bod

Výška křivky = **hustota**, není to podíl

**Podíl = plocha pod křivkou** nad intervalem; celková plocha 1

Normované normální rozdělení N(0, 1): $z = (x - \mu) / \sigma$



# Jedna přesná hodnota a zaokrouhlený výsledek

Bod má nulovou šířku, ve spojitém modelu tedy nulovou plochu

Zaznamenaných 50 bodů ≈ interval 49,5 až 50,5: v $N(50, 10)$ asi **4,0 %**

V modelu je „méně než 60“ totéž co „nejvýše 60“

V datech se mohou lišit o počet výsledků přesně 60

Počet správných odpovědí je diskrétní; model ho jen přibližuje

# Orientační pravidlo 68–95–99,7

| Interval z-skórů | V modelu N(50, 10) | Podíl uvnitř | V každém chvostu |
|---|---|---|---|
| −1 až 1 | 40 až 60 bodů | 68,3 % | 15,9 % |
| −2 až 2 | 30 až 70 bodů | 95,4 % | 2,3 % |
| −3 až 3 | 20 až 80 bodů | 99,7 % | 0,1 % |

Přesnějších prostředních 95 % leží mezi $z = -1{,}96$ a 1,96

*Platí jen pro normální model, ne pro libovolná data se známým m a s*

# Od hodnoty k podílu a zpět

# Distribuční funkce kumuluje plochu zleva

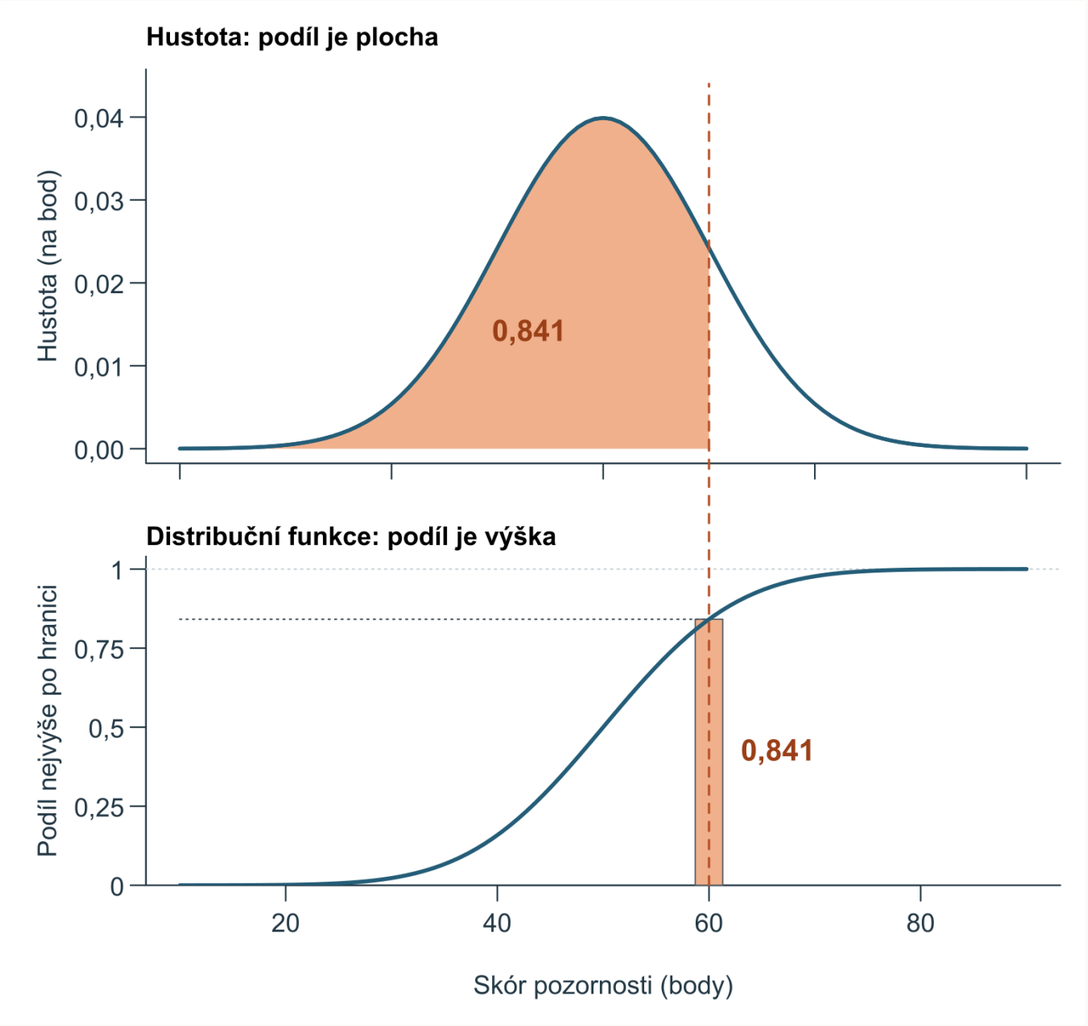
**Distribuční funkce:** podíl hodnot nejvýše po zvolenou hranici

Modelový protějšek kumulativní relativní četnosti

Nahoře plocha, dole výška: obojí **0,841** pro 60 bodů

Excel: =NORM.S.DIST(1;PRAVDA) → 0,841

PRAVDA = plocha; NEPRAVDA = výška křivky (hustota)



# Pod hranicí, nad ní a mezi dvěma mezemi

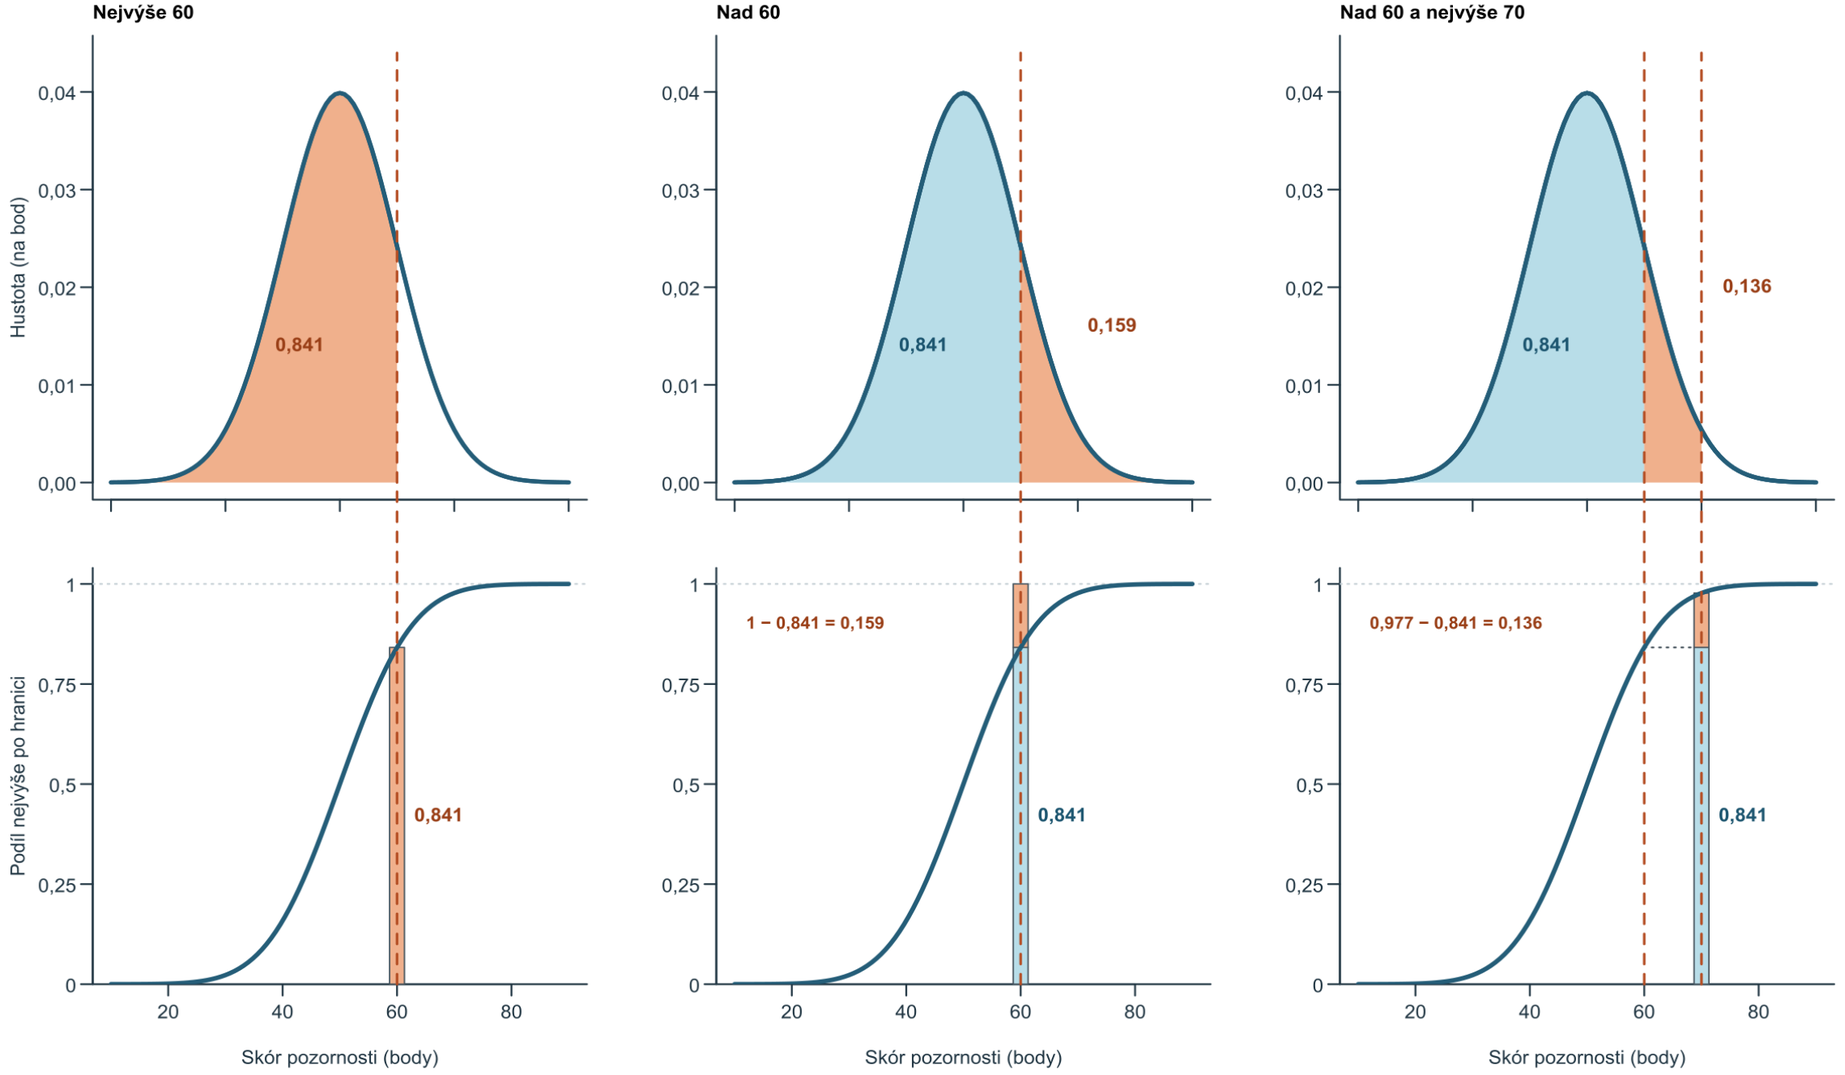
**Nejvýše 60:** 0,841

**Nad 60:** 1 − 0,841 = 0,159

**Mezi 60 a 70:**
0,977 − 0,841 = 0,136

Nejprve načrtněte hledanou oblast

Kontrola souměrností:
nad $z = 1$ je totéž
co pod $z = -1$



# Od podílu zpět k hranici: modelový percentil

## Který skór odděluje dolních 90 %?

=NORM.S.INV(0,9) → $z \approx 1{,}282$

$$x = \mu + \sigma z$$

$x = 50 + 10 \times 1{,}282 \approx$ **62,82 bodu**

Přímo: =NORM.INV(0,9;50;10); podíl zadáváme 0,9, ne 90

Zápis $z_p$: podíl $p$ vlevo, např. $z_{0,9} \approx 1{,}282$

# Prostředních 95 % a horních 5 % jsou různé úlohy

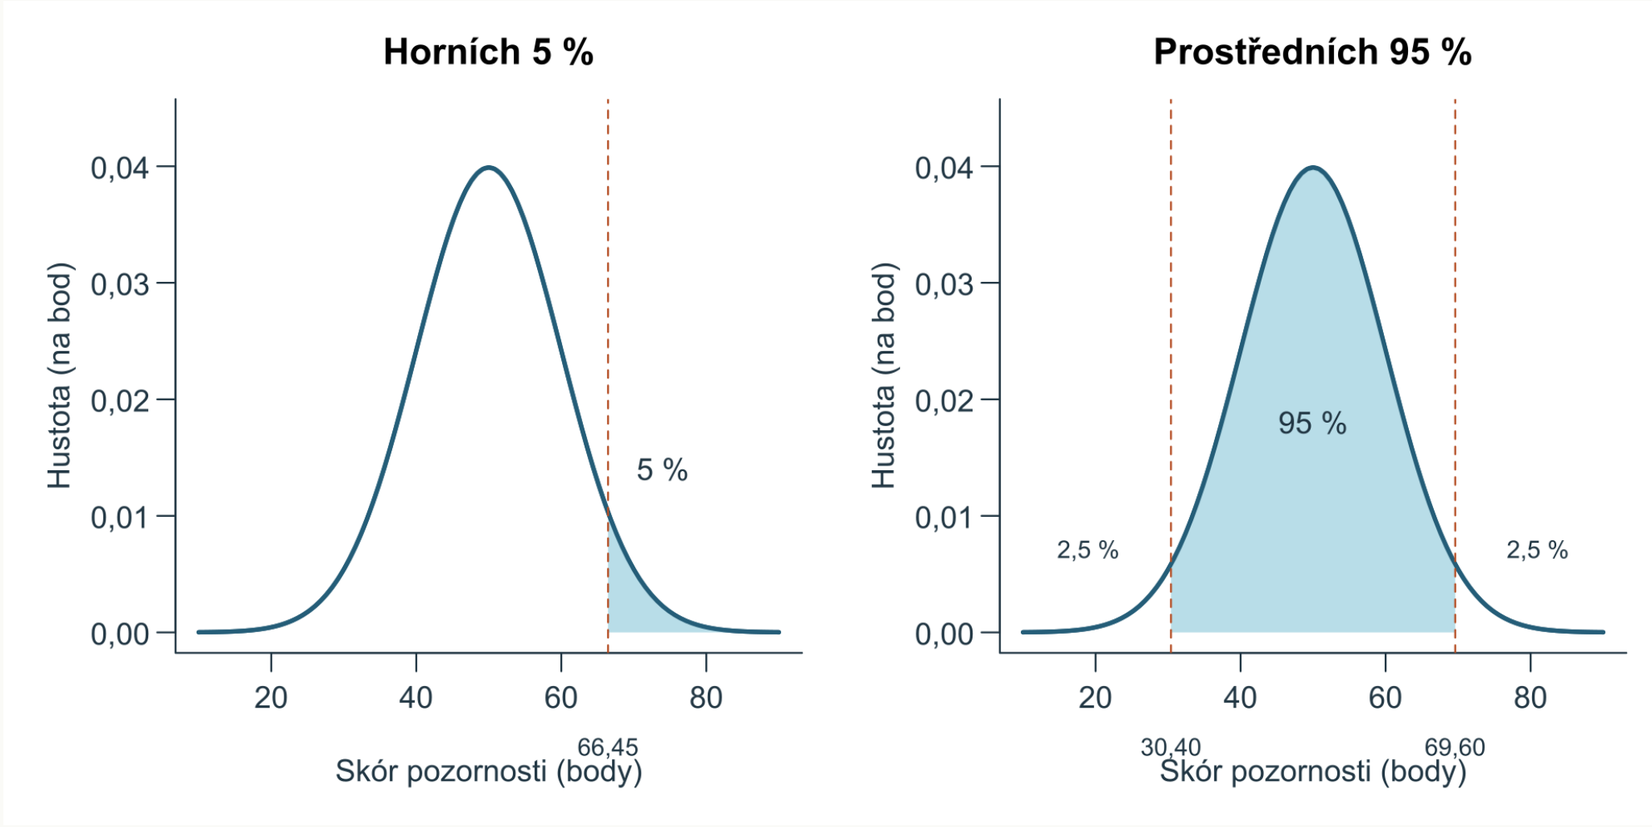
**Prostředních 95 %:** do chvostů 2,5 % + 2,5 %

Meze pro $p$ = 0,025 a 0,975: **30,40 a 69,60** bodu

**Horních 5 %:** jediná hranice, $p$ = 0,95

Hranice **66,45** bodu

Interval jednotlivých výsledků, ne diagnostický práh



# Hodnoty z, které je užitečné znát zpaměti

| z | Podíl nad +z | Mezi −z a +z | Typické použití |
|---|---|---|---|
| 0,674 | 25 % | 50 % | kvartily, prostředních 50 % |
| 1,645 | 5 % | 90 % | horních 5 %, prostředních 90 % |
| 1,960 | 2,5 % | 95 % | prostředních 95 % |
| 2,326 | 1 % | 98 % | horní 1 % |
| 2,576 | 0,5 % | 99 % | prostředních 99 % |
| 3,291 | 0,05 % | 99,9 % | prostředních 99,9 % |

Spolu s 1, 2 a 3 z pravidla 68–95–99,7; dolní meze se záporným znaménkem

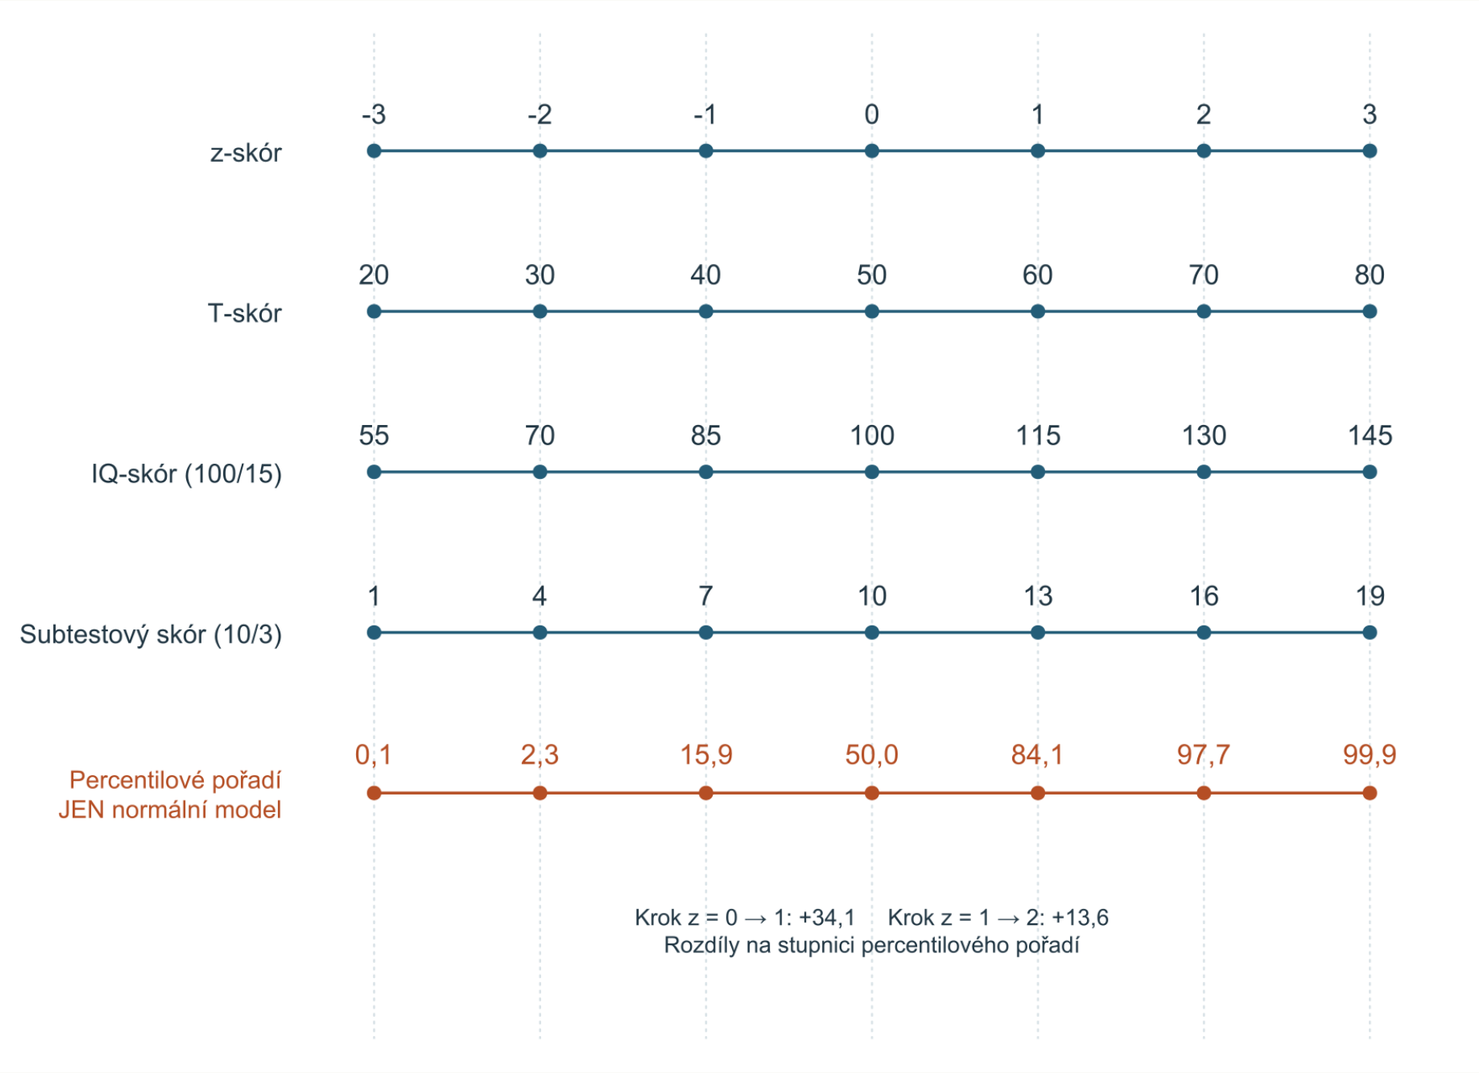
# Standardní skóry v psychologii

# Stejná poloha, různá čísla: standardní skóry

Nový skór = nový průměr + nová SD × *z*

| Škála | Průměr | SD | z = 1,5 |
|---|---|---|---|
| z-skór | 0 | 1 | 1,5 |
| T-skór | 50 | 10 | 65 |
| IQ-skór | 100 | 15 | 122,5 |
| subtest 10/3 | 10 | 3 | 14,5 |

Lineární převod normalitu nepotřebuje; percentilové pořadí ano



# Steny a staniny: pásma místo jemné škály

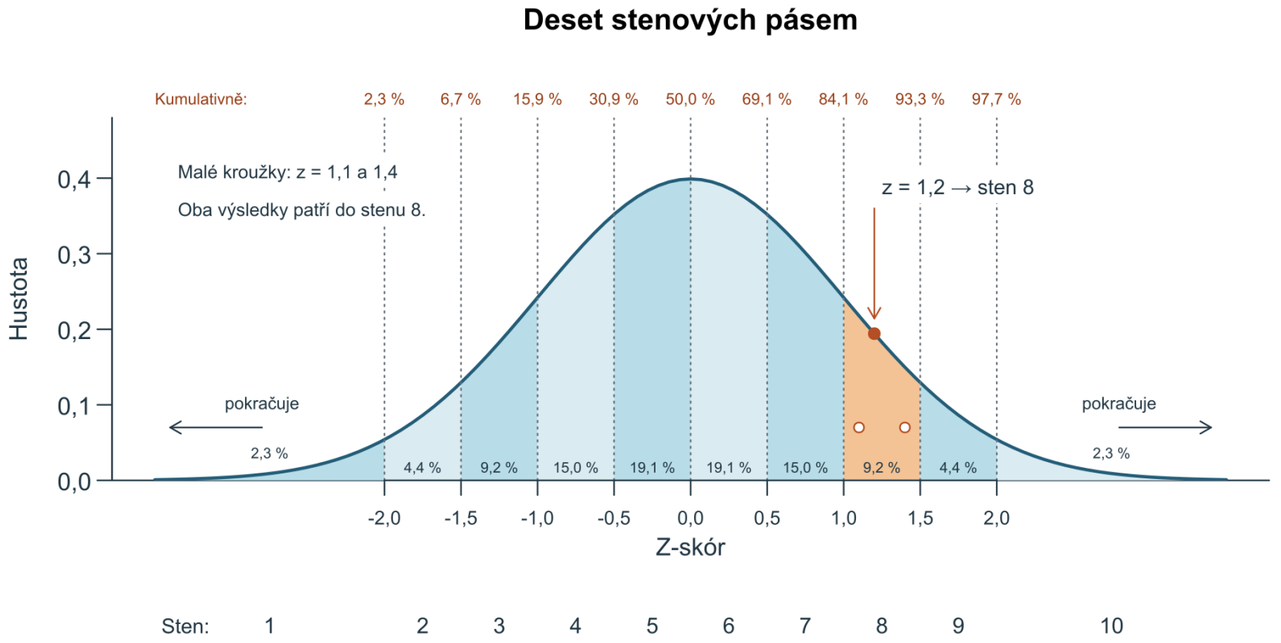
**Sten** 1–10, **stanin** 1–9

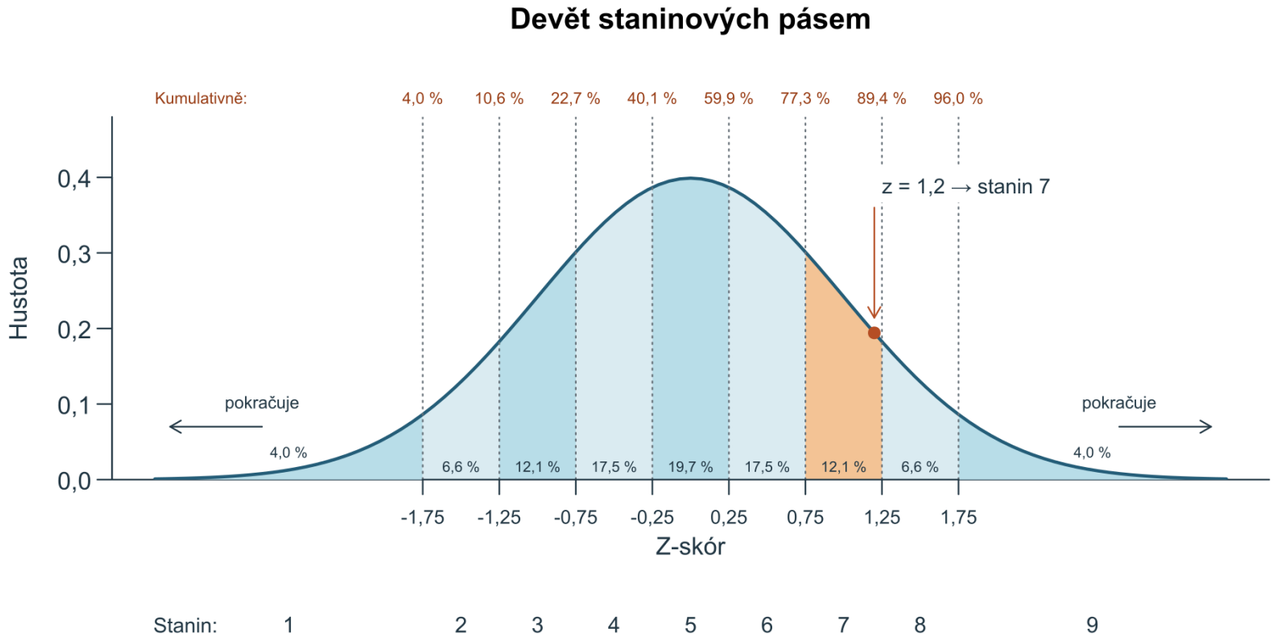
Pomocná hodnota 5,5 + 2*z* (sten), 5 + 2*z* (stanin)

*z* = 1,2: 7,9 → **sten 8**; 7,4 → **stanin 7**

Krajní pásma slučují vše za mezemi

Pásma nejsou stejně početná; přesný skór z pásma nezjistíme



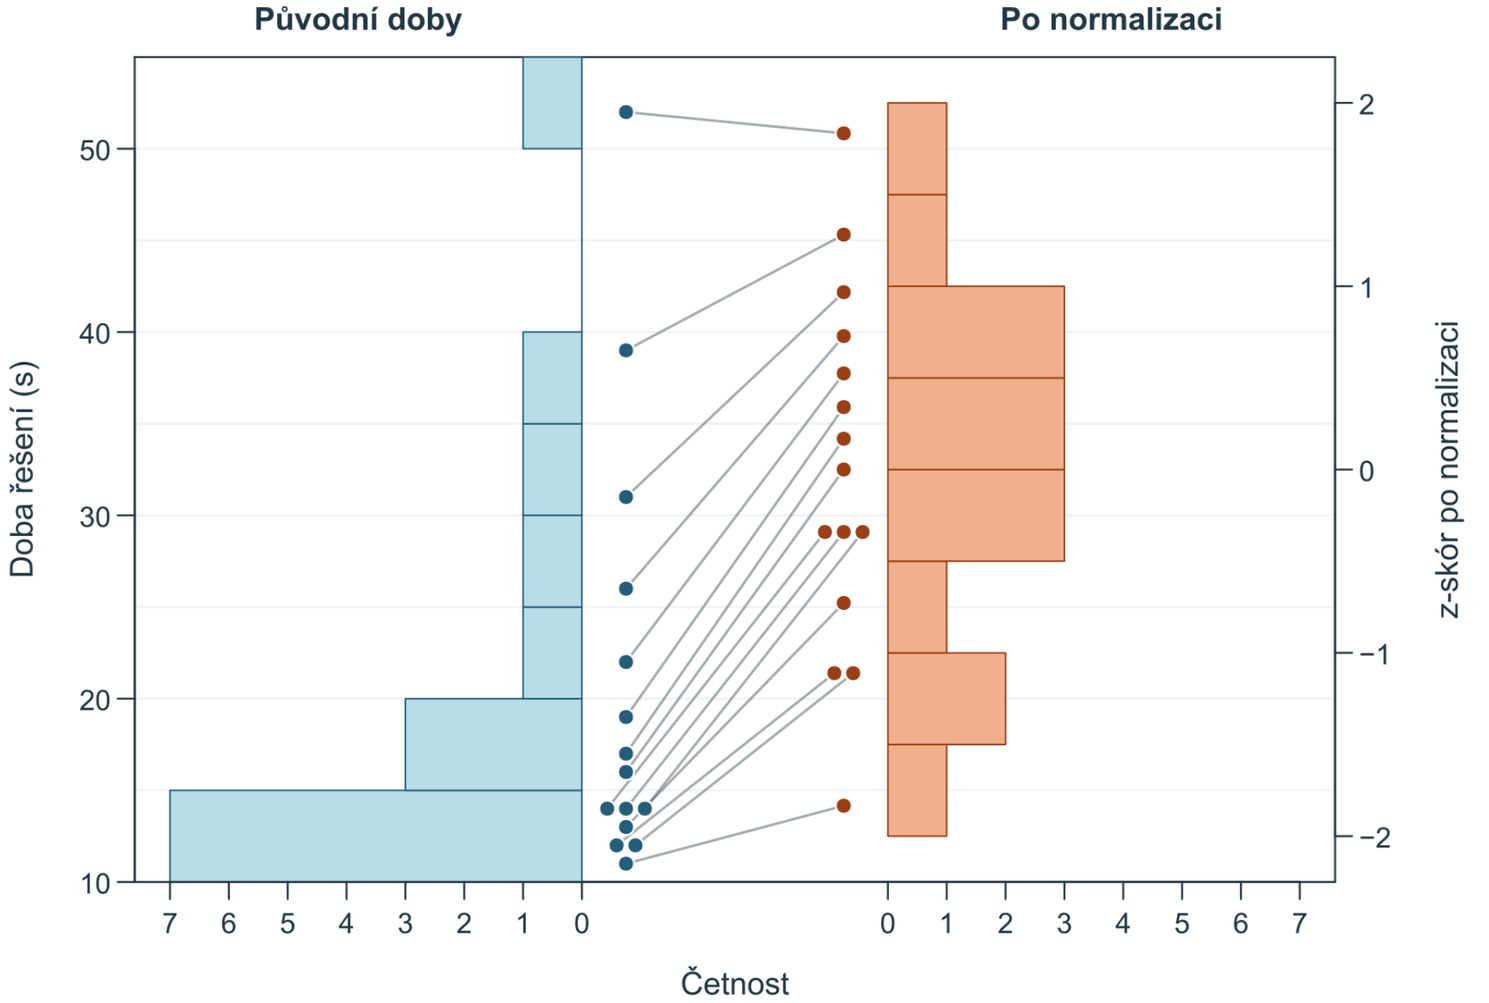
# Standardizace není normalizace

**Normalizace:** pořadí → normální kvantil (NORM.S.INV)

Zachová pořadí, **změní rozestupy** i tvar

Standardizace tvar zachová

Normálně vypadající normalizované skóry nedokazují normalitu hrubých skórů




Patnáct dob řešení úlohy v sekundách

# Je normální model přiměřený?

# Začínáme významem měření a histogramem

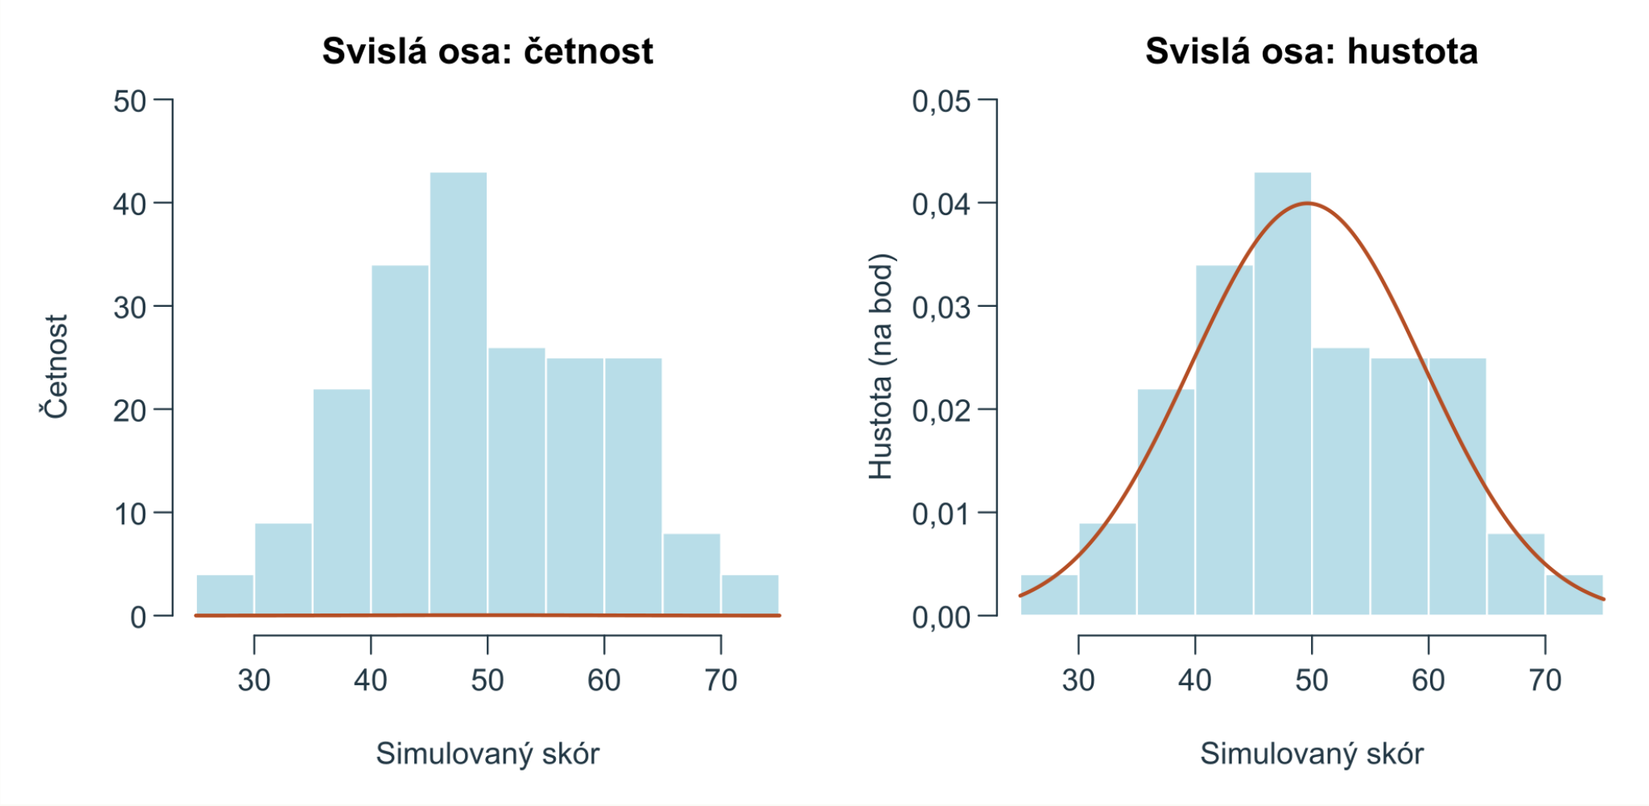
Která proměnná, skupina a **otázka**?

Meze škály, strop, chyby, směs skupin?

Histogram s několika šířkami intervalů

Křivku porovnáváme s histogramem **hustoty**

Pro odhad vysokých skórů potřebujeme věrný pravý chvost



# Normální Q–Q graf: data proti kvantilům modelu

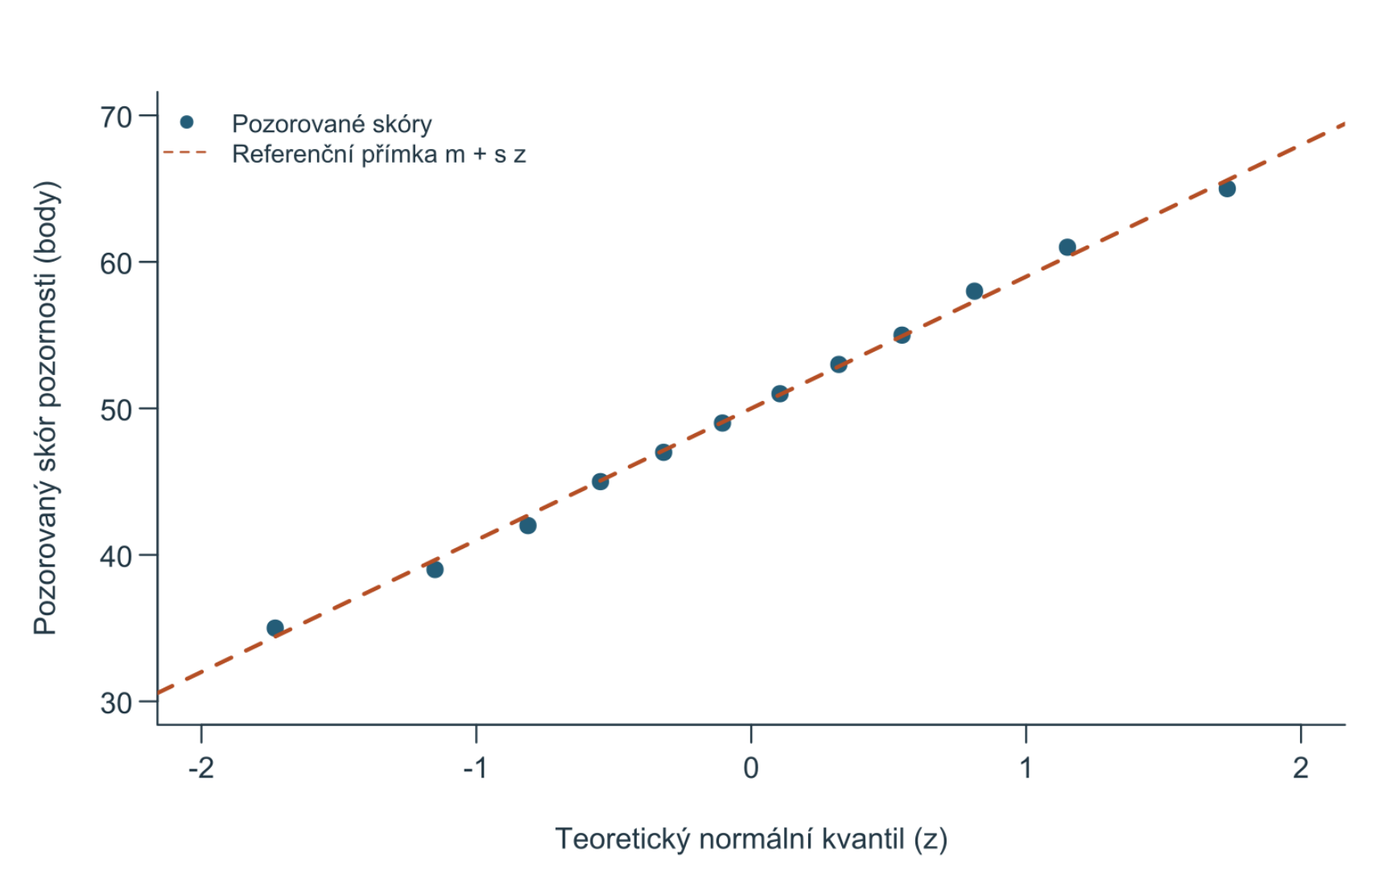
Vodorovně: **teoretický kvantil** N(0, 1)

Svisle: **seřazená pozorovaná hodnota**

Přímka $m + s \times z$: modelová srovnávací hodnota

Přibližně přímka = data **slučitelná** s modelem

Není to důkaz normality; malý soubor říká málo o chvostech




Dvanáct skórů pozornosti (body)

# Jak vzniká bod Q–Q grafu

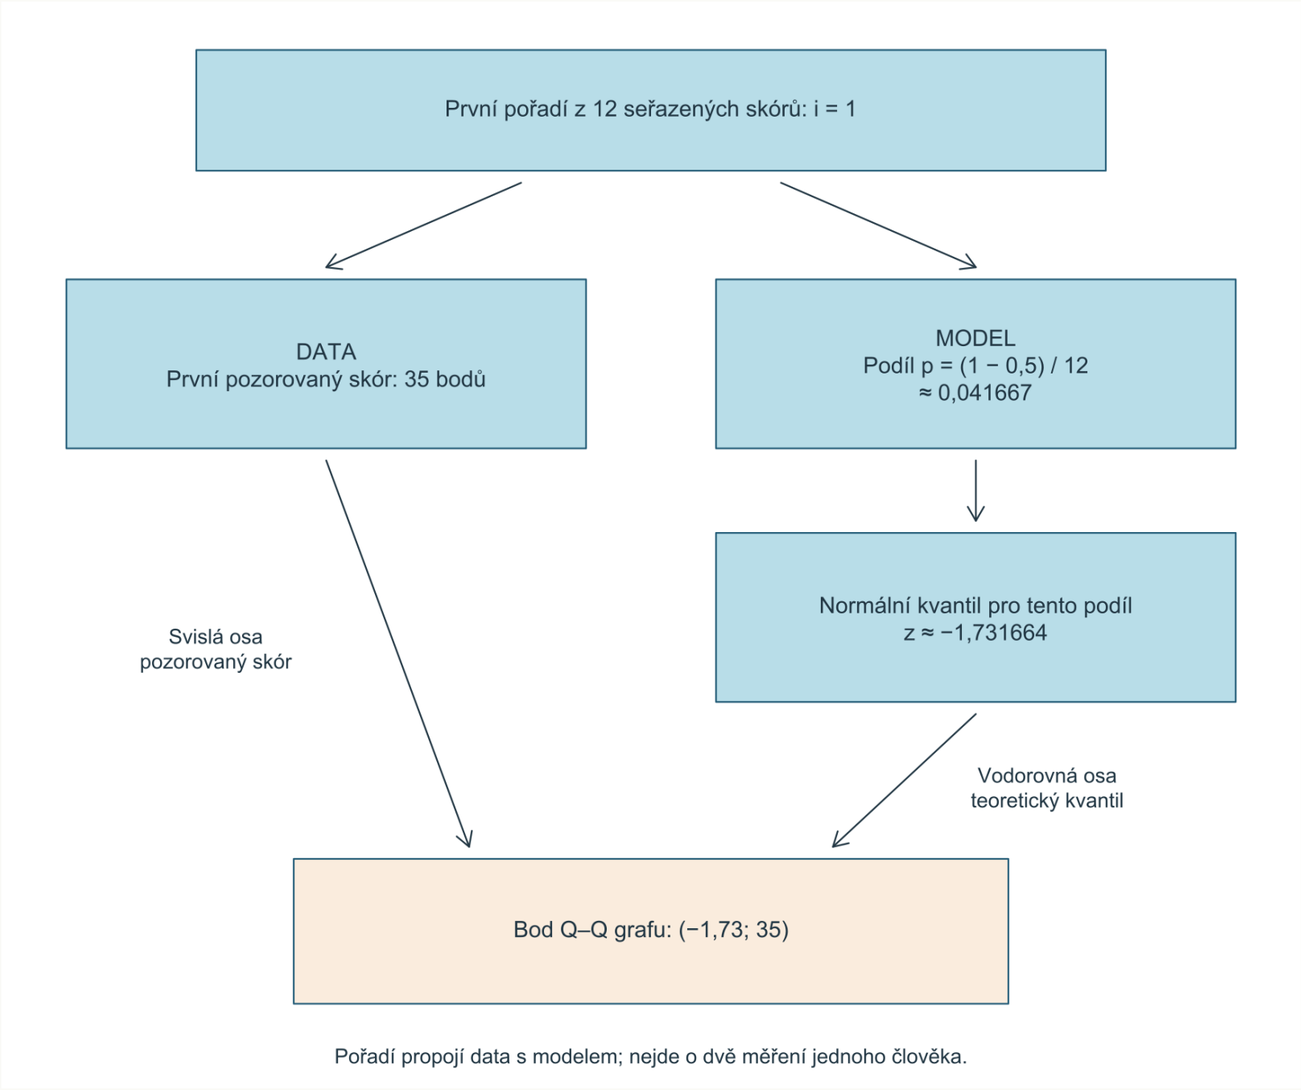
Seřadit hodnoty, pořadí $i = 1$ až $n$

$$p = \frac{i - 0{,}5}{n}$$

$z$ = NORM.S.INV($p$); přímka $m + s\,z$

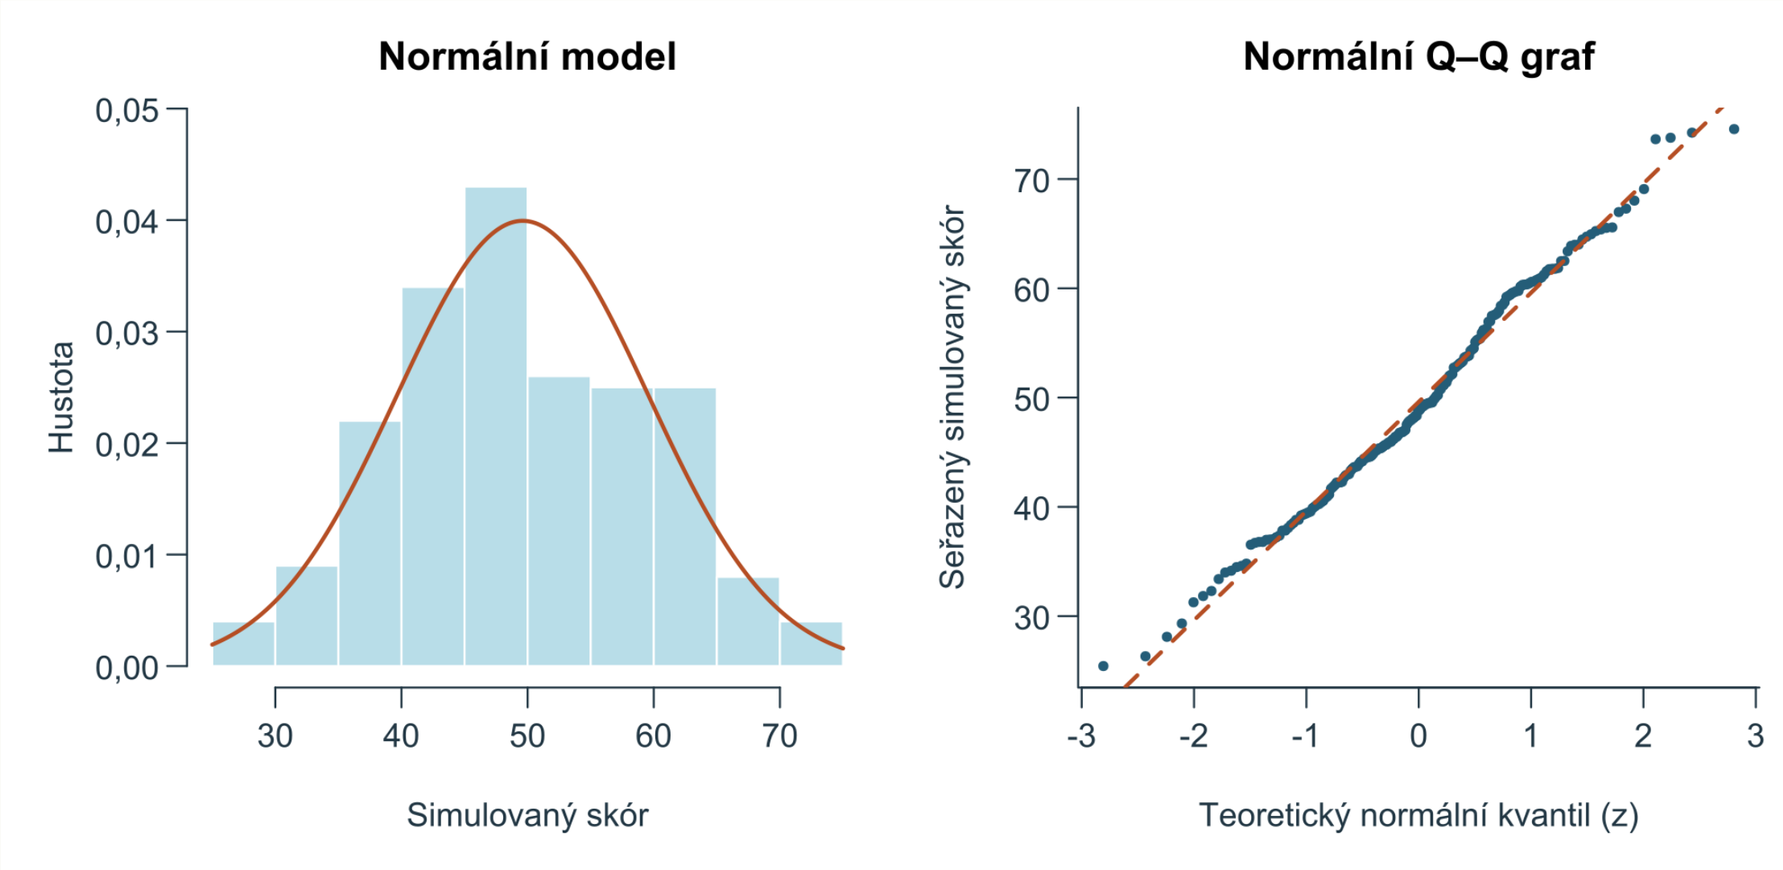
První bod: (−1,73; 35)

Bodový graf XY: řada bodů a řada přímky



# Normální model: body kolísají kolem přímky

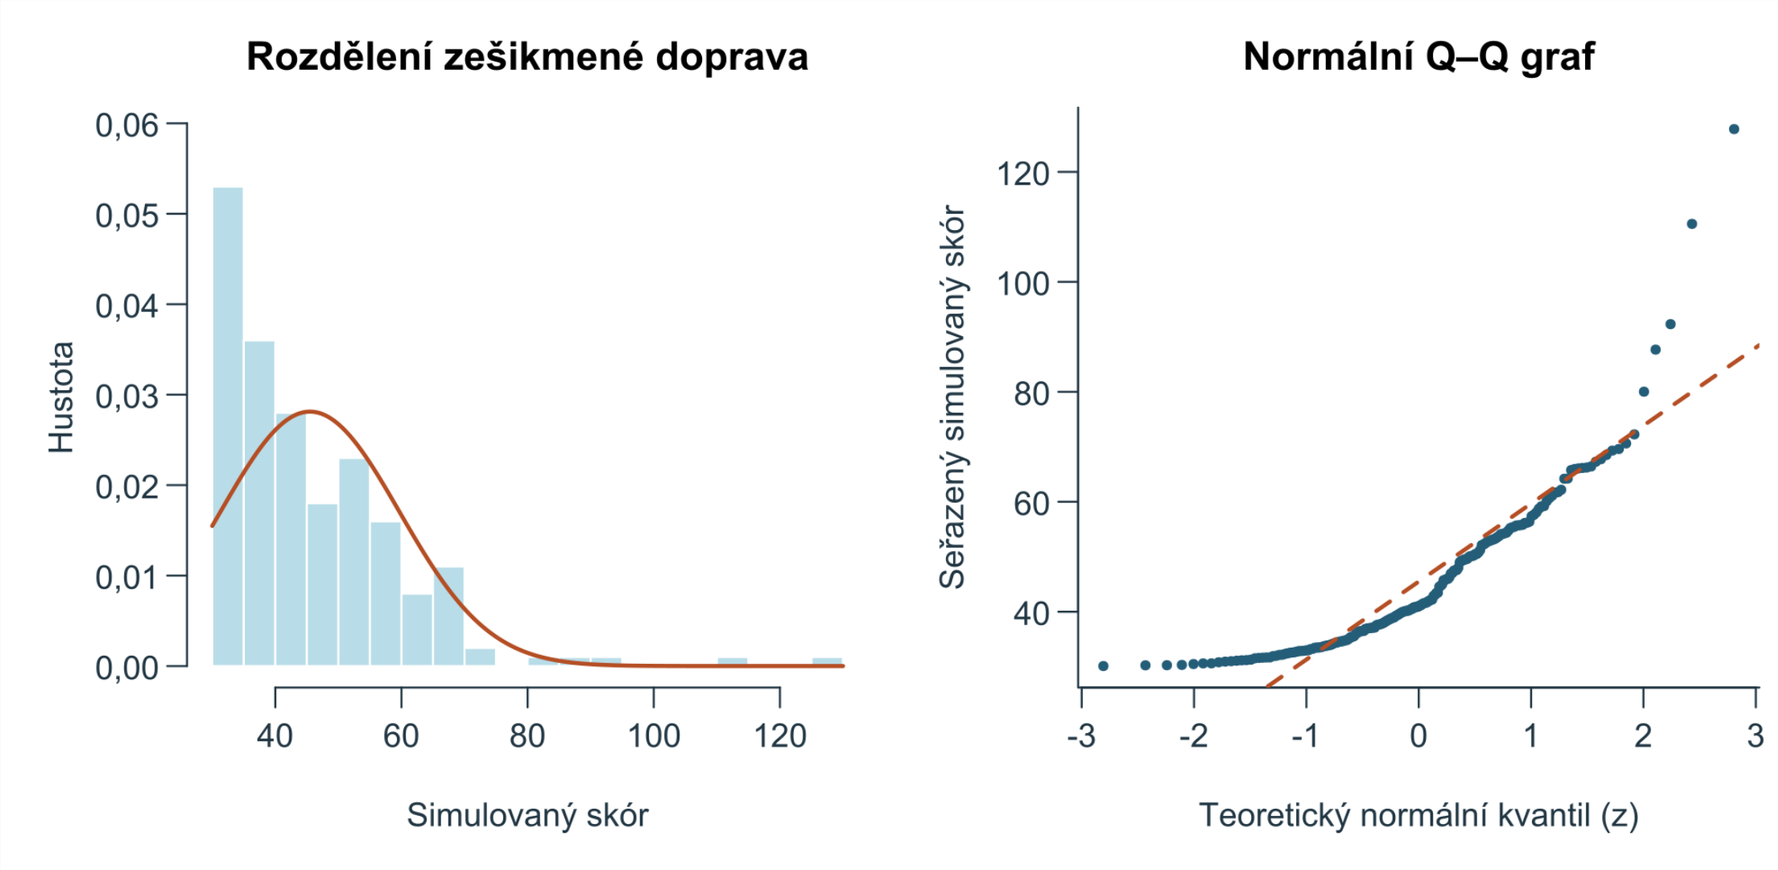
Jen tento soubor je z normálního modelu · Drobné odchylky na krajích jsou běžné




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Zešikmení doprava: oblouk a vysoký pravý konec

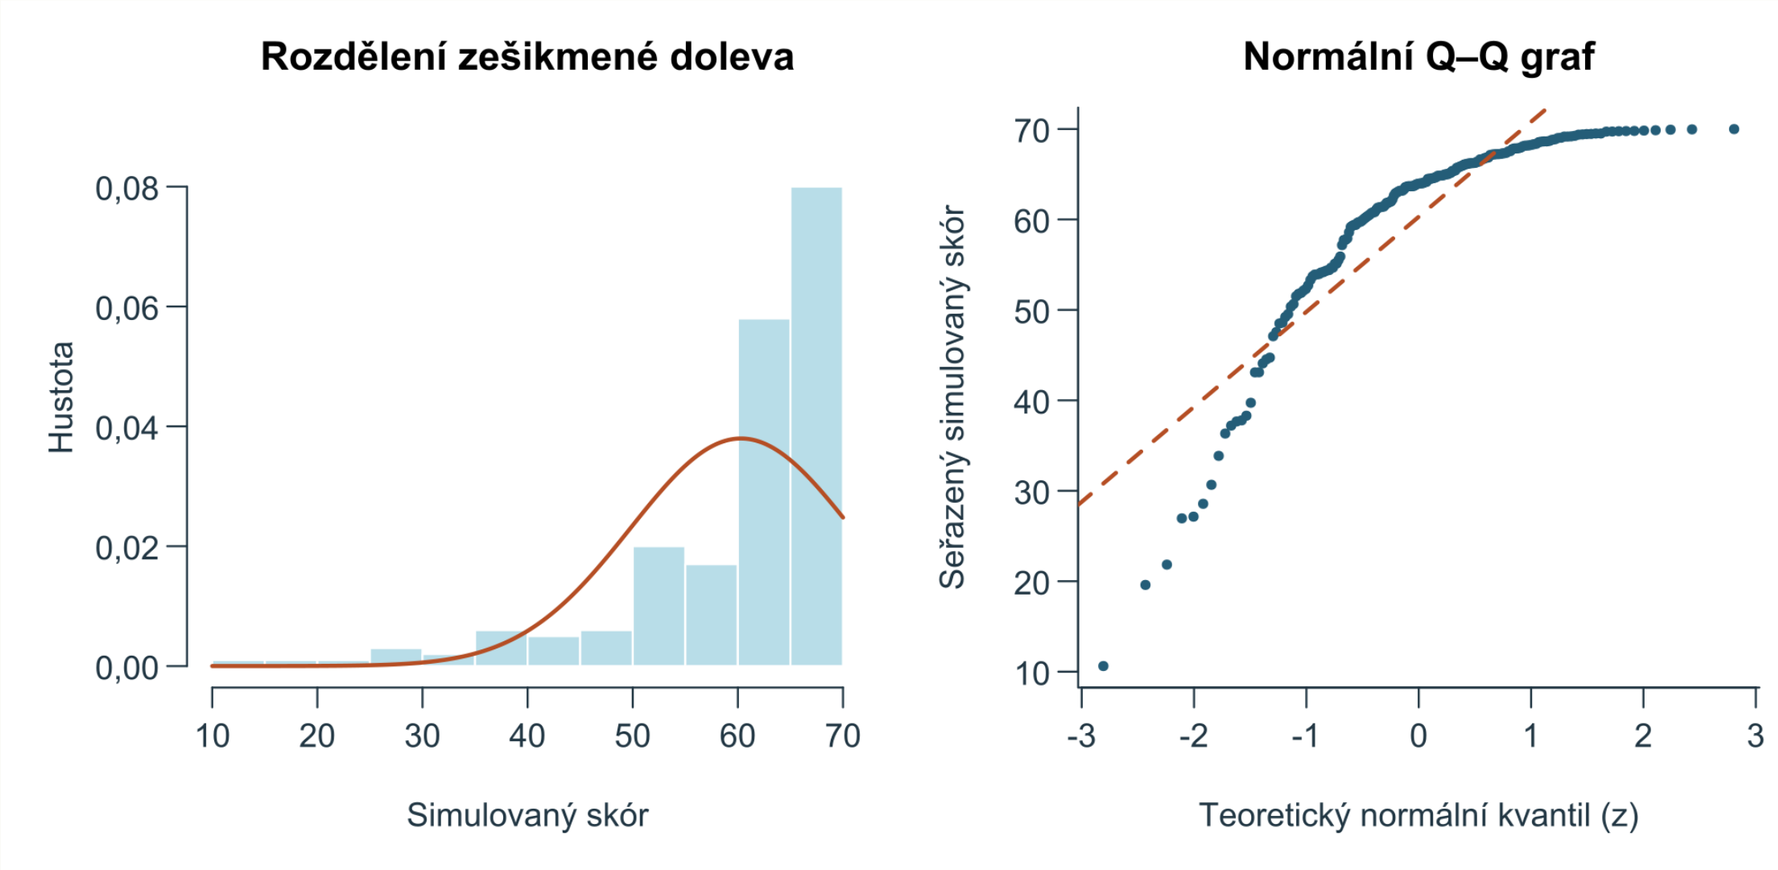
Body nad přímkou: model hodnotu **podhodnocuje** · 99. percentil: model 78,5, data 92,5




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Zešikmení doleva: opačný oblouk pod stropem

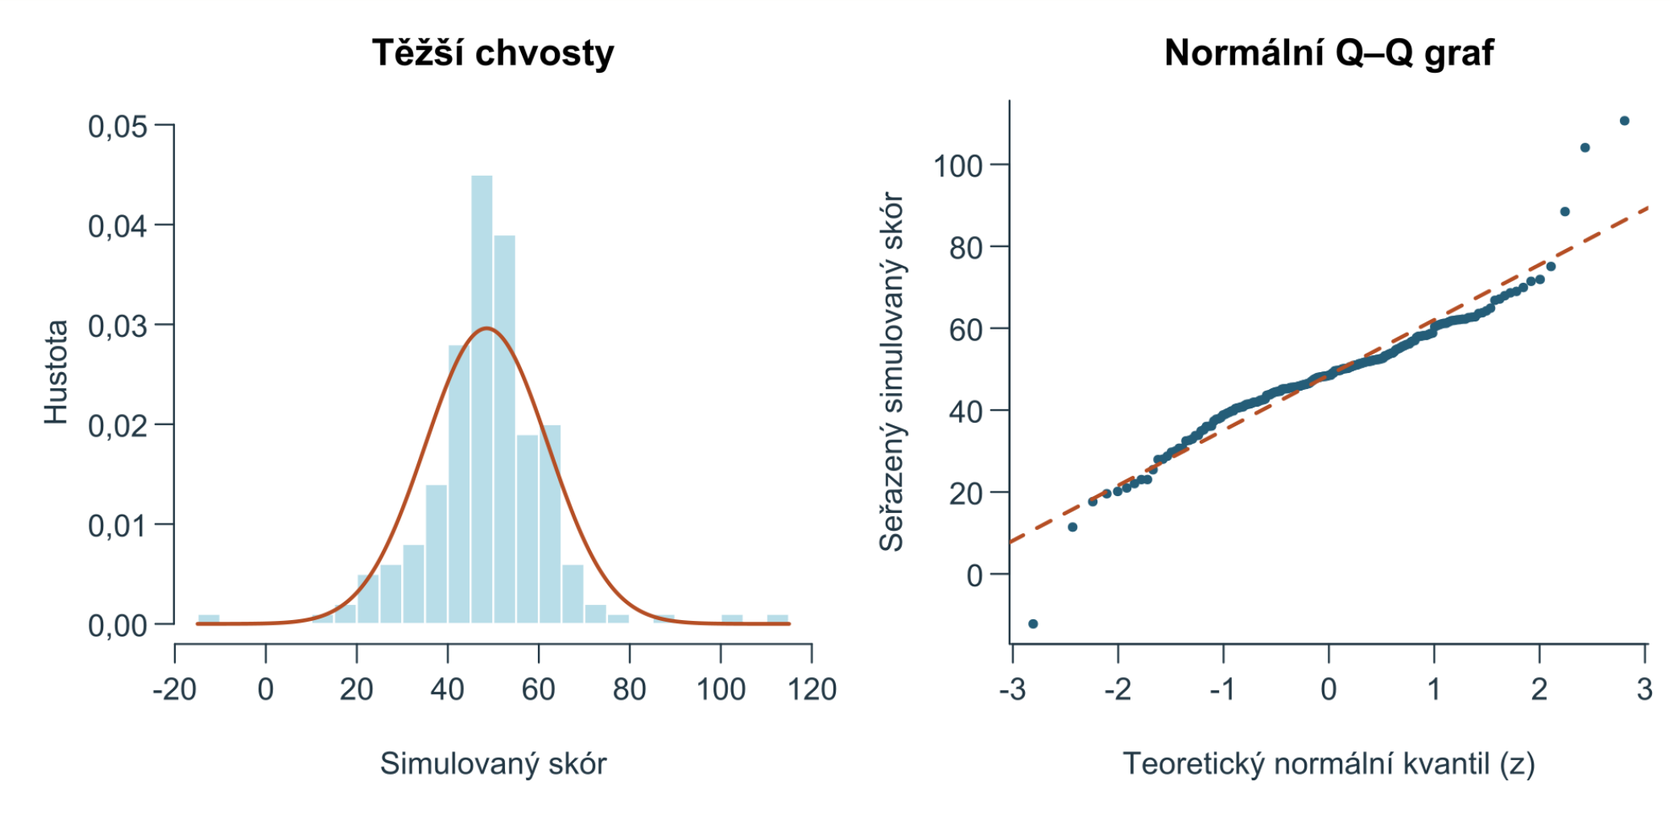
Strop 70 bodů, dlouhý levý chvost · 99. percentil modelu 84,7: nad stropem, nedosažitelný




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Těžší chvosty: leptokurtické rozdělení

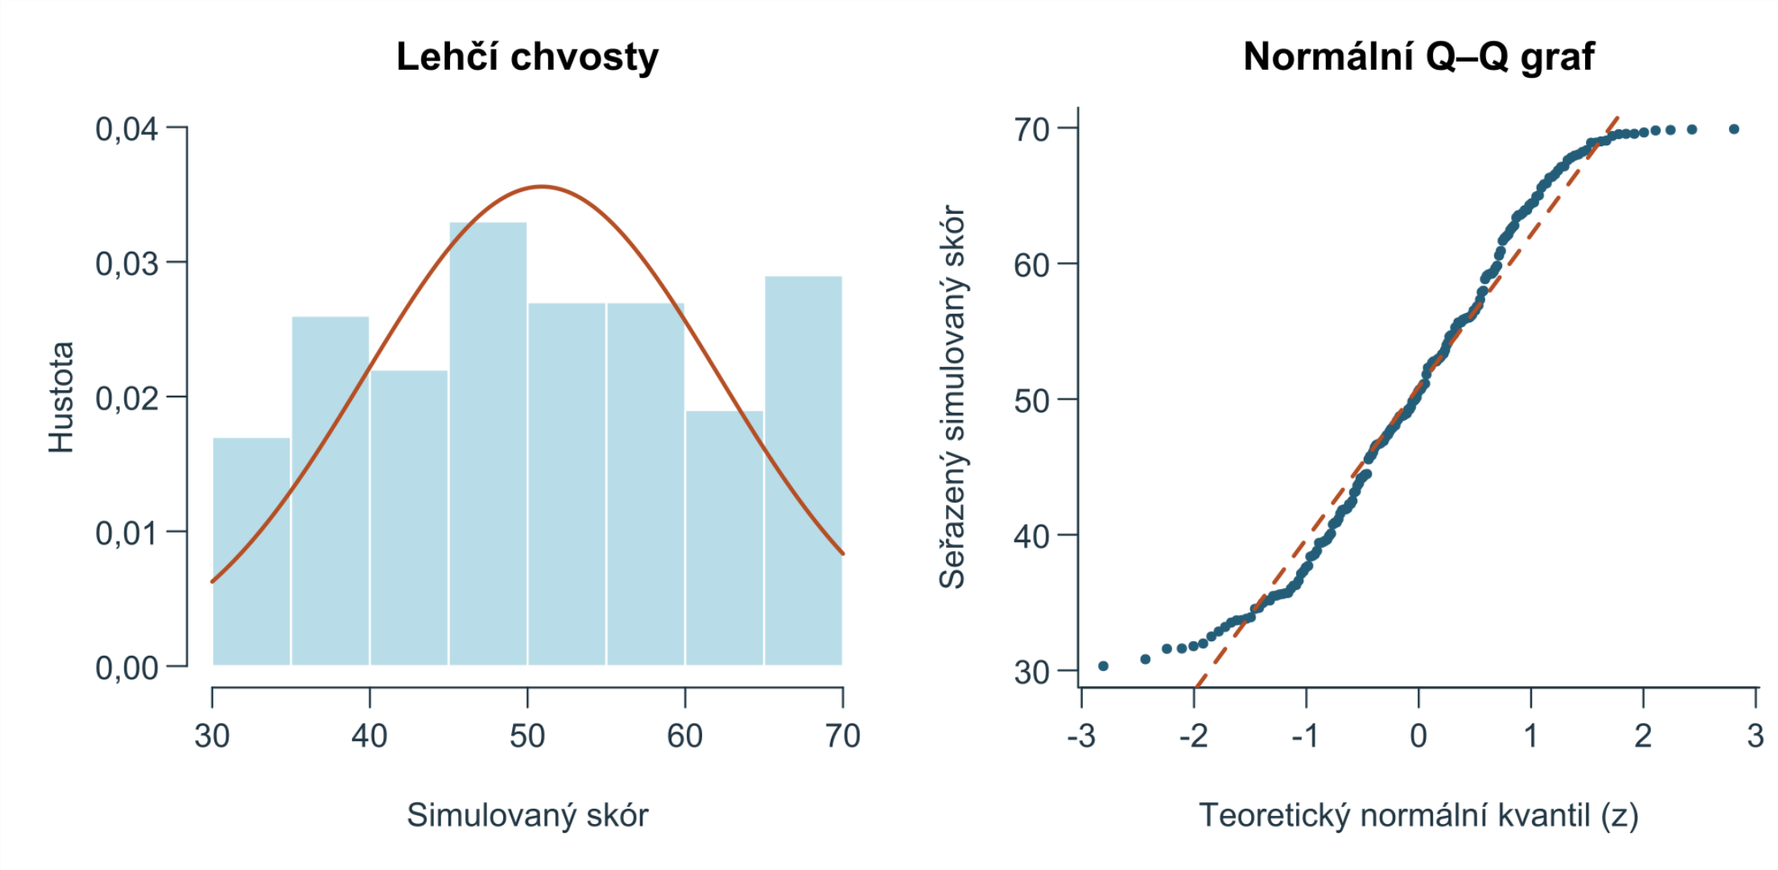
Souměrné, ale vzdálené hodnoty jsou častější · Levý konec pod přímkou, pravý nad ní; exces kladný




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Lehčí chvosty: platykurtické rozdělení

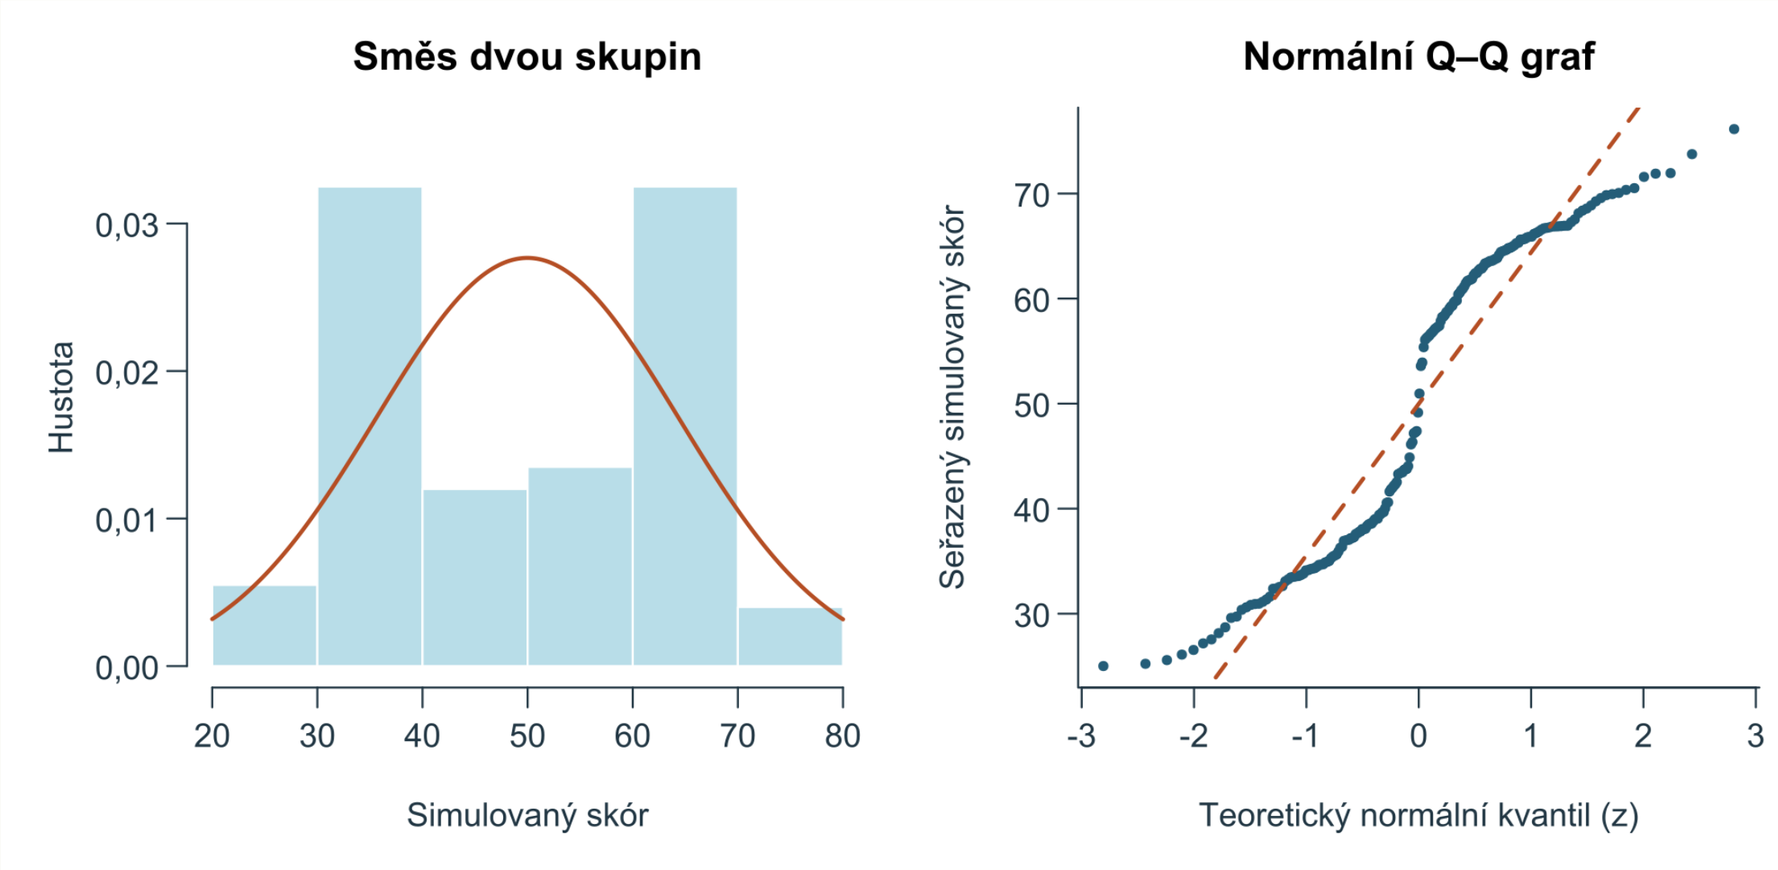
Rovnoměrně 30 až 70, vzdálené hodnoty chybějí · Levý konec nad přímkou, exces záporný




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Směs dvou skupin: dva vrcholy a zlom uprostřed

Jeden model čeká hodnoty uprostřed, kde nejsou · Věcně odlišné skupiny popíšeme zvlášť




Simulovaná data, 200 hodnot; křivka a přímka s průměrem a směrodatnou odchylkou souboru

# Přiměřenost modelu je závěr s omezeními

Spojíme význam měření, histogram a Q–Q graf

Uvedeme **účel**, pro který model přijímáme, a omezení

Větší soubor ukáže tvar přesněji, ale **nenormalizuje** data

Grafy neověřují reprezentativnost, měření ani nezávislost

Nevyhovuje-li model: empirické kvantily, případně skupiny zvlášť

# Procvičování

# Úloha 1: Je 950 zákazníků rozumný výsledek?

Mnoho posuzovatelů počítalo zákazníky, kteří ráno vešli do obchodního domu. Počty mají přibližně normální rozdělení s průměrem 975 a směrodatnou odchylkou 15.

Vedoucí projektu napočítal jen 950 zákazníků. Je to rozumný výsledek, pokud počítal svědomitě? Zdůvodněte bez Excelu.

Howell (2013), s. 79, úlohy 3.3 a 3.5. Česká adaptace.

# Úloha 2: Kdy se dva podíly rovnají?

Čtenářské skóry žáků 4. třídy mají rozdělení N(25, 5), žáků 9. třídy N(30, 10).

Podíl A: kolik procent čtvrťáků má lepší výsledek než průměrný deváťák? Podíl B: kolik procent deváťáků má horší výsledek než průměrný čtvrťák?

Za jakých podmínek by se podíly A a B rovnaly?

Howell (2013), s. 79–80, úlohy 3.6 a 3.7. Česká adaptace.

# Úloha 3: Vymyslel si student výsledek?

Studenti pozorovali vždy 100 aut a zaznamenali, kolik lidí bylo připoutaných. Průměr třídy je 44, směrodatná odchylka 7; předpokládejte normální rozdělení.

Student, který celý rok téměř nepracoval, odevzdal 62. Máme důvod podezírat, že si číslo vymyslel? Co z výpočtu plyne a co ne?

Howell (2013), s. 80, úloha 3.10. Česká adaptace s doplňující otázkou.

# Úloha 4: Převod škály a zešikmený test

Test jazykových obtíží počítá správně utvořené jazykové konstrukce. Má průměr 48 a směrodatnou odchylku 7. Autorka chce skóry převést na škálu s průměrem 80 a směrodatnou odchylkou 10.

a) Jak převod provést? Jaký nový skór dostane dítě se 34 body?

b) Skutečné rozdělení je silně zešikmené, protože většina dětí obtíže nemá. Jak najít hranici dolních 10 %?

Howell (2013), s. 80, úlohy 3.11 a 3.12. Česká adaptace s doplněným příkladem.

# Úloha 5: Proč T-skóry ve vzorku nemají přesně 50 a 10?

Dotazník problémového chování vykazuje T-skóry, které mají mít průměr 50 a směrodatnou odchylku 10.

Ve vzorku dětí, které jsme vyšetřili, vyšel průměr T-skórů 53,4 a směrodatná odchylka 11,2. Čím to může být? Je to chyba výpočtu?

Howell (2013), s. 80, úloha 3.19. Česká adaptace, čísla vzorku doplněna.

# Úloha 6: Zešikmené platy a normální model

Roční platy profesorů psychologie se 7–11 lety praxe mají rozdělení výrazně zešikmené doprava: většina platů je blízko sebe, několik je mnohem vyšších.

Co by se stalo, kdybychom s nimi zacházeli, jako by měly normální rozdělení? Jak by vypadal jejich Q–Q graf? Čím mohou být vysoké hodnoty způsobeny?

Howell (2013), s. 81, úloha 3.24. Česká adaptace bez logaritmické transformace.

# Práce v Excelu: doprovodný sešit

**kapitola_04_normalni_rozdeleni_cviceni.xlsx**

U1_z_skor: šestnáct hodnot, z-skóry po krocích; U8_QQ: Q–Q graf týchž dat

U2_podily, U3_hranice: počty zákazníků N(975, 15)

U4_dve_skupiny, U5_diagnostika, U6_referencni: další modely

U7_T_skory: T-skóry, IQ, subtestová škála, steny a staniny

Howell (2013), s. 79–81, úlohy 3.1–3.4, 3.6, 3.8, 3.13–3.15, 3.18 a 3.20–3.21. Česká adaptace.