Pravděpodobnost

Kapitola 5

Obsah přednášky

1. Co pravděpodobnost vyjadřuje
2. Jevy a pravidla počítání
3. Podmíněná pravděpodobnost a nezávislost
4. Obrácení podmínky: Bayesova věta
5. Rozdělení pravděpodobnosti a binomický model
6. Normální aproximace a podíl
7. Procvičování

Co pravděpodobnost vyjadřuje

Od relativní četnosti k pravděpodobnosti

Data: 14 z 36 účastníků se cítí „dost“ odpočatě

Relativní četnost 14/36 ≈ 0,389 popisuje soubor, který už máme

Jeden z 36 lístků se jmény vytáhneme naslepo: *P*(odpověď „dost“) = 14/36 ≈ 0,389

Pravděpodobnost: číslo od 0 do 1 (0 až 100 %), které vyjadřuje, nakolik lze očekávat, že něco nastane

Velké *P* = pravděpodobnost; malé *p* = relativní četnost nebo úroveň kvantilu

Tři pojetí: odkud číslo pochází

Pojetí	Z čeho číslo vychází	Příklad
Klasické	podíl příznivých mezi stejně pravděpodobnými výsledky	14 z 36 lístků
Četnostní	relativní četnost, k níž se blížíme ve velmi dlouhé řadě opakování	podíl odpovědí „dost“ v mnoha tazích s vracením
Subjektivní	míra přesvědčení podle dostupných informací	terapeutka: klient dokončí terapii s P = 0,7

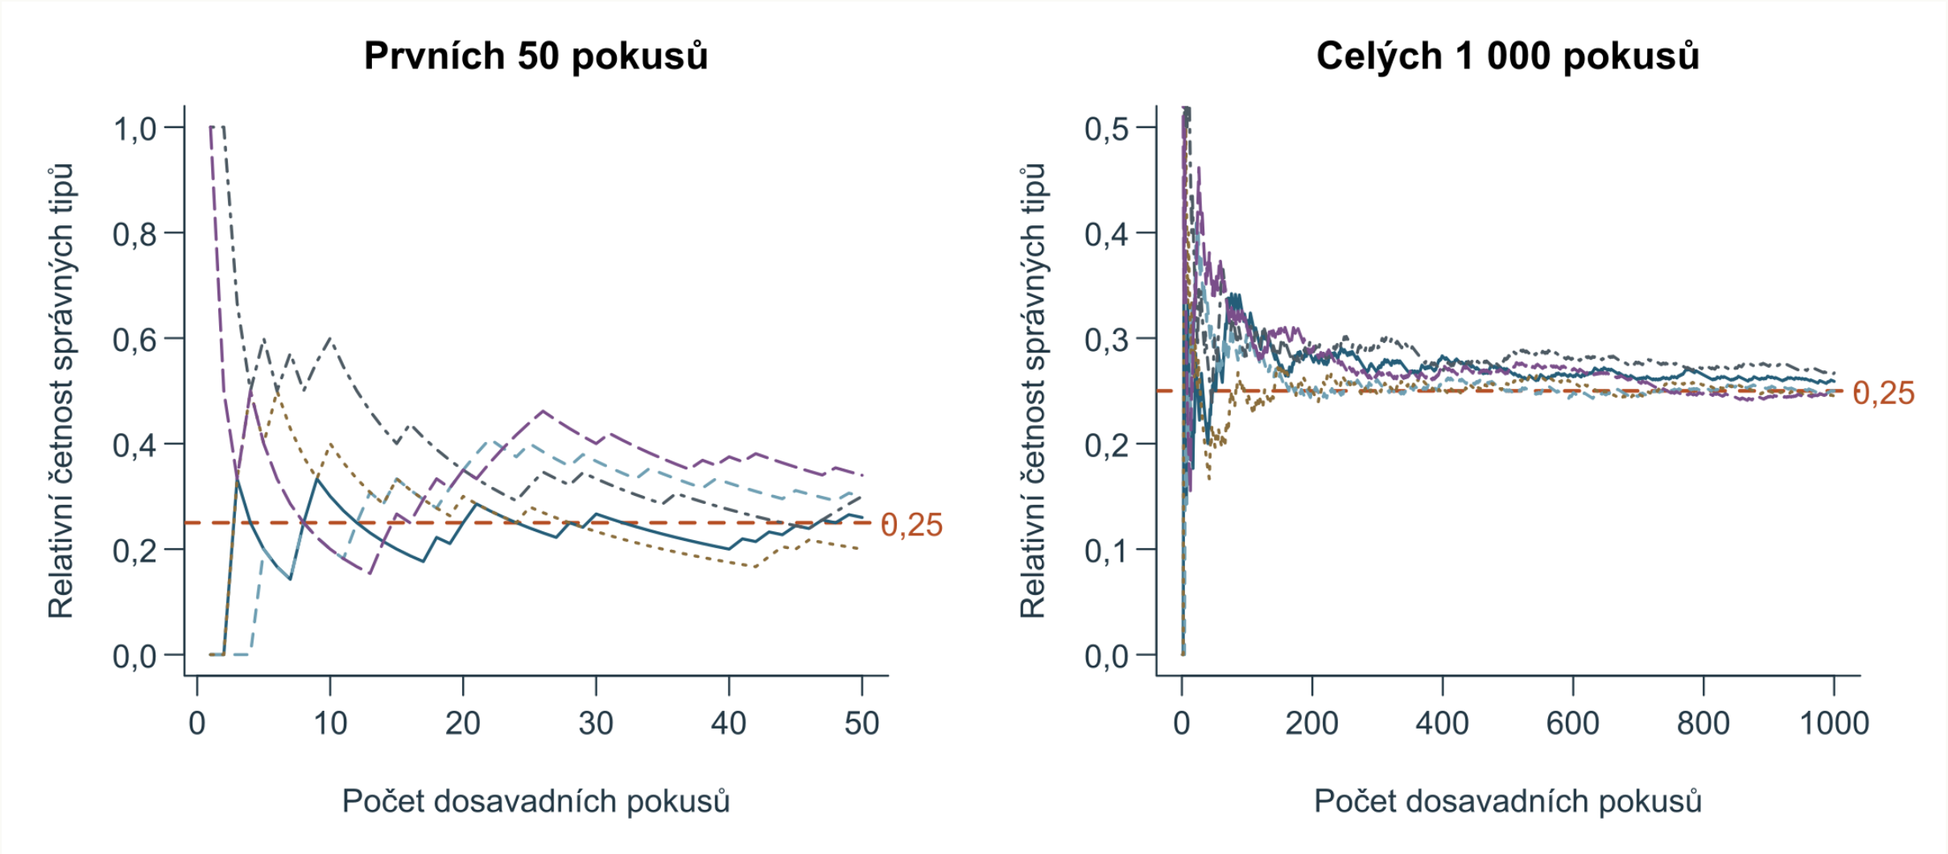
Interpretace se liší, **pravidla počítání jsou stejná**

Dlouhá řada kolísání zmenšuje, nic nevyrovnává

Tip na otázku se čtyřmi možnostmi: *P*(správně) = 0,25; pět řad po 1 000 tipech

Po 10 tipech 0,20 až 0,60; po 50 tipech 0,20 až 0,34; po 1 000 tipech 0,244 až 0,267

Hráčský klam: po sérii neúspěchů není úspěch „na řadě“



Simulovaná data

Jevy a pravidla počítání

Jev je množina výsledků

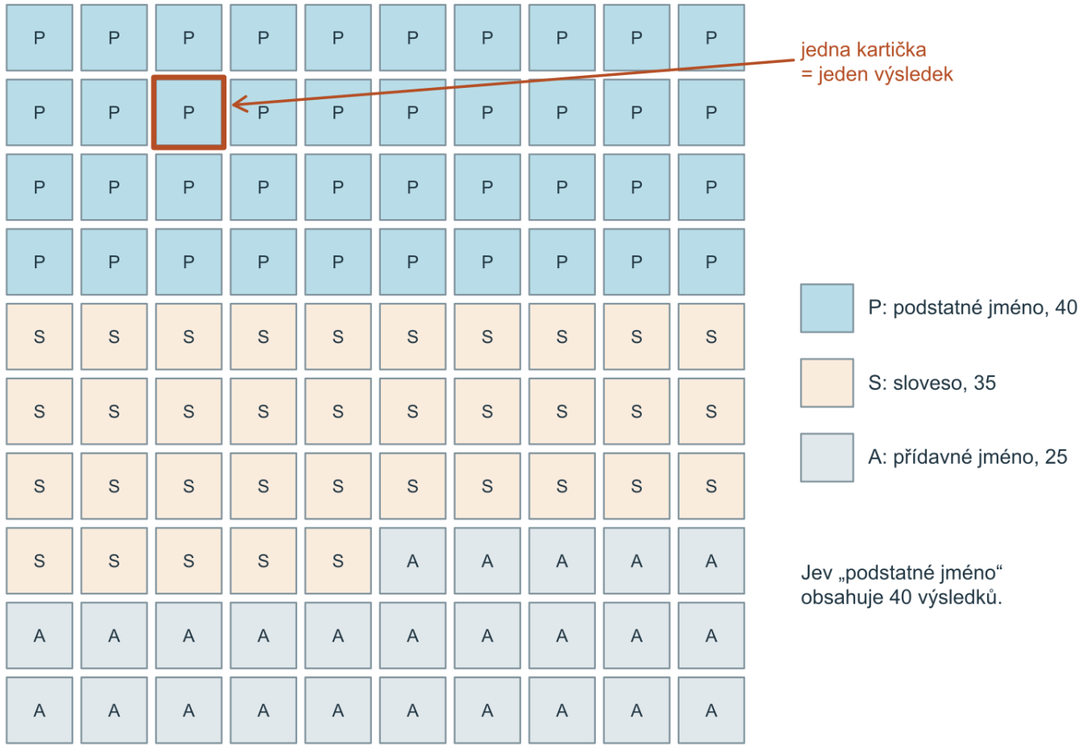
Náhodný pokus: vytažení jedné ze 100 kartiček

Výsledek: konkrétní kartička;
výběrový prostor: všech 100 kartiček

Jev: množina výsledků se společnou vlastností, např. „podstatné jméno“ (40 kartiček)

P(podstatné jméno) = 40/100 = 0,40

Podíl jen pro stejně pravděpodobné výsledky:
kartičky ano, slovní druhy ne



Modelový příklad: krabice se 100 kartičkami

Opačný jev: dopočet do jedné

$$P(A') = 1 - P(A)$$

Opačný jev A′ obsahuje právě ty výsledky, které do A nepatří

P(není podstatné jméno) = 1 − 0,40 = 0,60, totéž jako 60/100

Jistý jev: *P* = 1; **nemožný jev:** *P* = 0

Ve spojitém modelu má nulovou pravděpodobnost i hodnota, která nastat může

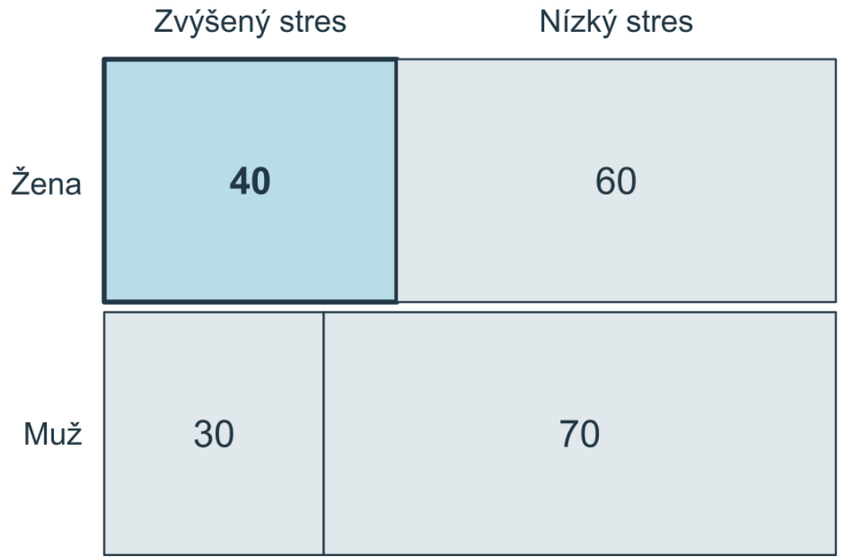
Průnik, sjednocení a součtové pravidlo

$$P(A \cup B) = P(A) + P(B) - P(A \cap B)$$

200 studentů: žen 100, zvýšený stres 70, obojí 40

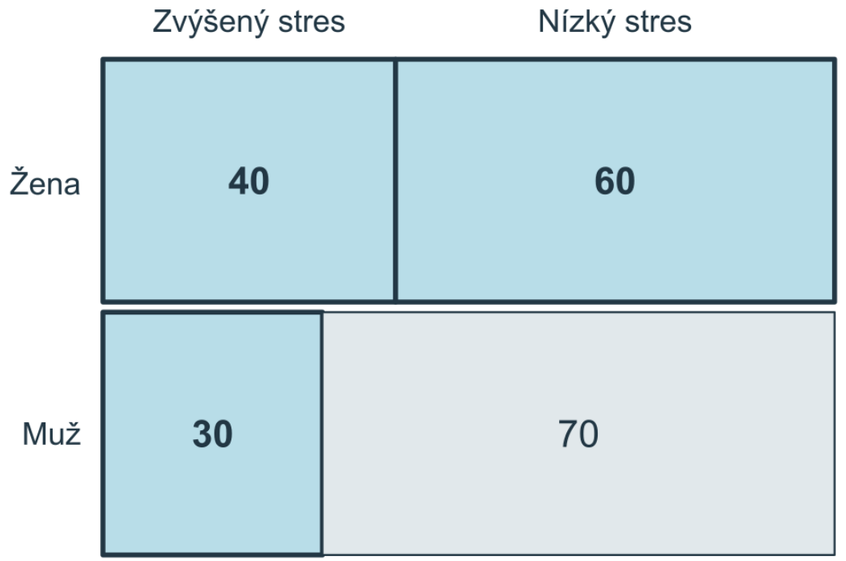
P(žena ∪ zvýšený stres) = 0,50 + 0,35 − 0,20 = **0,65**; bez odečtení bychom 40 studentek započítali dvakrát

Průnik: žena a zároveň zvýšený stres



40 z 200, tedy 0,20

Sjednocení: žena nebo zvýšený stres



40 + 60 + 30 = 130 z 200, tedy 0,65

Společná a marginální pravděpodobnost

	Zvýšený stres	Nízký stres	Celkem
Žena	40	60	100
Muž	30	70	100
Celkem	70	130	200

Společná: z vnitřního pole, $P(\text{muž} \cap \text{nízký stres}) = 70/200 = 0{,}35$

Marginální: z okraje, $P(\text{zvýšený stres}) = 70/200 = 0{,}20 + 0{,}15 = 0{,}35$

Modelový soubor 200 studentů

Konjunkční klam: věrohodnější není pravděpodobnější

„Klára studuje psychologii, ráda čte detektivky a o víkendech hraje deskové hry.“

a) Klára pracuje při studiu jako knihovnice.

b) Klára pracuje při studiu jako knihovnice a je členkou čtenářského klubu.

Průnik nemůže být pravděpodobnější než kterýkoli z jevů: $P(A \cap B) \leq P(A)$ a $P(A \cap B) \leq P(B)$

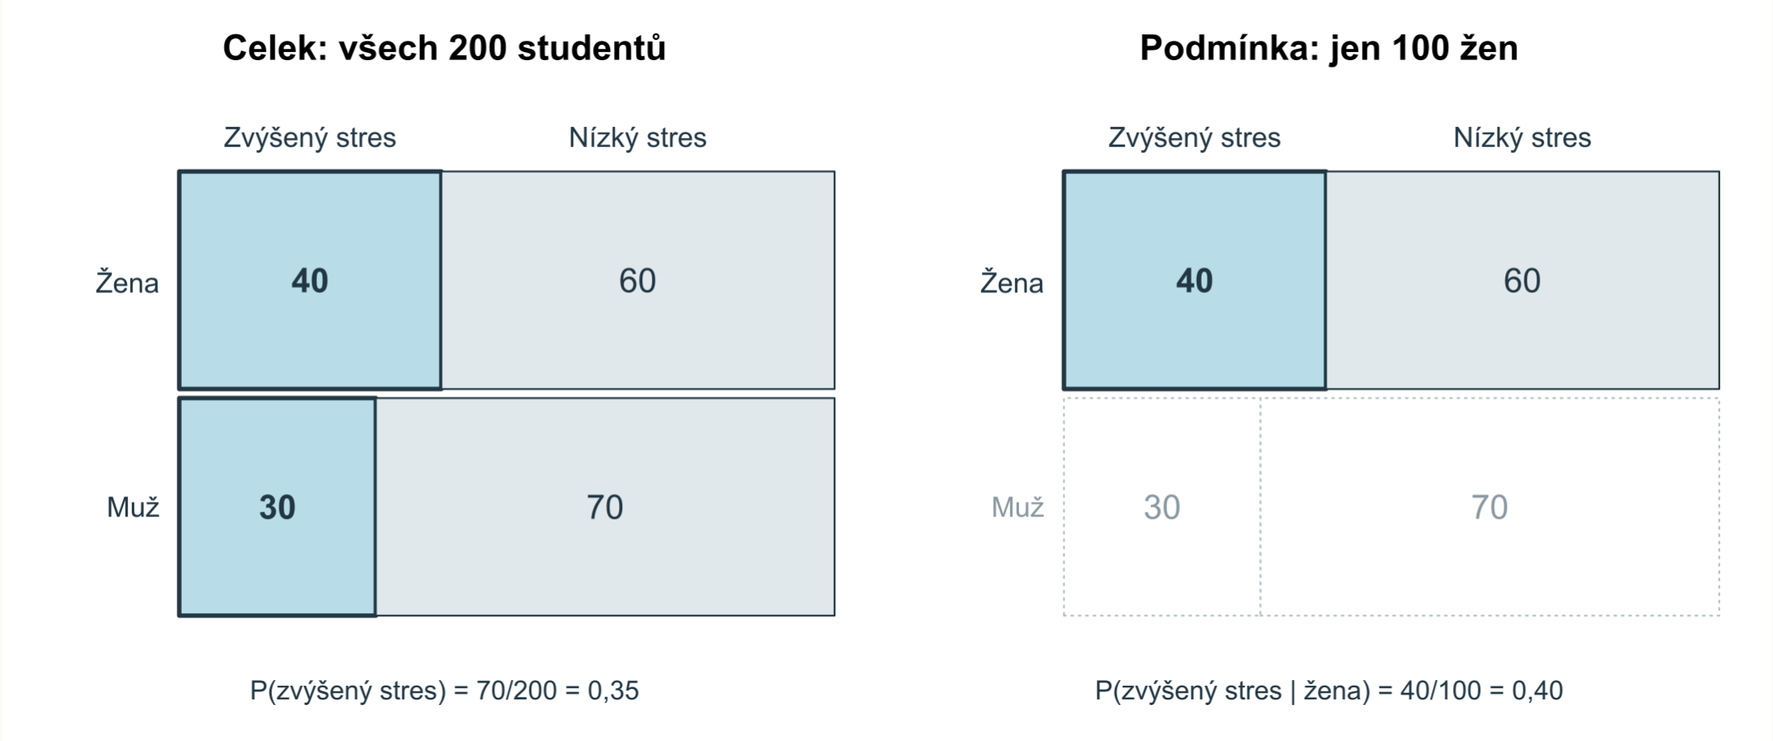
Konjunkční klam: otázku „jak pravděpodobné?“ nahradíme otázkou „jak dobře to sedí?“

Podmíněná pravděpodobnost a nezávislost

Podmínka zužuje celek

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}, \text{ pokud } P(B) > 0$$

P(zvýšený stres | žena) = 40/100 = 0,20/0,50 = **0,40**; marginálně 0,35



Modelový soubor 200 studentů

Z koho počítám? P(A | B) ≠ P(B | A)

Otázka	Zápis	Výpočet
Jaká část všech studentů jsou ženy se zvýšeným stresem?	P(žena ∩ zvýšený stres)	40/200 = 0,20
Jaká část žen uvedla zvýšený stres?	P(zvýšený stres | žena)	40/100 = 0,40
Jaká část studentů se zvýšeným stresem jsou ženy?	P(žena | zvýšený stres)	40/70 = 0,57

Podmínka neoznačuje časové pořadí ani příčinu

Součinové pravidlo: průnik krok za krokem

$$P(A \cap B) = P(B) \times P(A \mid B)$$

Polovina studentů jsou ženy, z nich 40 % uvádí zvýšený stres: 0,50 × 0,40 = **0,20**

Dvě kartičky **bez vracení**, obě podstatná jména: 40/100 × 39/99 ≈ **0,158**

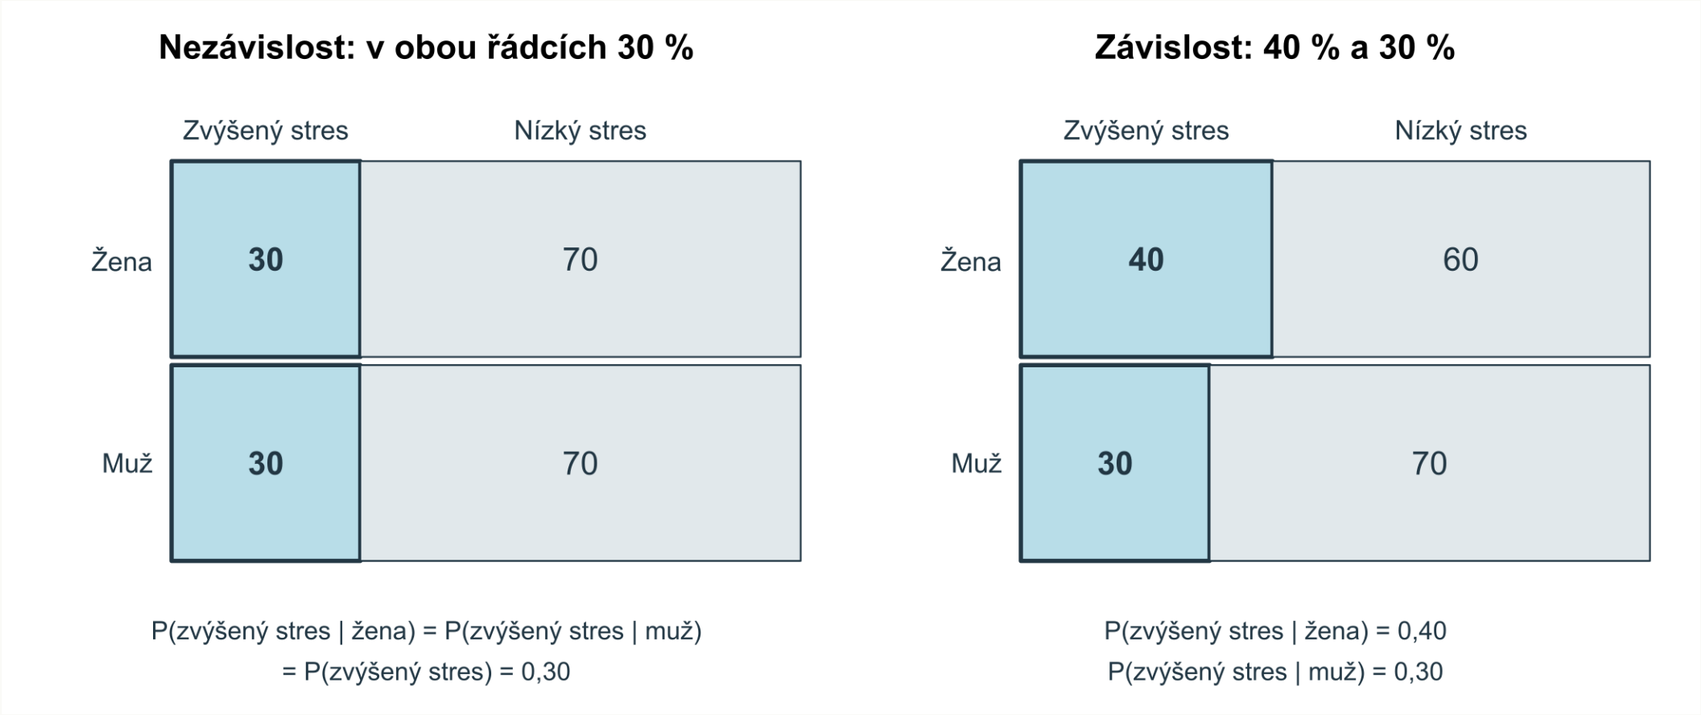
S vracením: 0,40 × 0,40 = 0,16

Nezávislé jevy: jeden nemění pravděpodobnost druhého

$$P(A \cap B) = P(A) \times P(B)$$

Druhý soubor: zvýšený stres u 30 % žen i 30 % mužů; 0,15 = 0,50 × 0,30

Původní soubor: 0,20 ≠ 0,50 × 0,35 = 0,175, jevy jsou závislé



Vlevo druhý modelový soubor (nezávislost), vpravo původní soubor (závislost)

Co nezávislost neznamená

Nezávislé ≠ vzájemně výlučné. Výlučné jevy s kladnou pravděpodobností jsou vždy závislé

Závislost ≠ příčina. Rozdíl podílů neříká, proč vznikl

Tabulka ≠ populace. Jiný výběr by dal trochu jiné podíly

Nezávislost je předpoklad, který je třeba zdůvodnit: sourozenci, spolužáci, opakovaná měření

Obrácení podmínky: Bayesova věta

Screening: co víme a na co se ptáme

Skutečný stav	Pozitivní výsledek	Negativní výsledek
Porucha přítomna	správně pozitivní	falešně negativní
Porucha nepřítomna	falešně pozitivní	správně negativní

Senzitivita *P*(pozitivní | porucha) = 0,95;
specificita *P*(negativní | bez poruchy) = 0,90

Psycholožka se ptá obráceně: *P*(porucha | pozitivní) = ?

Chybí ještě **prevalence:** v poradně má poruchu 10 % příchozích

Modelové hodnoty; nepopisují skutečný dotazník

Přirozené četnosti: tisíc studentů ve stromu

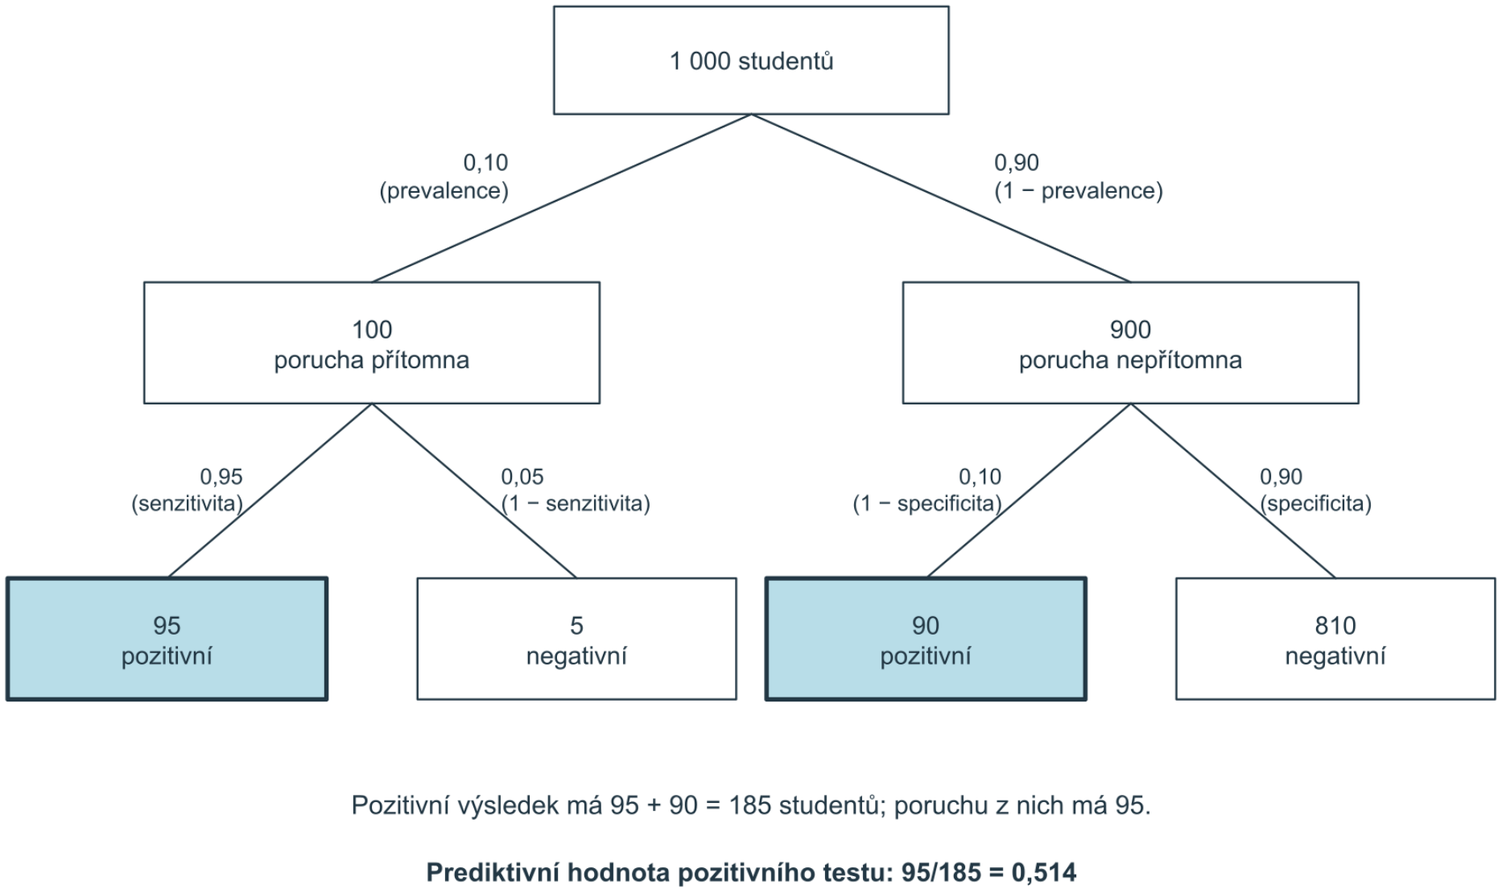
1 000 studentů: 100 s poruchou, 900 bez

Pozitivní: 95 správně + 90 falešně = 185

Prediktivní hodnota pozitivního testu: 95/185 ≈ **0,514**

Negativního testu: 810/815 ≈ 0,994

Senzitivita se čte po řádcích, otázka psycholožky po sloupcích



Pozitivní výsledek má 95 + 90 = 185 studentů; poruchu z nich má 95.

Prediktivní hodnota pozitivního testu: 95/185 = 0,514

Úplná pravděpodobnost a Bayesova věta

$$P(B) = P(A) \times P(B \mid A) + P(A') \times P(B \mid A')$$

P(pozitivní) = 0,10 × 0,95 + 0,90 × 0,10 = 0,095 + 0,090 = **0,185**

$$P(A \mid B) = \frac{P(A) \times P(B \mid A)}{P(A) \times P(B \mid A) + P(A') \times P(B \mid A')}$$

P(porucha | pozitivní) = 0,095 / 0,185 ≈ **0,514**

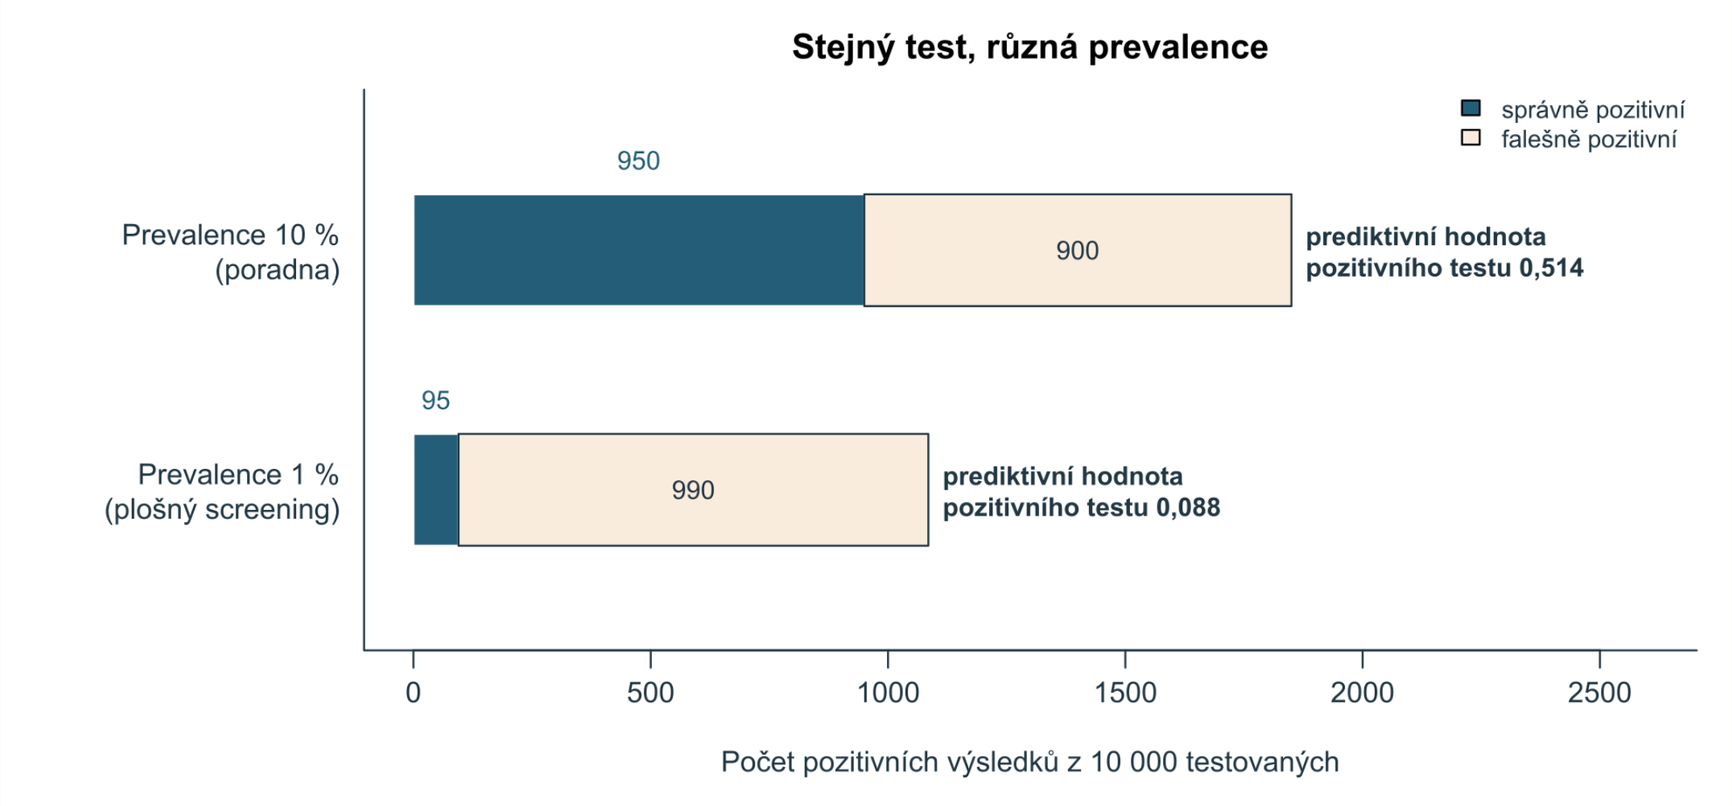
Čitatel: jedna cesta stromem; jmenovatel: všechny cesty k pozitivnímu výsledku

Stejný dotazník, jiná prevalence

Prevalence 10 %: 950/(950 + 900) ≈ **0,514**; prevalence 1 %: 95/(95 + 990) ≈ **0,088**

Prediktivní hodnota pozitivního testu není vlastností samotného testu

Zanedbání základních četností; **apriorní** 0,10 → **aposteriorní** 0,514



Předpoklad: senzitivita 0,95 a specificita 0,90 v obou skupinách

Rozdělení pravděpodobnosti a binomický model

Náhodná proměnná přiřazuje výsledkům čísla

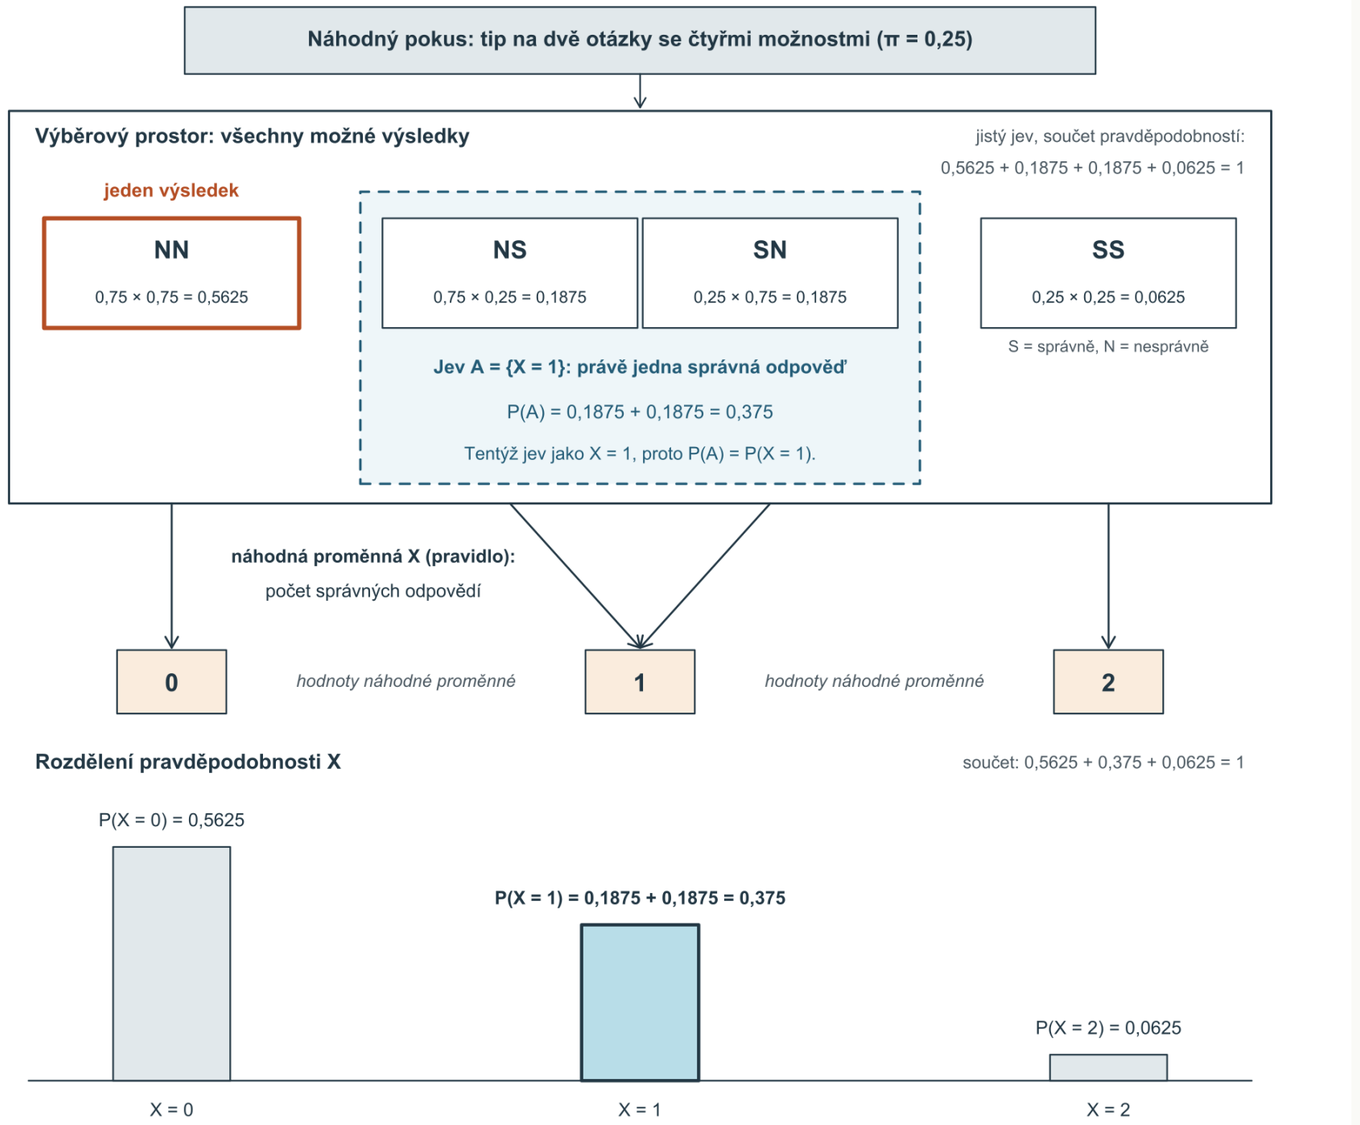
Náhodná proměnná *X*: pravidlo, které každému výsledku přiřadí číslo

X = počet správných tipů;
k = konkrétní hodnota

Hodnota *X* = 1 je jev:
výsledky NS a SN

Rozdělení pravděpodobnosti:
P(*X* = *k*) pro všechny hodnoty, součet 1

Není to sloupec dat
a nevyžaduje opakování

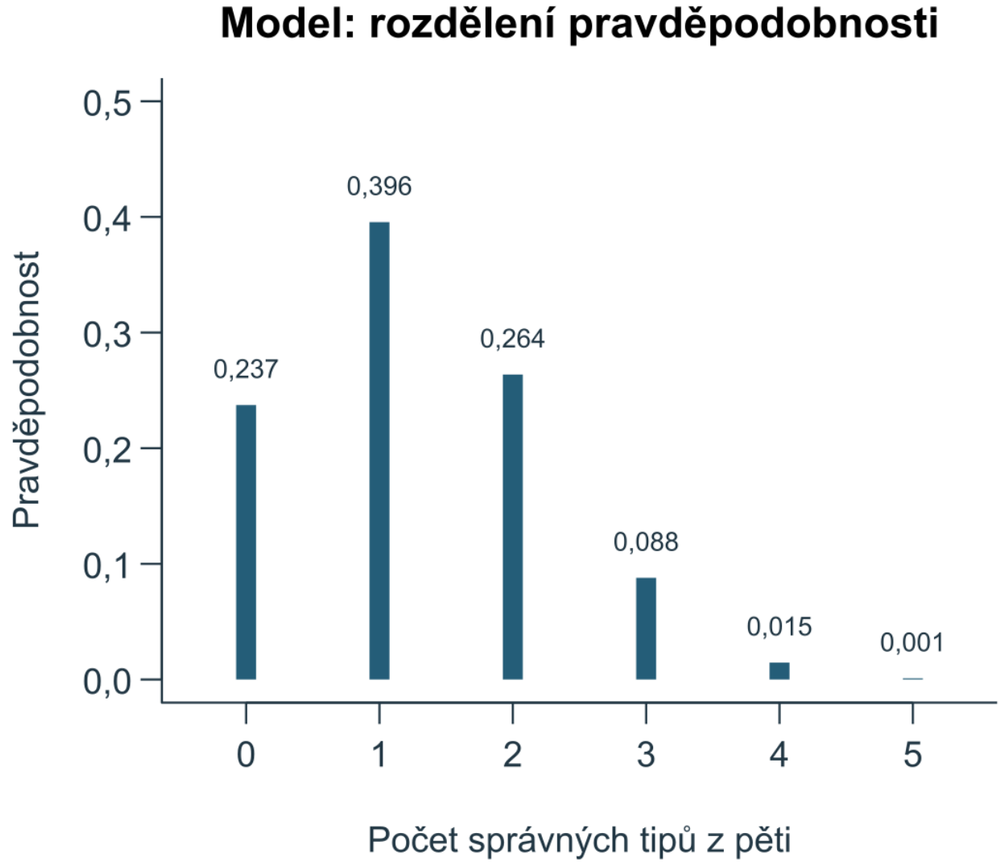


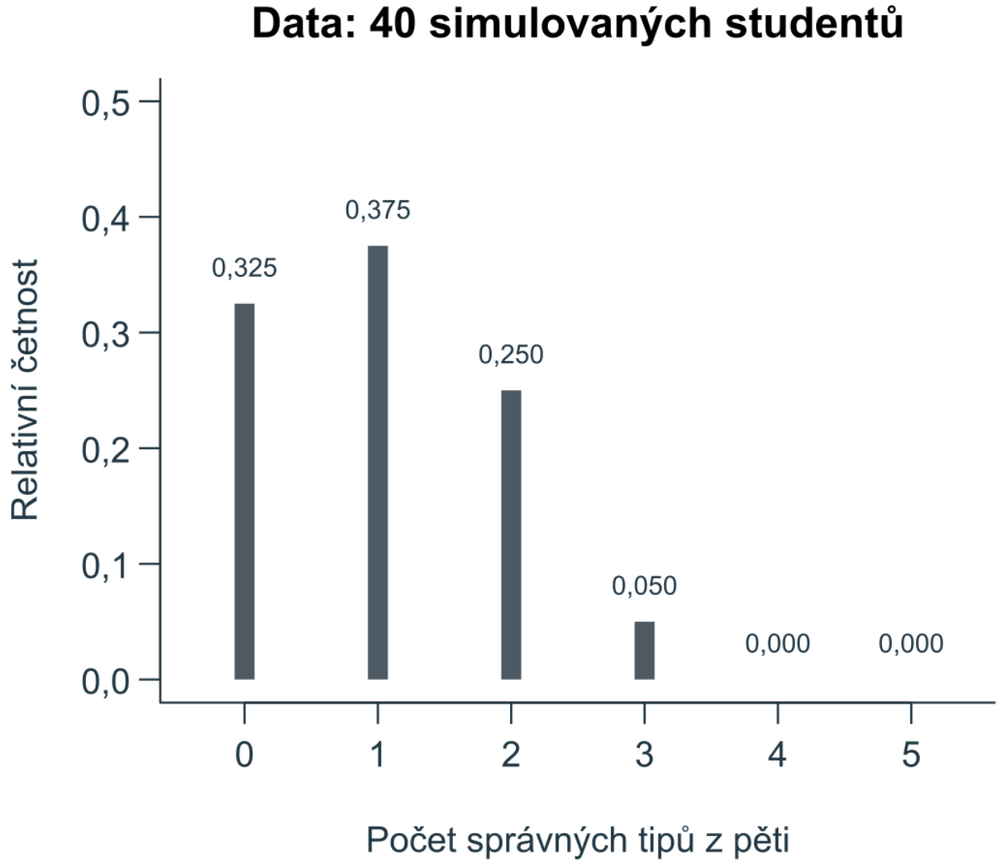
Rozdělení je model, data se od něj liší

Test s pěti otázkami a tipováním: model a 40 simulovaných studentů

Střední hodnota μ = 1,25 (dlouhodobý průměr modelu); v datech *m* = 1,025

Diskrétní proměnná: pravděpodobnost hodnoty; spojitá: hustota, plocha intervalu





Kdy použít binomický model

1. **Počet pokusů *n* je předem daný**

2. **Každý pokus má dva výsledky:** úspěch, nebo neúspěch

3. **Pravděpodobnost úspěchu π je ve všech pokusech stejná**

4. **Pokusy jsou nezávislé**

X = počet úspěchů v *n* pokusech; „úspěch“ je jen výsledek, který počítáme

Porušení: částečná znalost, učení či únava, navazující otázky, výběr bez vracení

Kombinační číslo: kolika způsoby lze vybrat

$$\binom{n}{k} = \frac{n!}{k! \times (n - k)!}$$

Dvě správné otázky z pěti:
(5 × 4) / 2 = **10**

Faktoriál *n*! =
n × (*n* − 1) × … × 1;
5! = 120, 0! = 1

Excel:
KOMBINACE(5;2) = 10;
FAKTORIÁL(5) = 120

Deset způsobů, jak mít právě 2 z 5 tipů správně



S = správně, N = nesprávně; pořadí kroužků odpovídá otázkám 1 až 5.

Binomický vzorec

$$P(X = k) = \binom{n}{k} \times \pi^k \times (1 - \pi)^{n-k}$$

$P(X = 2) = 10 \times 0{,}25^2 \times 0{,}75^3 = 10 \times 0{,}0264 \approx \mathbf{0{,}264}$

k	0	1	2	3	4	5
P(X = k)	0,237	0,396	0,264	0,088	0,015	0,001

32 možných pětic, ale nejsou stejně pravděpodobné

Test s pěti otázkami a čtyřmi možnostmi, tipování: n = 5, π = 0,25

Tvar, střední hodnota a směrodatná odchylka

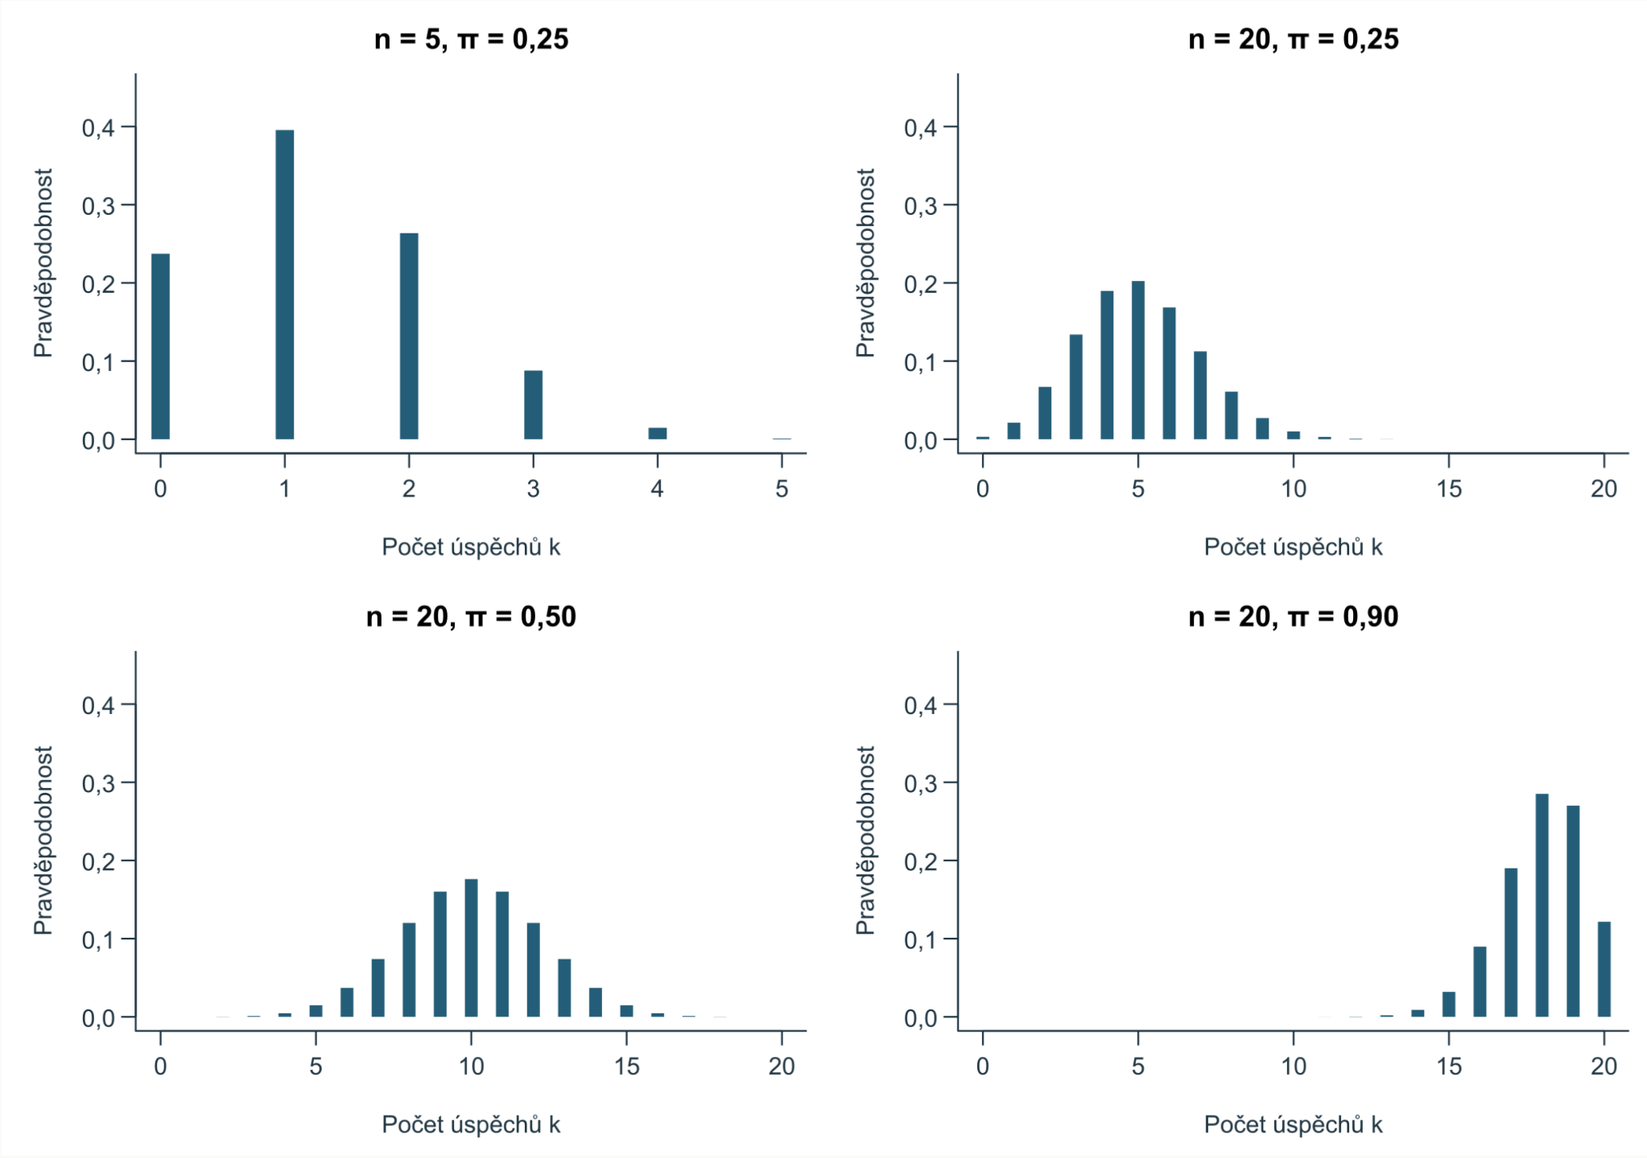
$$\mu = n \times \pi$$

$$\sigma = \sqrt{n \times \pi \times (1 - \pi)}$$

n = 5, π = 0,25: μ = 1,25; σ ≈ 0,97

π = 0,5 souměrné;
malé π doprava, velké doleva zešikmené

Víc pokusů: širší a souměrnější rozdělení



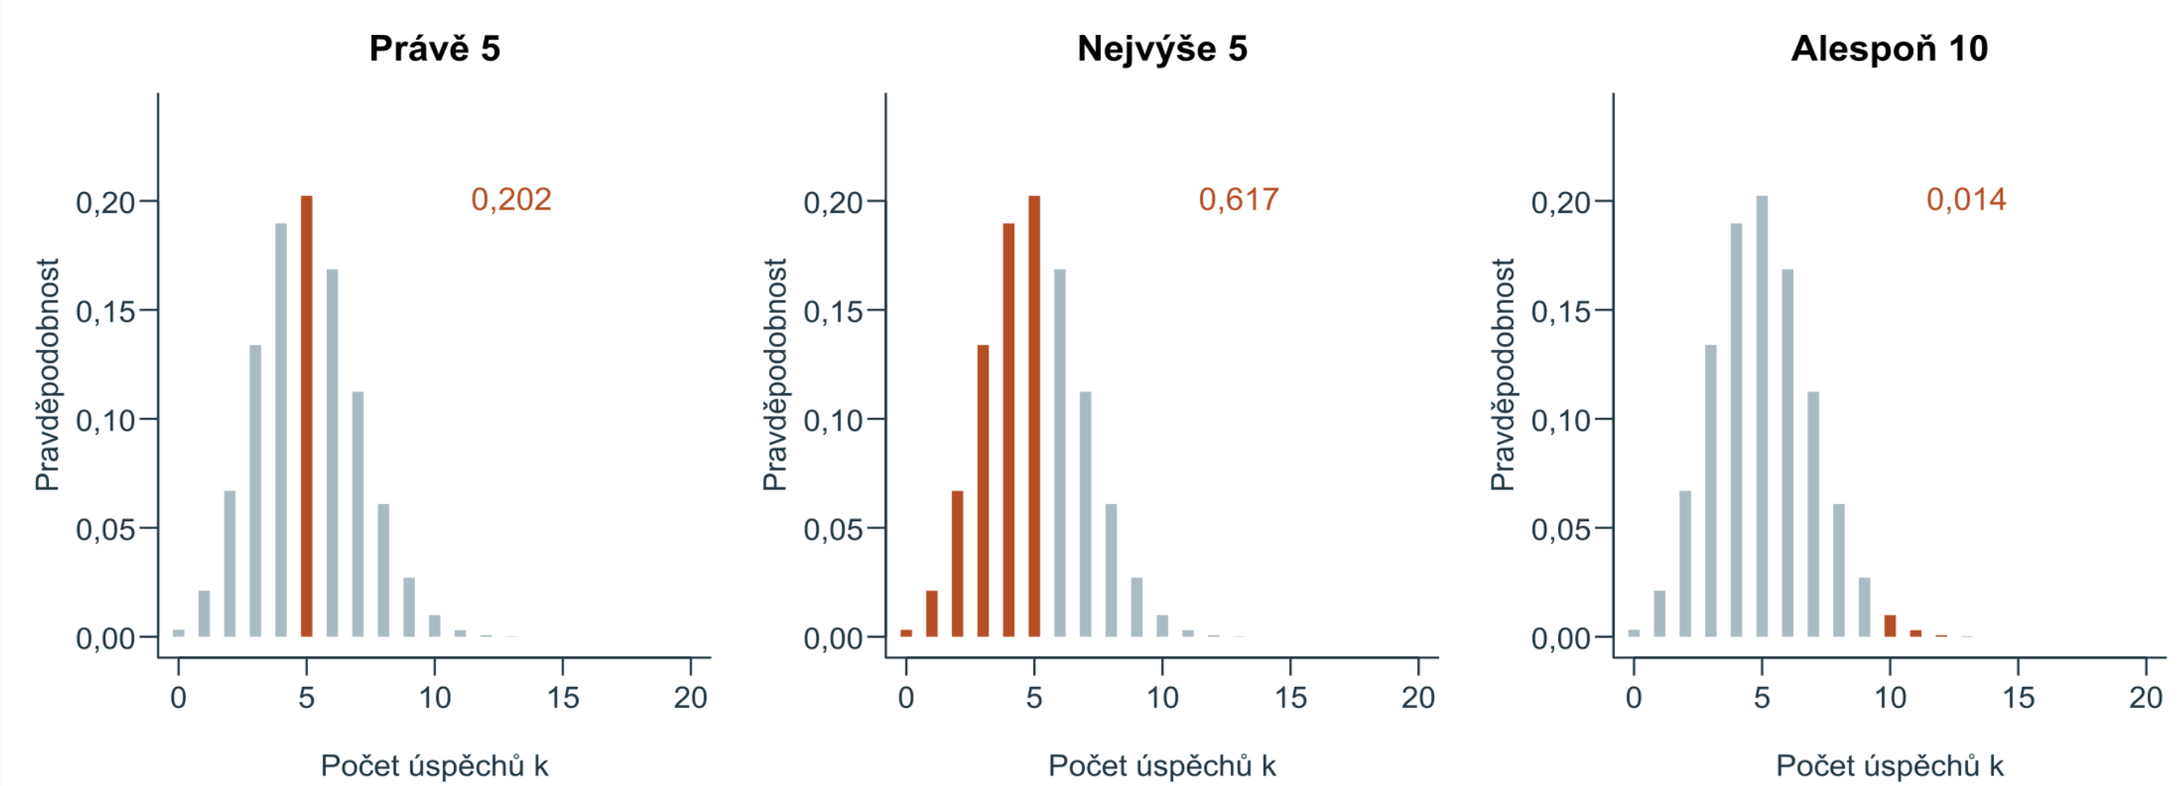
Právě, nejvýše, alespoň

20 otázek, tipování (n = 20, π = 0,25): $P(X = 5) = 0{,}202$; $P(X \leq 5) = 0{,}617$

$P(X \geq 10) = 1 - P(X \leq 9) =$ **0,014**; opačným jevem k „alespoň 10“ je „nejvýše 9“

Excel: BINOM.DIST(*k*; *n*; π; NEPRAVDA) právě, PRAVDA nejvýše

Je to P(výsledek | tipování), nikoli P(tipování | výsledek)



Normální aproximace a podíl

Normální aproximace: postup

Podmínka: $n \times \pi \geq 10$ a zároveň $n \times (1 - \pi) \geq 10$

Normální model se stejnými $\mu = n \times \pi$ a $\sigma = \sqrt{[n \times \pi \times (1 - \pi)]}$

$$z = \frac{\text{hranice} - \mu}{\sigma}$$

200 pokusů, $\pi = 0{,}6$: $\mu = 120$, $\sigma = \sqrt{48} \approx 6{,}928$

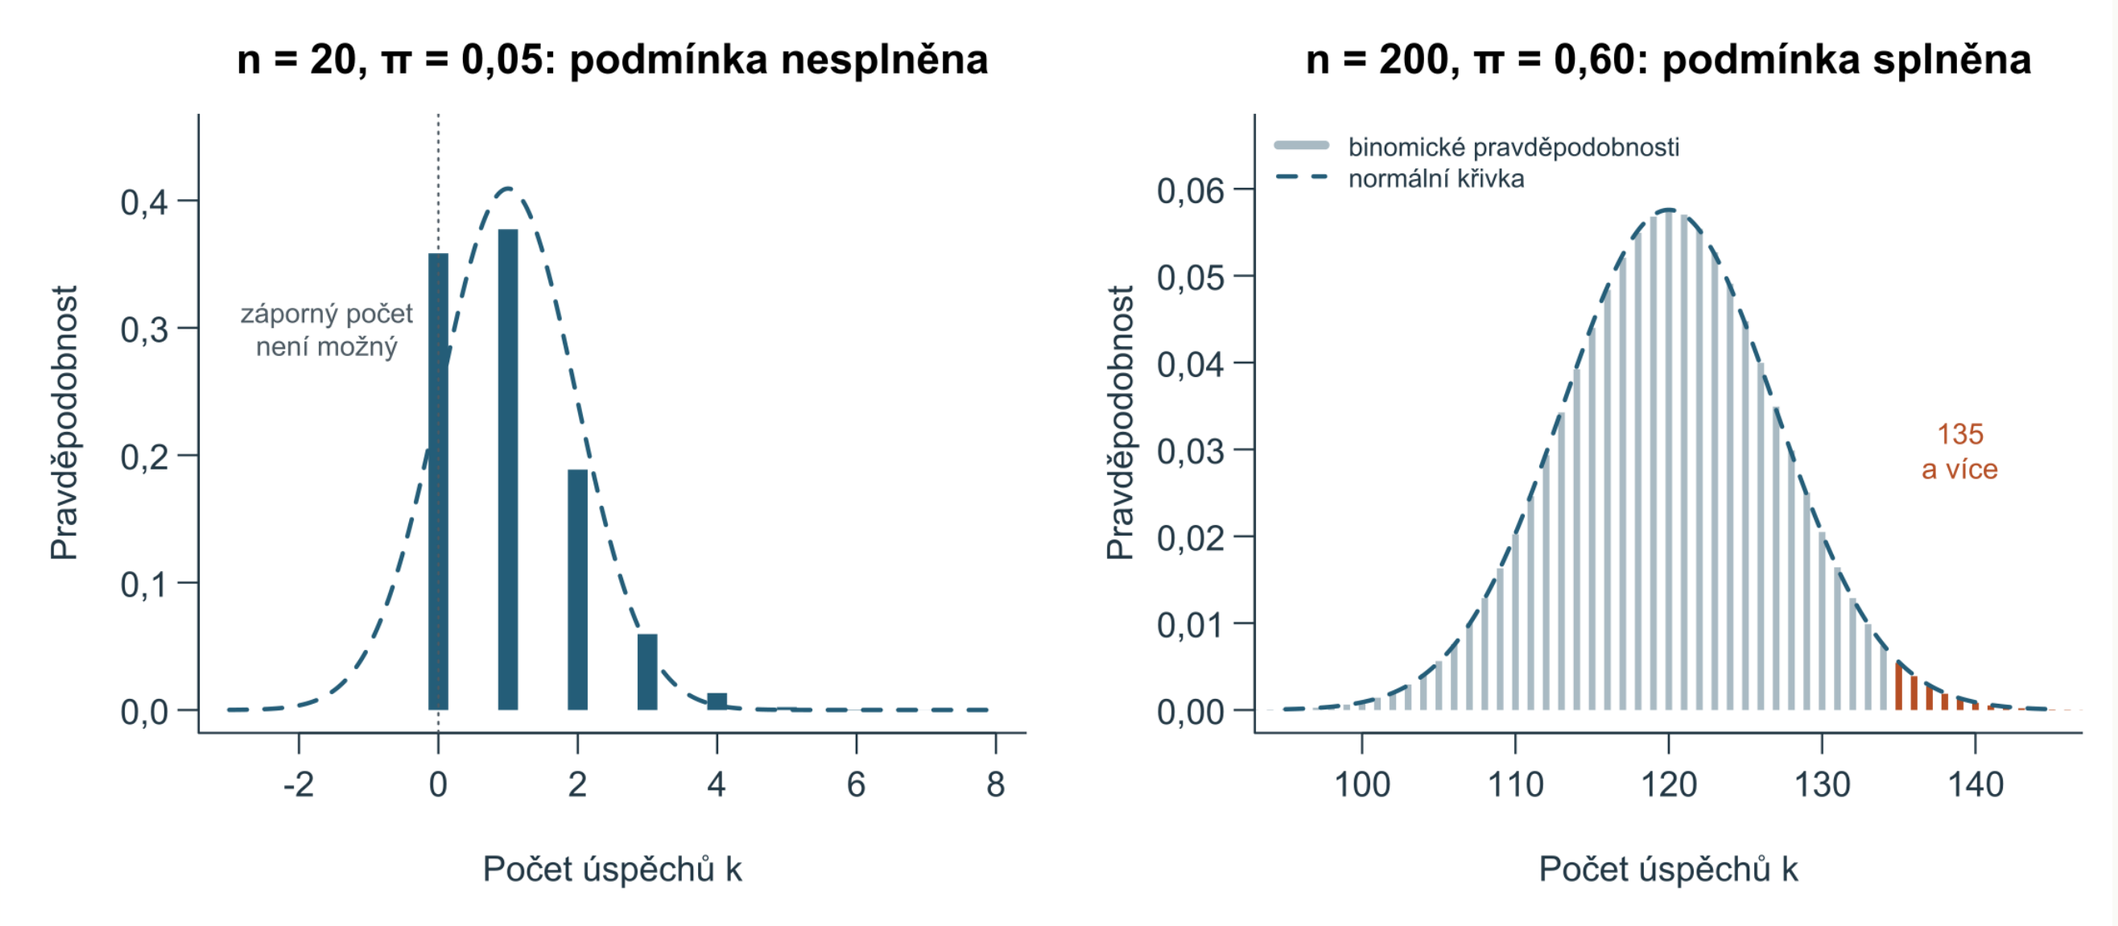
$z = (135 - 120) / 6{,}928 \approx 2{,}165$; =1-NORM.S.DIST(2,165;PRAVDA) ≈ **0,015**

Modelový příklad: rozpoznávací úloha s 200 nezávislými pokusy

Jak přesná aproximace je

Přesně: =1-BINOM.DIST(134;200;0,6;PRAVDA) = **0,0173**; aproximace 0,0152, od 134,5 vychází 0,0182

Nesplněná podmínka (*n* = 20, π = 0,25): přesně 0,0139, aproximace 0,0049; vlevo krajní případ π = 0,05



Od počtu k podílu: víc pokusů, menší kolísání

p = *k* / *n*: 135 / 200 = 0,675 (relativní četnost); π je pravděpodobnost v modelu

Střední hodnota podílu = π

$$\text{směrodatná odchylka podílu} = \sqrt{\frac{\pi \times (1 - \pi)}{n}}$$

π = 0,6, *n* = 200: 0,0346; *z* = (0,675 − 0,6) / 0,0346 ≈ 2,165

n = 50 → 0,069; 200 → 0,035; 800 → 0,017: **čtyřnásobek pokusů půlí kolísání**

Procvičování

Úloha 1: Co číslo znamená

a) Uveďte vlastní příklad pravděpodobnosti v klasickém, četnostním a subjektivním pojetí.

b) Manželé mají osm dcer. Lékař jim řekl, že podle „zákona průměrů“ je nyní syn téměř jistý. Co je na úvaze chybného? Za jakého předpokladu by byla pravděpodobnost syna i nyní přibližně 0,5?

Howell (2013), s. 132, úloha 5.1, a s. 135, úloha 5.35. Česká adaptace.

Úloha 2: Losování odměn za účast ve výzkumu

Účastníci výzkumu dostávají lístky do slosování o odměnu. Vy máte jeden lístek, váš kamarád dva.

a) Prodáno 1 000 lístků, jedna cena: jaká je pravděpodobnost, že vyhrajete vy, kamarád, vy nebo kamarád?

b) Lístků je jen 10, ceny dvě a vytažený lístek se nevrací: jaká je pravděpodobnost, že vyhrajete 2. cenu, víte-li, že jste nevyhráli 1. cenu? Že kamarád vyhraje 1. a vy 2. cenu? Že si vy dva rozdělíte obě ceny?

c) Které pravděpodobnosti v b) jsou společné a které podmíněné?

Howell (2013), s. 132–133, úlohy 5.2–5.5. Česká adaptace.

Úloha 3: Matka a dítě se dívají na sebe

Matka se během dne dívá na své dítě celkem 2 hodiny, dítě na matku celkem 3 hodiny. Předpokládejte, že se chovají nezávisle.

a) Jaká je pravděpodobnost, že se v náhodně zvolené chvíli dne podívají jeden na druhého současně?

b) Jak se výsledek změní, když oba spí od 20 do 7 hodin?

c) Je předpoklad nezávislosti rozumný? Co by znamenalo, kdyby se skutečně dívali na sebe častěji?

Howell (2013), s. 133, úlohy 5.8–5.9. Česká adaptace s doplněnou otázkou c).

Úloha 4: Kde je chyba?

a) „Dotazník má senzitivitu 0,90, takže 90 % lidí s pozitivním výsledkem poruchu má.“

b) „V poradně měl dotazník prediktivní hodnotu pozitivního testu 0,51; při plošném screeningu bude stejná.“

c) „Mít právě 10 správných z 20 při tipování otázek ano–ne má pravděpodobnost 0,18, takže výsledek 10 je u tipujícího neobvyklý.“

d) „Je pravděpodobnější, že Petr je tichý knihovník, než že je knihovník.“

Vlastní úlohy pro tuto výuku

Úloha 5: Kolika způsoby?

a) Účastník uvidí po jednom slově ze čtyř slovních druhů (podstatné jméno, sloveso, přídavné jméno, příslovce). Kolik je různých pořadí, má-li každé pořadí vidět jeden účastník?

b) Z časových důvodů uvidí každý účastník jen dva ze čtyř slovních druhů. Kolik je různých dvojic, nezáleží-li na pořadí?

c) Elektroencefalograf má čtyři funkční kanály a na hlavě je šest elektrod. Kolika způsoby lze vybrat čtyři elektrody k záznamu?

Howell (2013), s. 134, úlohy 5.26, 5.27 a 5.30. Česká adaptace; b) a c) změněny.

Úloha 6: Hodí se binomický model?

U každé situace rozhodněte, zda lze počet použít jako binomickou náhodnou proměnnou. Pokud ne, která podmínka je porušena?

a) Deset účastníků tipuje, který z pěti podnětů experimentátor předem určil jako správný; počítáme správné tipy v prvním pokusu.

b) Ze skupiny 12 studentů, z nichž 3 jsou leváci, vybereme bez vracení 5; počítáme leváky.

c) Počítáme, kolik pokusů potřebuje účastník do prvního správného rozpoznání podnětu.

d) Student odpovídá na 15 otázek, z nichž některé umí a jiné tipuje; počítáme správné odpovědi.

Situace a) podle Howella (2013), s. 133, úloha 5.21; ostatní vlastní

Práce v Excelu: doprovodný sešit

kapitola_05_pravdepodobnost_cviceni.xlsx

U1_tabulka: přípravný kurz a úspěch u zkoušky (160 studentů)

U2_screening: mamografie, přirozené četnosti a Bayesova věta

U3_tipovani: deset účastníků, pět možností, rozdělení a graf

U4_test_20: 11 správných z 20 otázek ano–ne

U5_aproximace: zkouška v autoškole, 22 z 30, a podíl

Howell (2013), s. 133–135, úlohy 5.21–5.23, 5.31, 5.33 a 5.36–5.38. Česká adaptace; U1 vlastní.