Výběrové rozdělení a testování hypotéz

Kapitola 6

Obsah přednášky

1. Výběrové rozdělení: jak kolísají výsledky výběrů
2. Směrodatná chyba a zákon velkých čísel
3. Centrální limitní věta a pravděpodobnost průměru
4. Princip testu: hypotézy, *p*-hodnota a rozhodnutí
5. Chyby rozhodnutí a statistická síla
6. Co výsledek znamená a meze testování
7. Procvičování

Výběrové rozdělení: jak kolísají výsledky výběrů

Rozdíl necelých sedmi sekund

Parkovací studie: dvě skupiny po 100 řidičích

Nikdo nečeká: průměr **32,15 s**; čeká jiné auto: **39,03 s**; rozdíl **6,88 s**

Vysvětlení 1: rozdíl vznikl jen tím, **kteří řidiči** se do pozorování dostali

Vysvětlení 2: rozdíl odráží **obecný rozdíl** mezi řidiči

Potřebujeme vědět, jak velké rozdíly vznikají **jen střídáním výběrů**

Postup: výběrové rozdělení → směrodatná chyba → test hypotézy

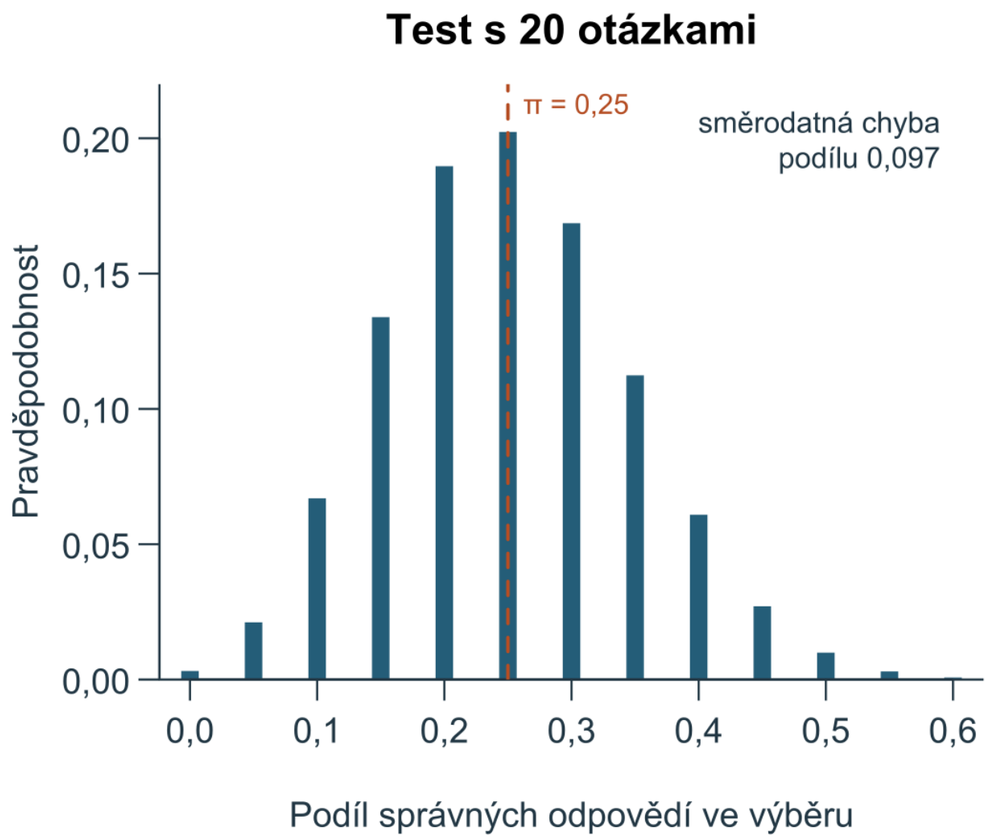
Čísla podle Howella (2013, s. 86), studie Rubacka a Juienga (1997)

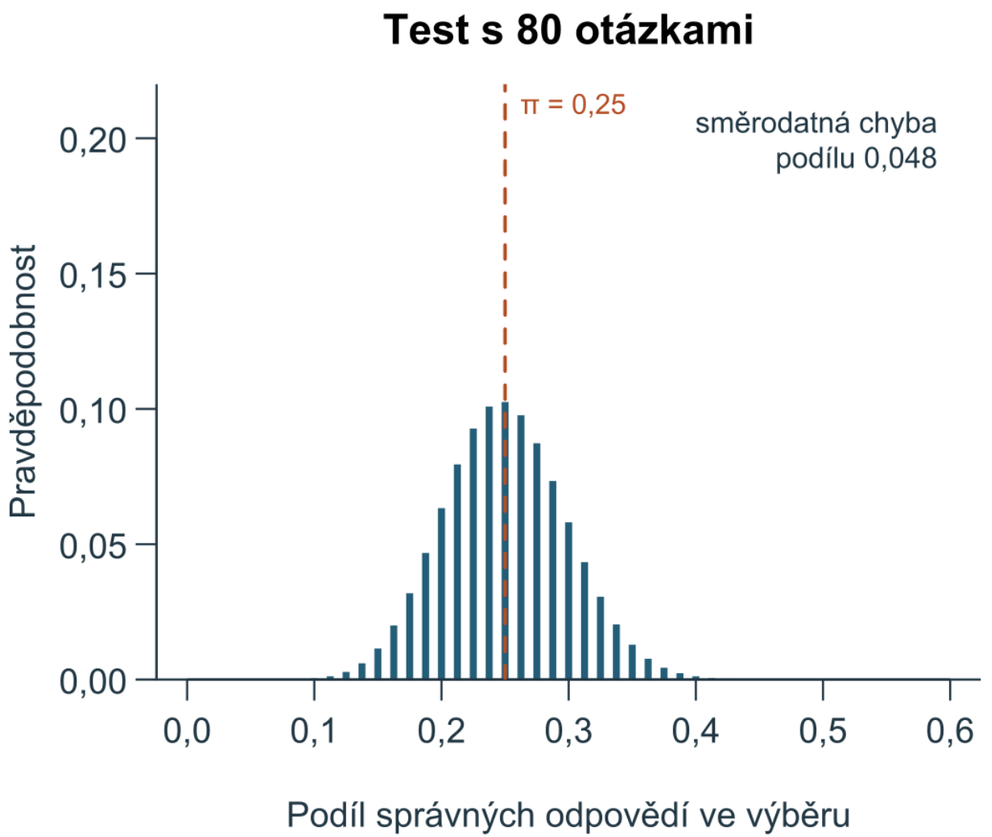
Počet správných tipů jako statistika

Tipování ve 20 otázkách se 4 možnostmi: odpovědi studenta = **výběr**, počet správných = **statistika**

Výběrové rozdělení statistiky: jakých hodnot nabývá v možných výběrech téže velikosti a jak často

Směrodatná chyba = směrodatná odchylka výběrového rozdělení; podíl: **0,097** (20 otázek), **0,048** (80 otázek)





Všech devět výběrů

Populace: doby **20, 35, 50 s**, každá s *P* = 1/3; μ = 35 s, σ = 12,25 s; vybíráme 2 řidiče s vracením

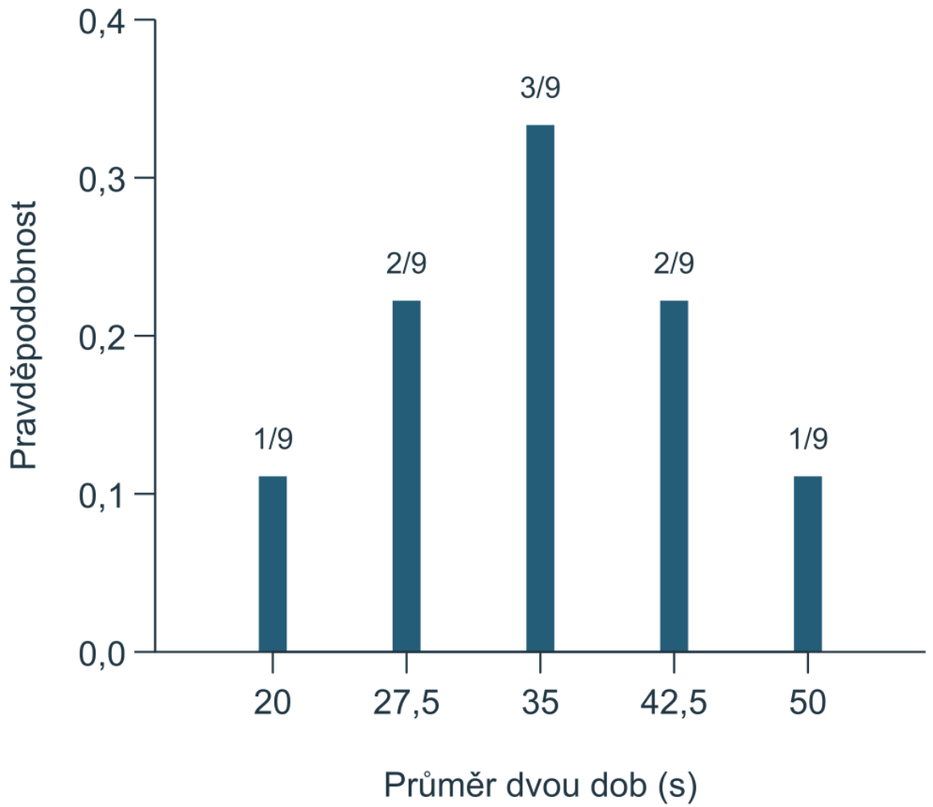
výběr → statistika → rozdělení statistiky

Střed průměrů = **35 s** = μ; směrodatná chyba **8,66 s** < 12,25 s: průměry kolísají **méně** než jednotlivci

Devět stejně pravděpodobných výběrů

první vylosovaná doba (s) \ druhá vylosovaná doba (s)	20	35	50
20	20 a 20 **průměr 20**	20 a 35 **průměr 27,5**	20 a 50 **průměr 35**
35	35 a 20 **průměr 27,5**	35 a 35 **průměr 35**	35 a 50 **průměr 42,5**
50	50 a 20 **průměr 35**	50 a 35 **průměr 42,5**	50 a 50 **průměr 50**

Výběrové rozdělení průměru



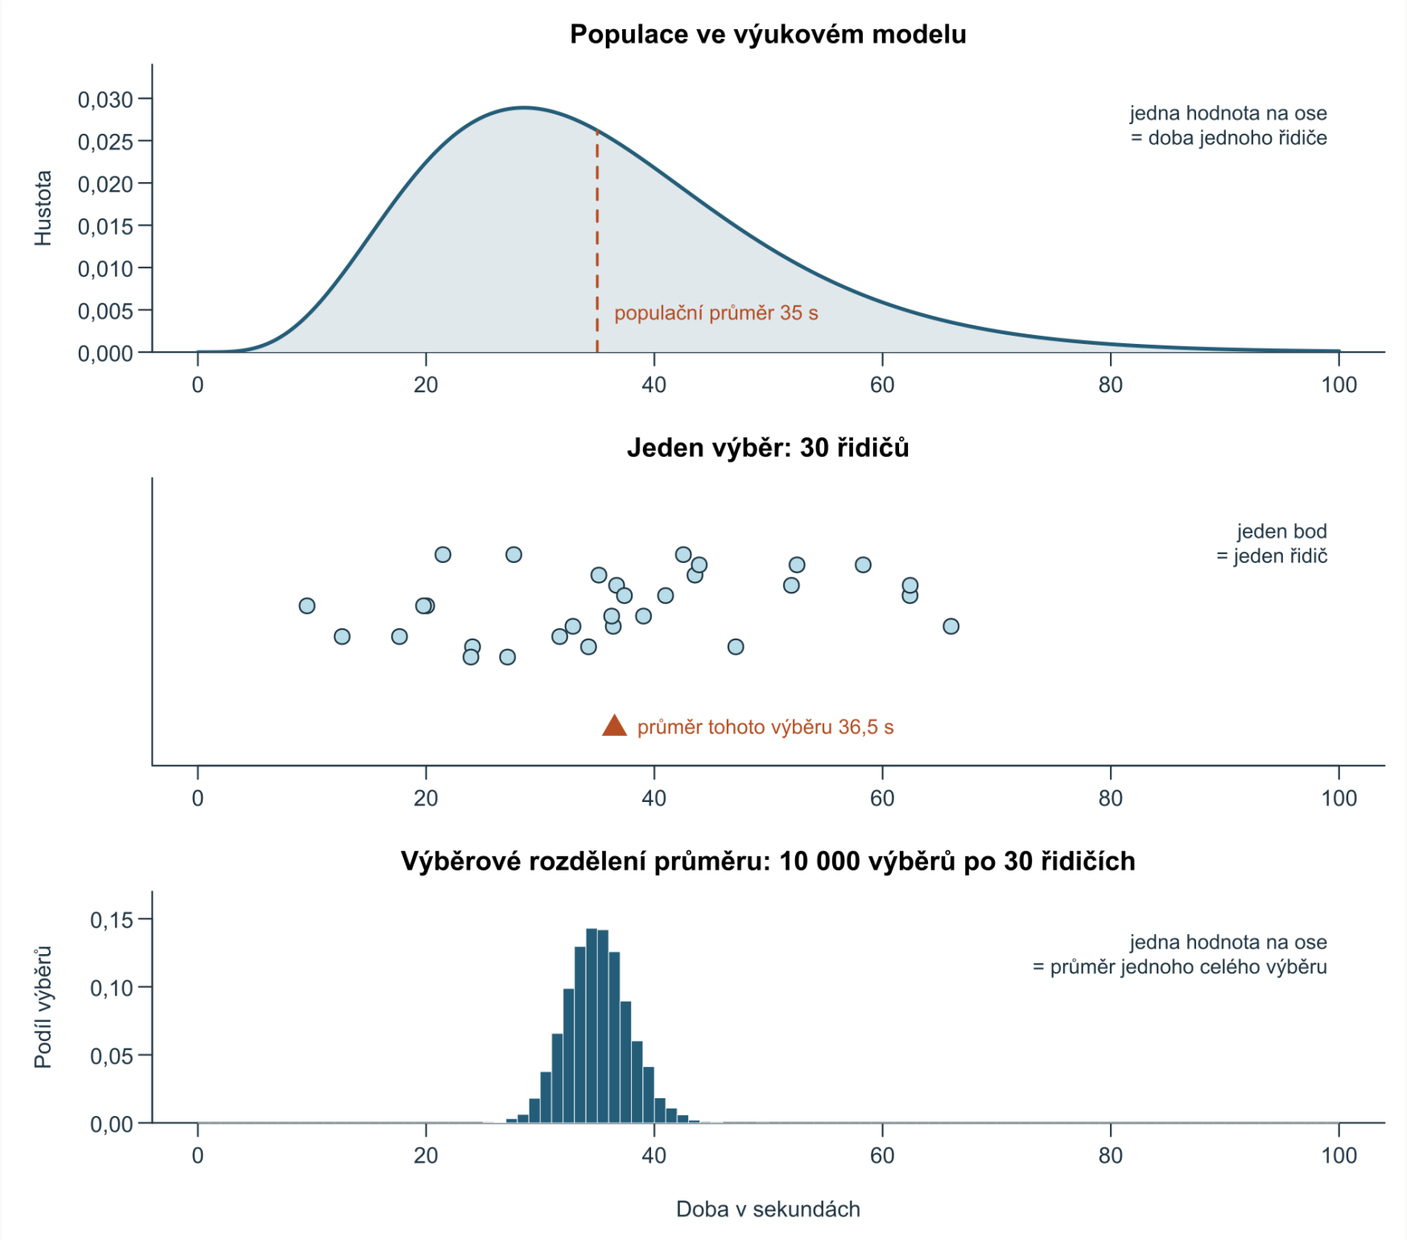
Tři rozdělení, tři významy jedné hodnoty

Populace: jedna hodnota = doba jednoho řidiče; křivka je model

Jeden výběr: jedna hodnota = jeden z 30 pozorovaných řidičů

Výběrové rozdělení průměru: jedna hodnota = průměr jednoho **celého výběru** (10 000 výběrů po 30)

Ve výzkumu máme jen **jeden výběr**; výběrové rozdělení nepozorujeme přímo



Velikost výběru a počet opakování

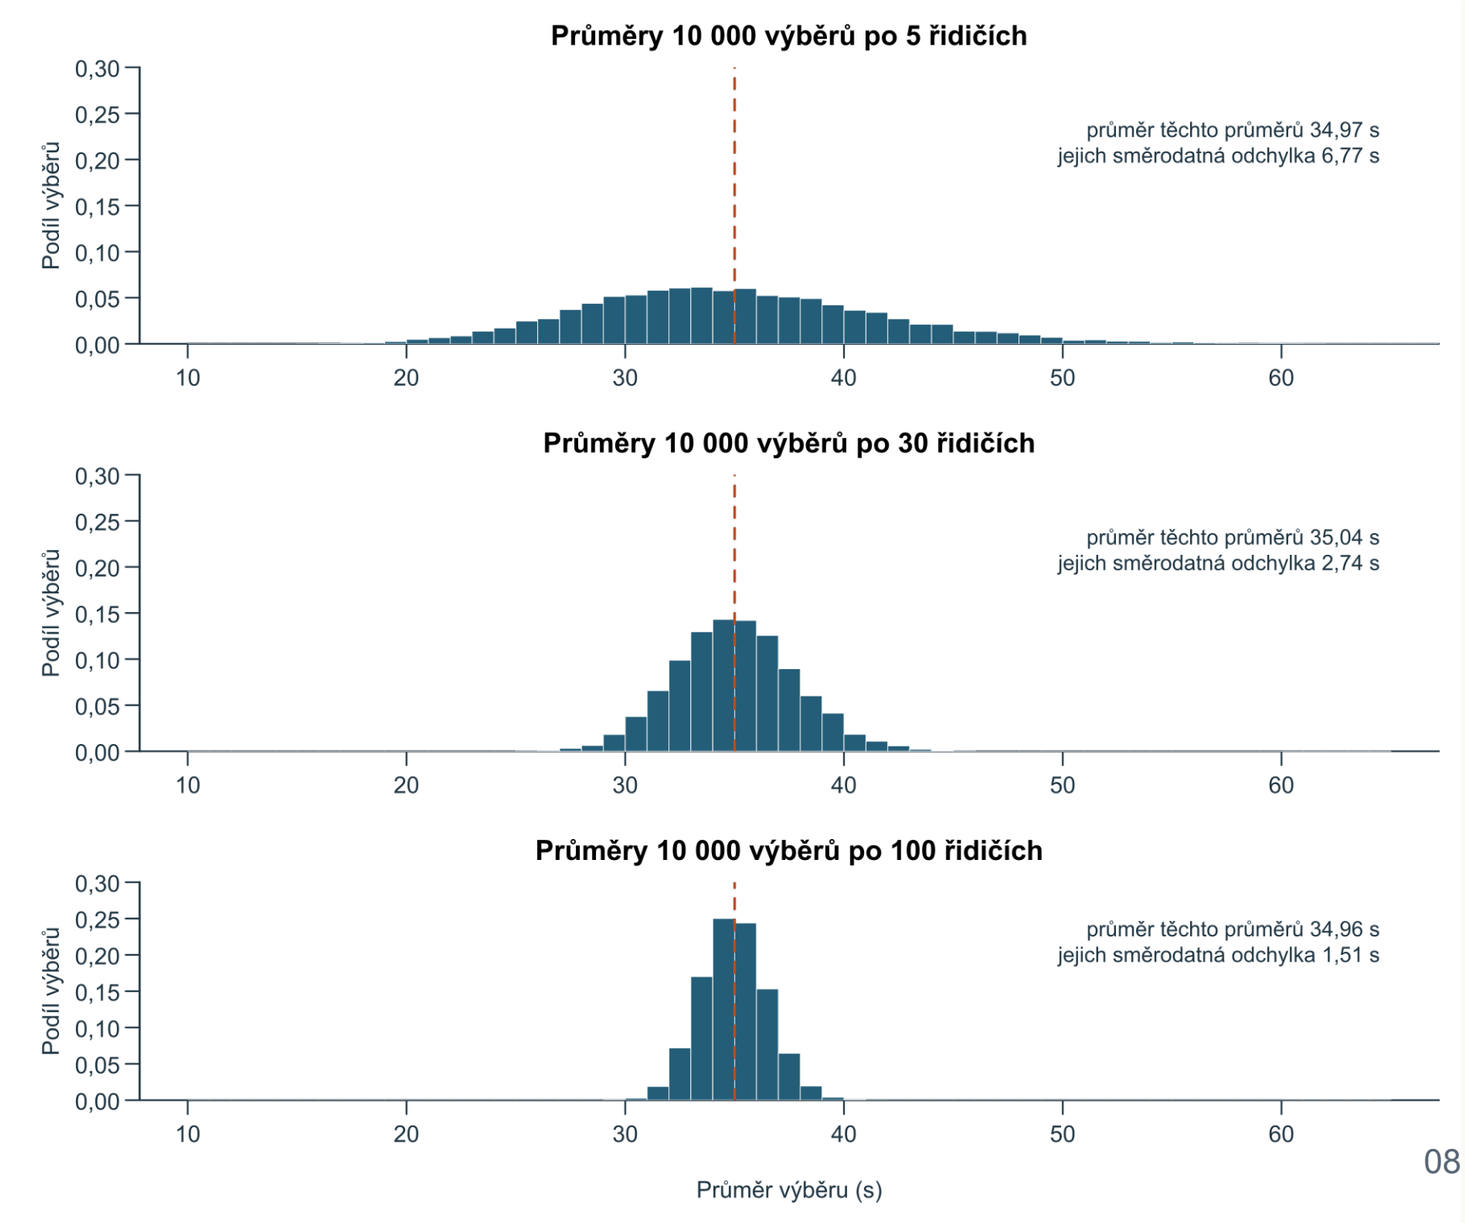
Simulace: 10 000 výběrů po **5, 30 a 100** řidičích

Střed zůstává u **35 s**

Šířka klesá: **6,77** → **2,74** → **1,51 s**

Tvar se blíží souměrnému

Velikost výběru mění výběrové rozdělení; **počet opakování** jen zpřesní jeho obraz



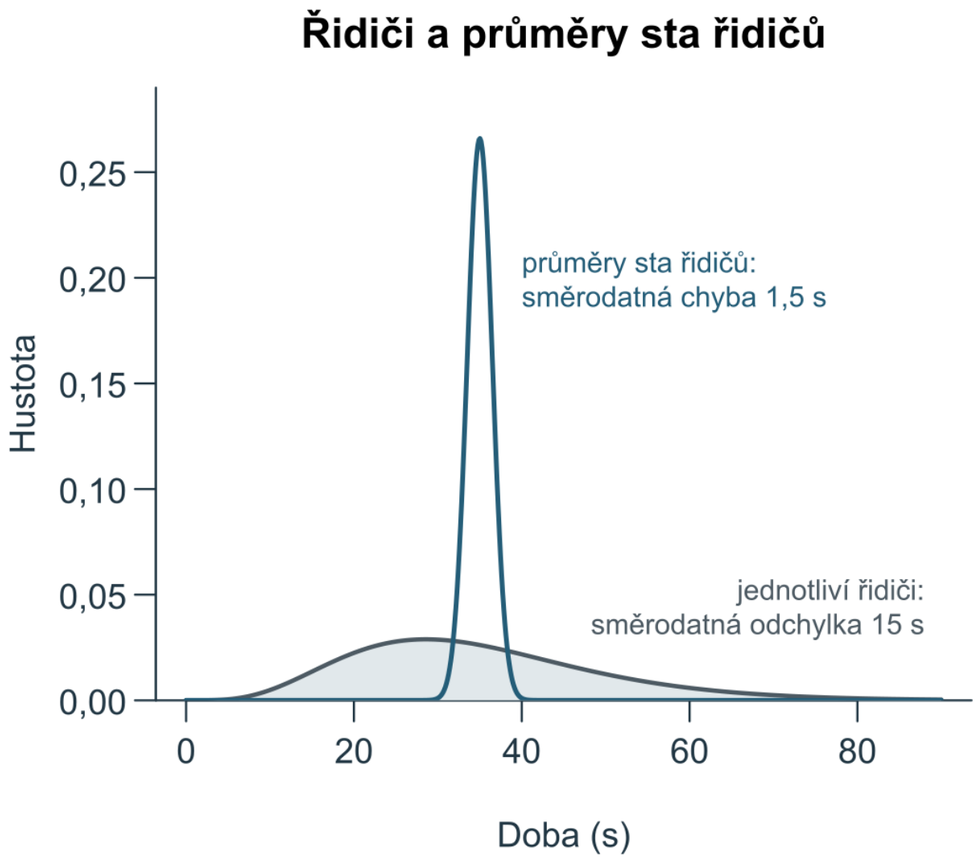
Směrodatná chyba a zákon velkých čísel

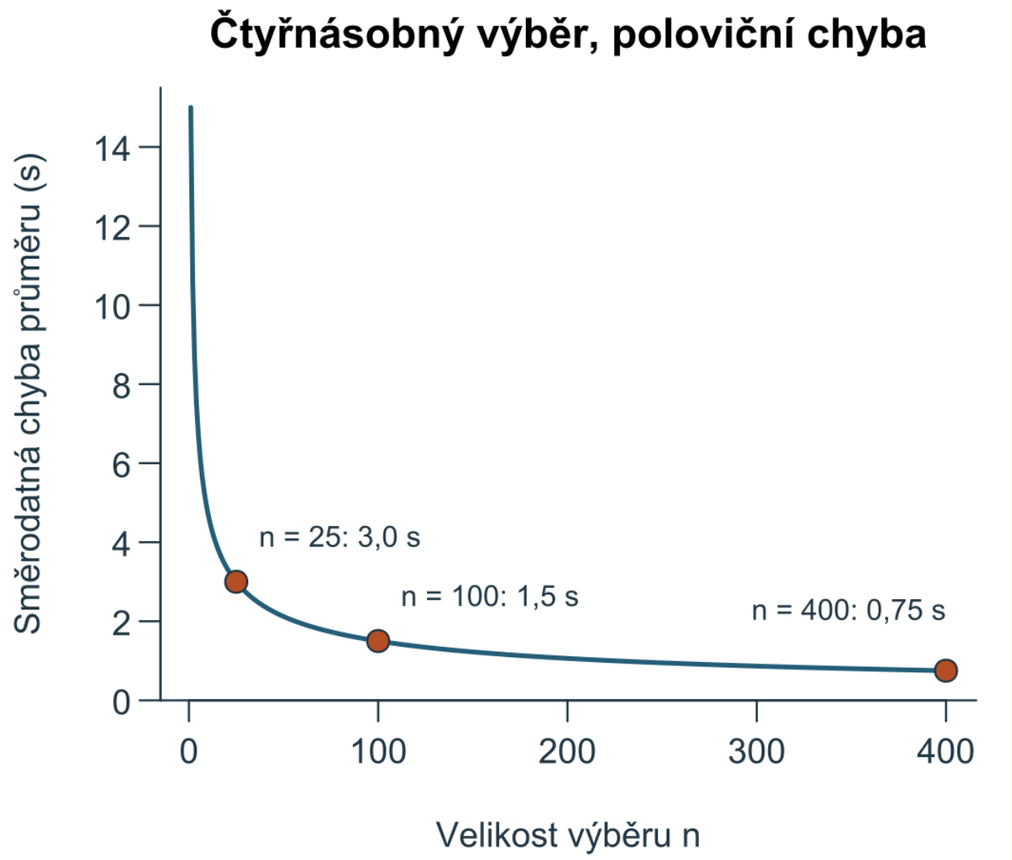
Směrodatná chyba průměru

$$\sigma_m = \frac{\sigma}{\sqrt{n}}$$

σ = 15 s: *n* = 25 → **3,0 s**; *n* = 100 → **1,5 s**; *n* = 400 → **0,75 s**:
čtyřnásobný výběr, poloviční chyba

Ve výzkumu σ neznáme → **odhad** $s_m = s / \sqrt{n}$





Zákon velkých čísel

S rostoucím výběrem se výběrový průměr **blíží průměru populace**: velké odchylky jsou stále méně pravděpodobné

Velikost výběru	Průměry v pásmu 35 ± 3 s (tedy 32–38 s)
5 řidičů	34 %
30 řidičů	73 %
100 řidičů	95 %

Dřívější odchylky se **nevyrovnávají**, jen ztrácejí váhu

Velký **zkreslený** výběr se spolehlivě blíží **nesprávné** hodnotě

Pět pojmů, které se pletou

Pojem	Na jakou otázku odpovídá	Větším výběrem se zmenší?
Směrodatná odchylka	Jak moc se liší jednotliví lidé?	Ne, jen se přesněji odhadne
Výběrová variabilita	Liší se mezi výběry?	Ano
Směrodatná chyba	Jak velké je obvykle toto kolísání?	Ano, s odmocninou z *n*
Výběrová chyba	O kolik se náš odhad liší od parametru?	Obvykle, jistě to nevíme
Systematické zkreslení	Míří postup soustavně vedle?	Ne

Centrální limitní věta a pravděpodobnost průměru

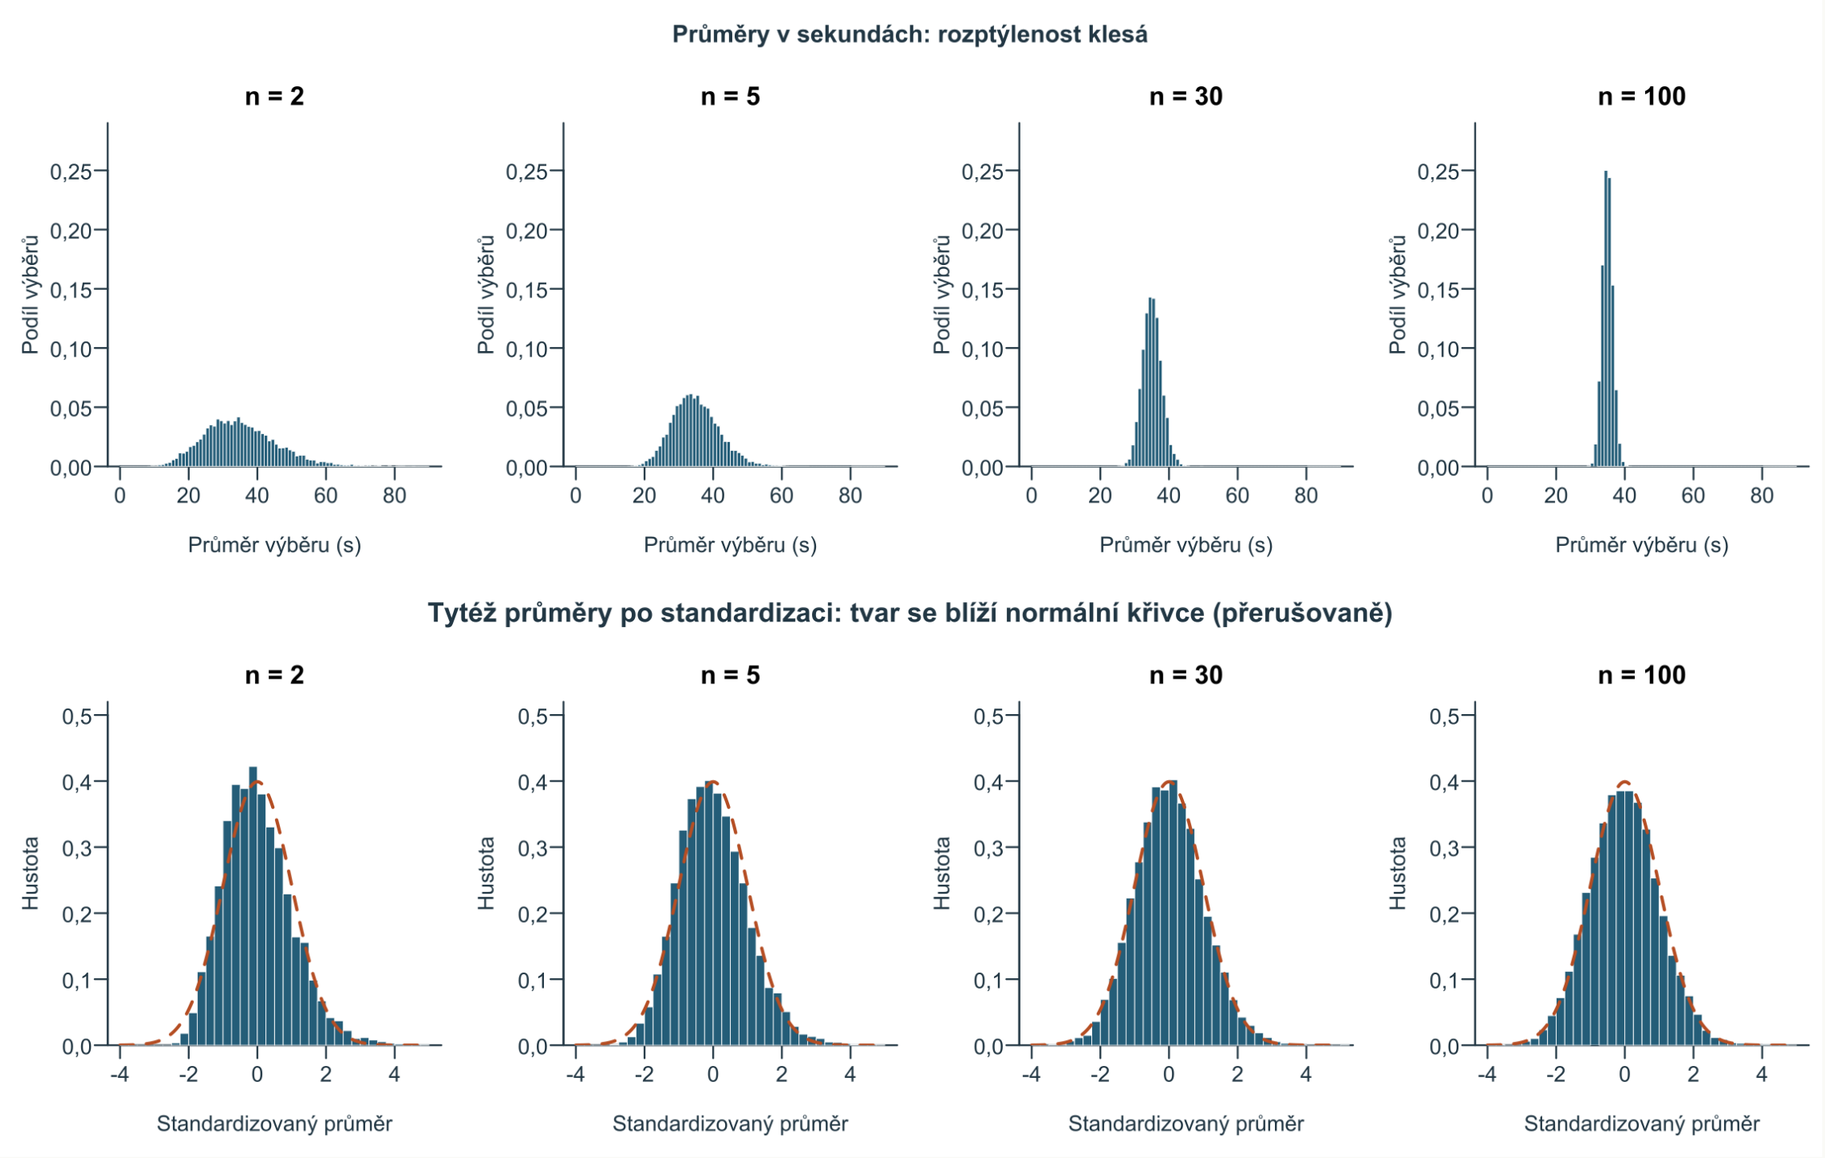
Šířka a tvar se mění současně

Standardizace průměrů:

$$z = \frac{m - \mu}{\sigma_m}$$

Horní řada:
histogramy se zužují → zákon velkých čísel

Dolní řada: tvar se blíží normální křivce → centrální limitní věta



Co centrální limitní věta říká

Průměr *n* nezávislých pozorování z téže populace má pro rostoucí *n* rozdělení blízké normálnímu, **i když populace normální není**

Normální model průměru: střední hodnota μ, směrodatná odchylka σ_m; pro 100 řidičů **35 s a 1,5 s**

Podmínky: **nezávislá** pozorování z **téže** populace; konečná variabilita; potřebné *n* závisí na tvaru populace (30 je jen orientační)

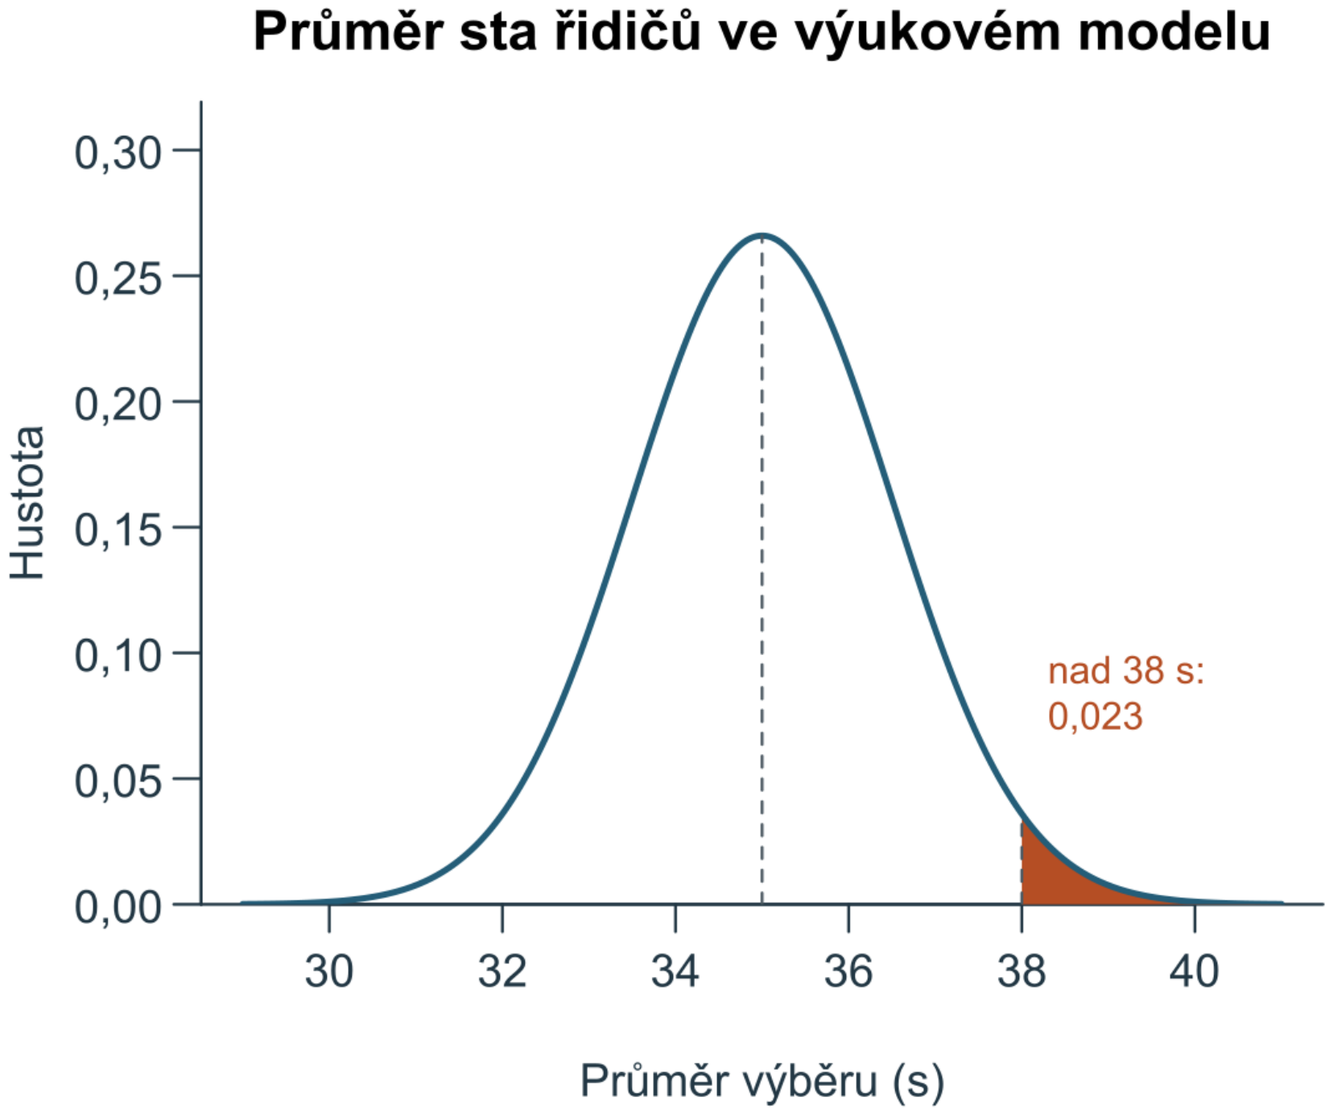
Častý omyl: větší výběr „znormální“ data; normálnímu se blíží jen rozdělení **průměrů**

Průměr sta řidičů: řešený výpočet

S jakou pravděpodobností bude průměr 100 řidičů větší než 38 s?

1. Model: μ = 35 s, σ = 15 s, n = 100
2. Směrodatná chyba:
   σ_m = 15 / √100 = **1,5 s**
3. Tvar: centrální limitní věta → normální model (35 s; 1,5 s)
4. z = (38 − 35) / 1,5 = **2**
5. Plocha: 1 − 0,9772 = **0,0228**

Pro jednoho řidiče nad 38 s: **37 %**



Rozdíl dvou průměrů jako statistika

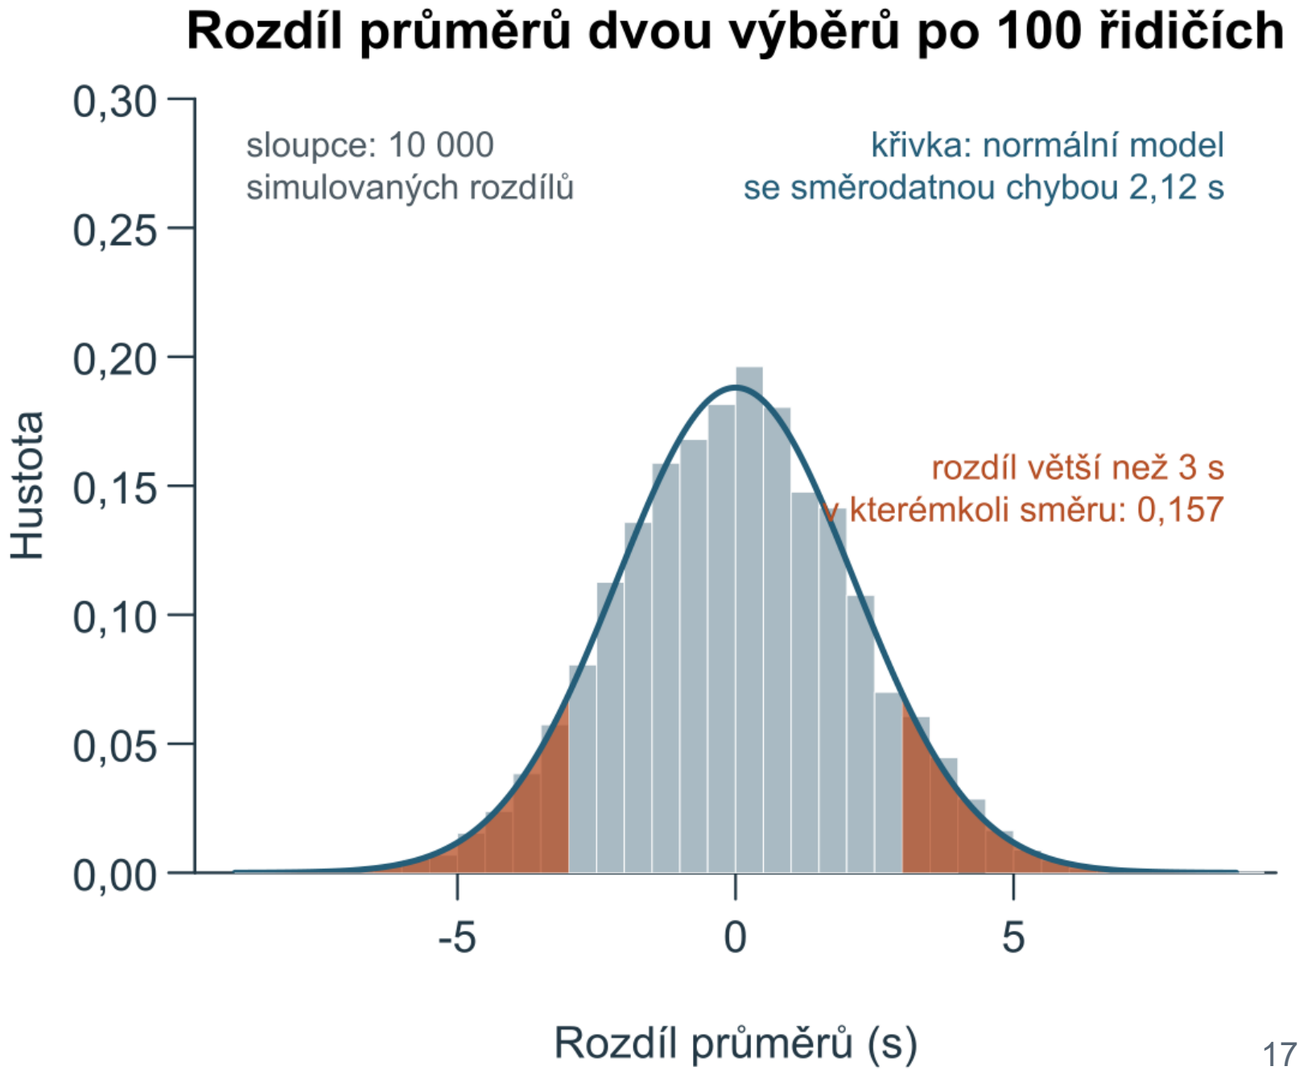
Model „žádného rozdílu“:
obě skupiny z **téže populace** (35 s; 15 s)

10 000 dvojic výběrů po 100:
průměr rozdílů 0,02 s

Směrodatná chyba rozdílu **2,12 s**
(větší než 1,5 s: kolísají oba průměry)

Rozdíl přes 3 s kterýmkoli
směrem: 2 × 0,0786 ≈ **0,157**

Třísekundový rozdíl je běžný. **A 6,88 s?**



Princip testu: hypotézy, *p*-hodnota a rozhodnutí

Výzkumná a statistická hypotéza

Výzkumná hypotéza: s čekajícím autem odjíždějí řidiči jinak rychle

Statistická hypotéza: tvrzení o parametru populace

Nulová H_0: $\mu_{čeká} - \mu_{nečeká} = 0$ · **alternativní** H_1: $\mu_{čeká} - \mu_{nečeká} \neq 0$

S H_0 porovnáváme, protože určuje **jedno výběrové rozdělení**

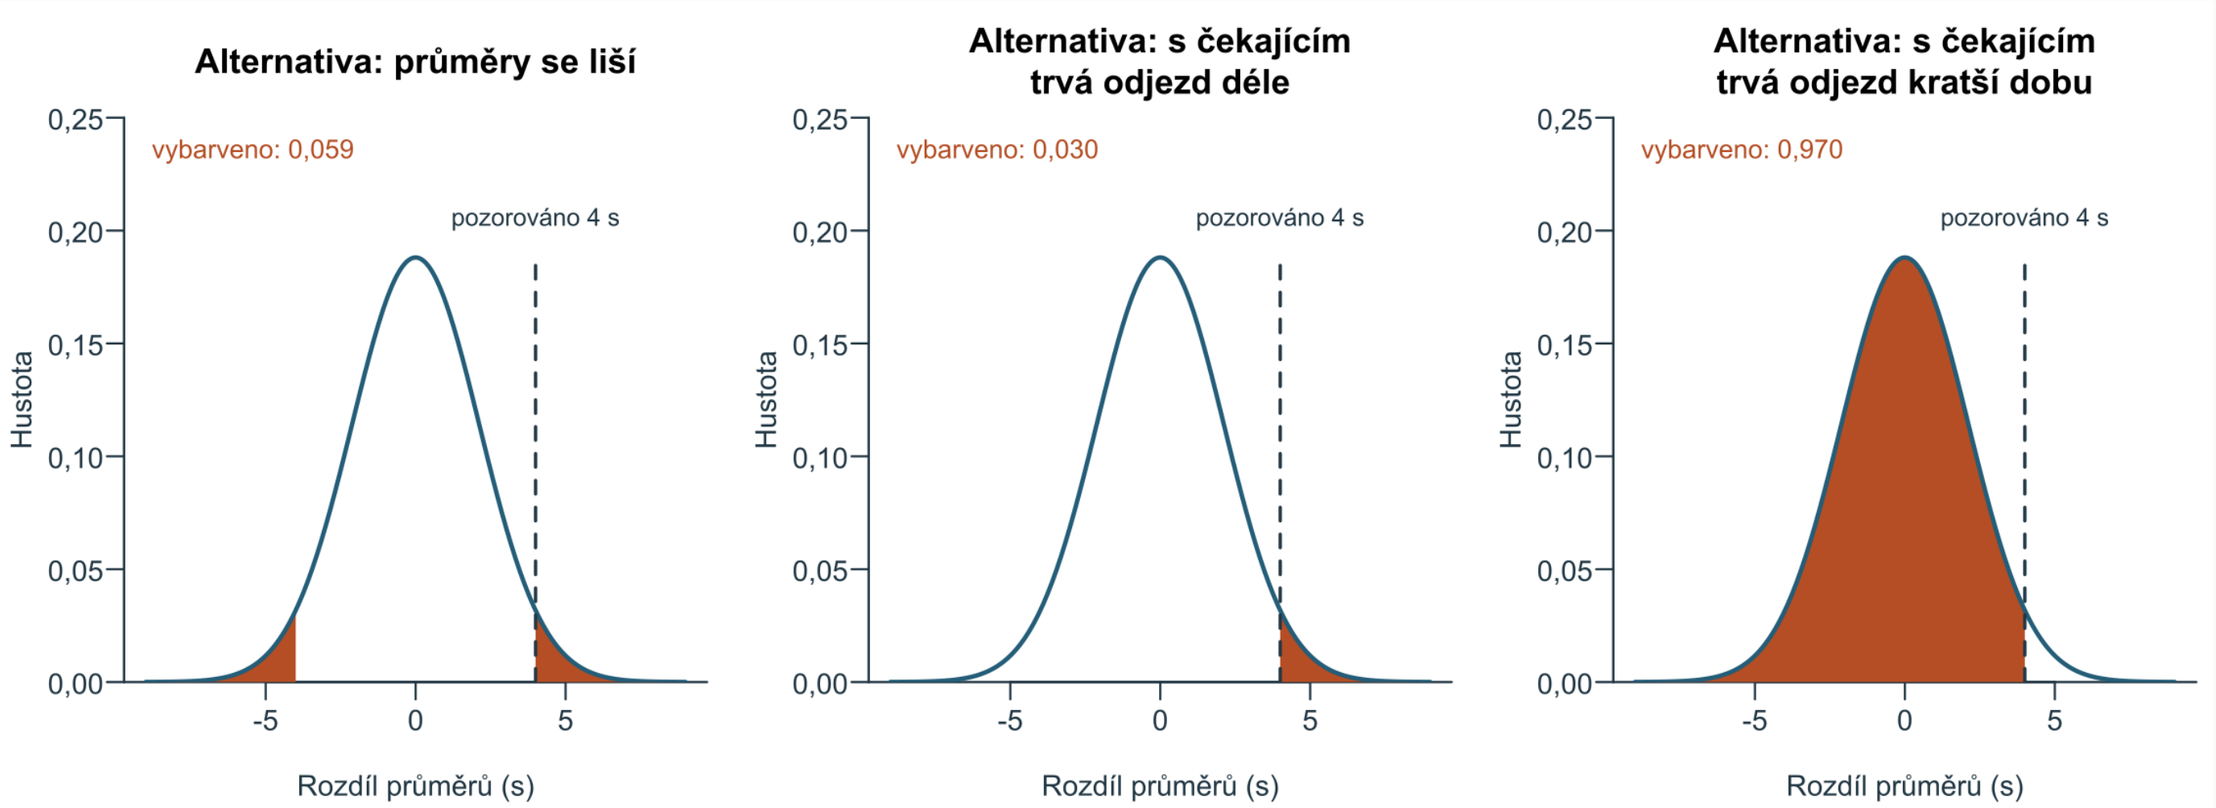
Hypotézy se týkají **populací**, ne výběrů

Směr testu a extrémnější výsledky

Které výsledky jsou **extrémnější**, určuje alternativní hypotéza

Smyšlený rozdíl 4 s: oboustranně **0,059** · „déle“ **0,030** · „kratší“ **0,970**

Směr se volí **před sběrem dat**; parkování: **oboustranný test**

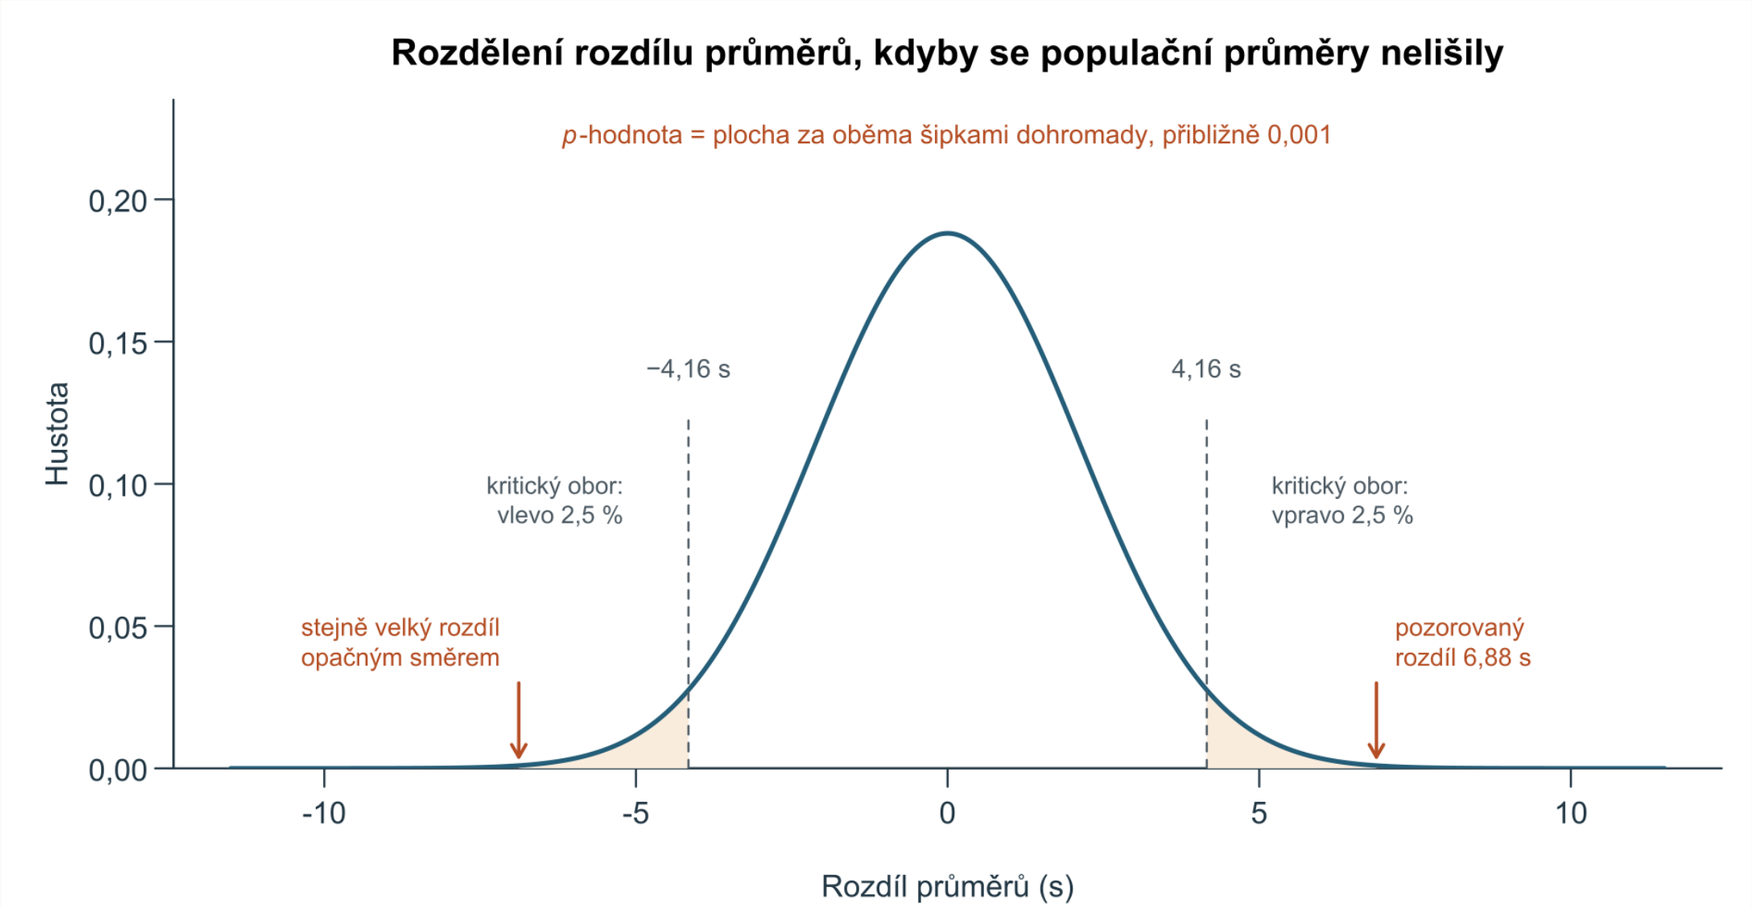


Jak neobvyklý je náš výsledek: *p*-hodnota

Testová statistika: rozdíl **6,88 s**, tj. $z = 6{,}88 / 2{,}12 \approx \mathbf{3{,}24}$

p-hodnota = pravděpodobnost výsledku **stejně extrémního nebo extrémnějšího**, kdyby platila H_0

Oboustranně: $2 \times 0{,}0006 = \mathbf{0{,}0012}$, asi jedna dvojice výběrů z osmi set



Hladina významnosti a kritický obor

Hladina významnosti α: předem zvolená hranice, obvykle 0,05 (zvyklost)

$p \leq \alpha \rightarrow$ **zamítáme** H_0, výsledek je statisticky významný · $p > \alpha \rightarrow H_0$ **nezamítáme**

Kritický obor: rozdíly pod −4,16 s a nad 4,16 s (±1,96 × 2,12)

Stanoveno předem: pravidlo	Vypočteno z dat: výsledek
hypotézy, oboustranný test, α = 0,05	*p*-hodnota 0,0012
kritický obor: pod −4,16 s, nad 4,16 s	rozdíl 6,88 s, z = 3,24

Rozhodnutí testu a věcná interpretace

1. Rozhodnutí testu

Na hladině 0,05 zamítáme H_0, že jsou populační průměry shodné; *p*-hodnota ≈ 0,001

2. Věcná interpretace

Směr: déle s čekajícím autem · **Velikost:** 6,88 s, asi pětina · **Nejistota:** chyba 2,12 s · **Uspořádání:** pozorování, ne náhodné přiřazení

p-hodnota = $P(\text{data} \mid H_0)$, **ne** $P(H_0 \mid \text{data})$

Chyby rozhodnutí a statistická síla

Chyba I. a II. druhu

	H_0 platí	H_0 neplatí
Zamítáme H_0	chyba I. druhu: α	správně: síla 1 − β
Nezamítáme H_0	správně: 1 − α	chyba II. druhu: β

α = P(zamítnutí | H_0 platí)

β = P(nezamítnutí | H_0 neplatí)

Obdoba screeningu: falešně pozitivní a falešně negativní výsledek

α **není** podíl chybných mezi všemi zamítnutími

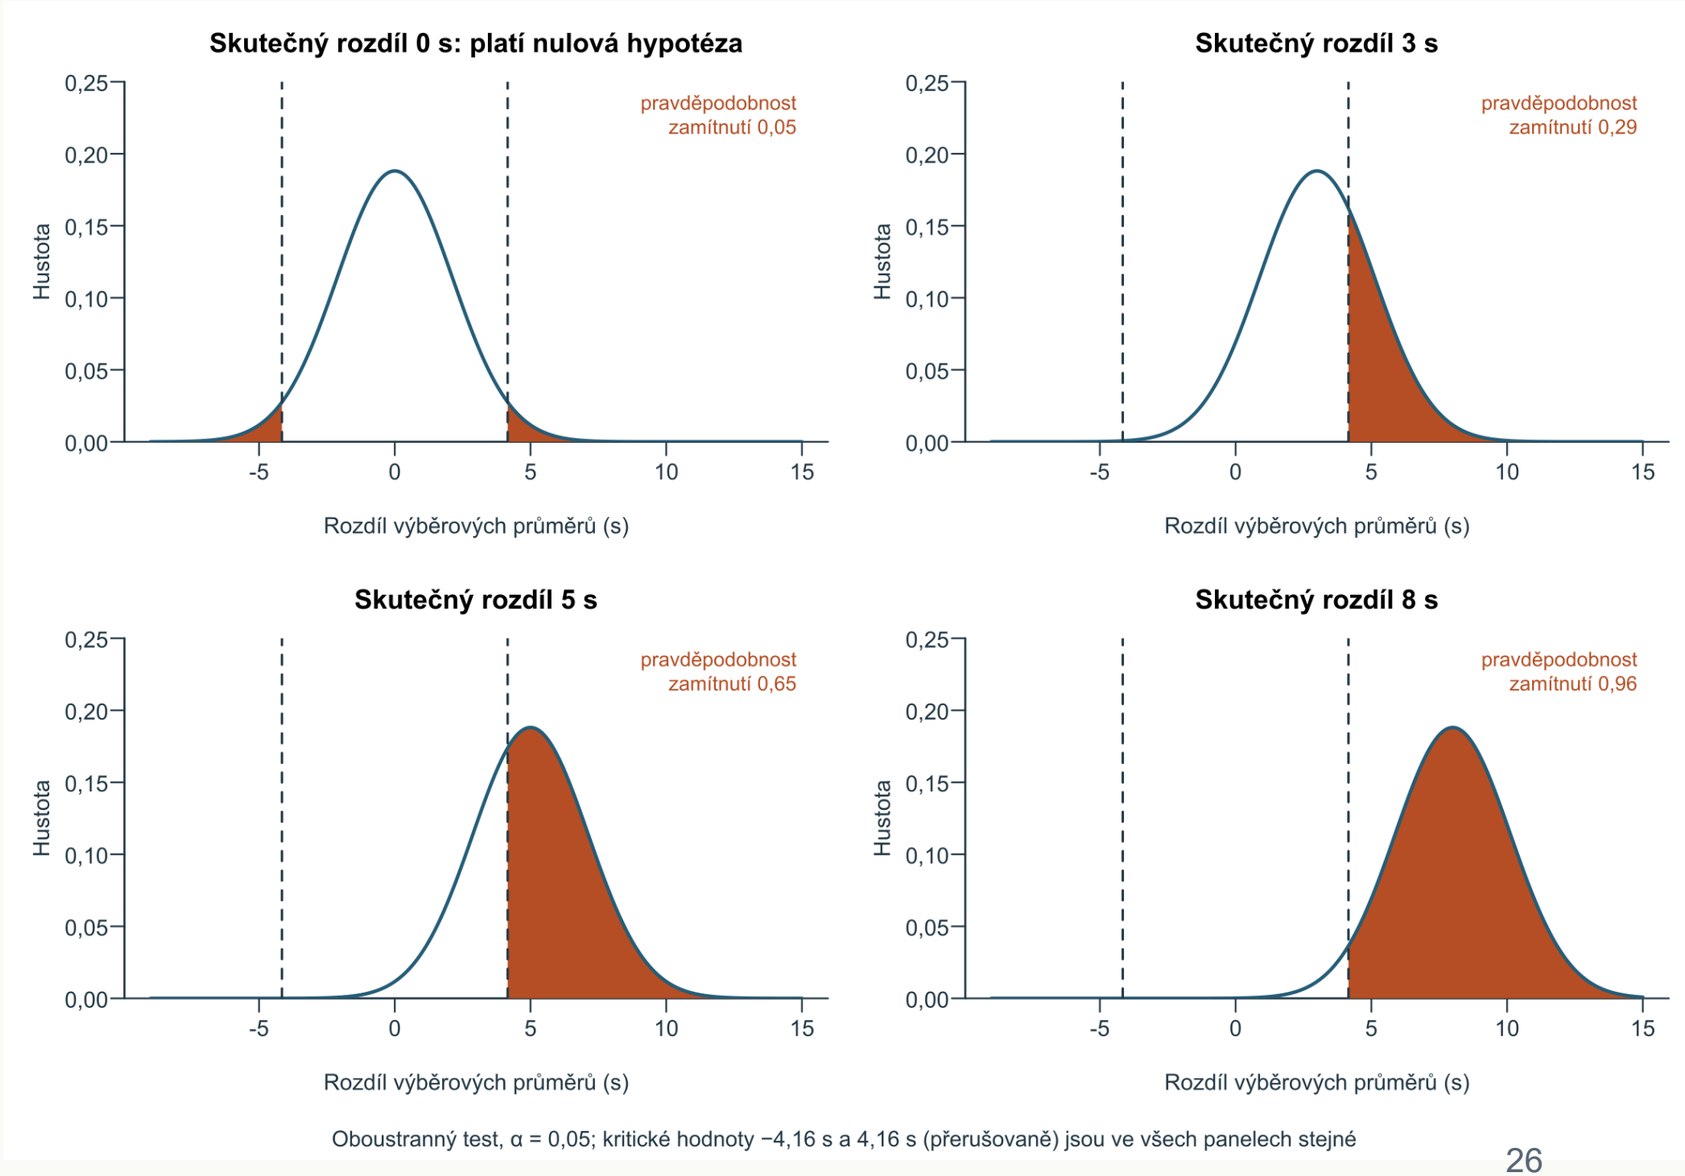
Statistická síla pro konkrétní alternativy

Statistická síla = 1 − β: pravděpodobnost zamítnutí při konkrétní alternativě

Stejné kritické hodnoty ±4,16 s

Skutečný rozdíl	Zamítnutí
0 s	0,05 (α)
3 s	0,29
5 s	0,65
8 s	0,96

Síla roste s rozdílem, velikostí výběru, reliabilitou měření, mírnější α



Oboustranný test, α = 0,05; kritické hodnoty −4,16 s a 4,16 s (přerušovaně) jsou ve všech panelech stejné

Když nulovou hypotézu nezamítneme

Smyšlená varianta: rozdíl **2,9 s** → $z = 1{,}37$, p-hodnota = 0,17

Rozhodnutí: na hladině 0,05 H_0 nezamítáme

Interpretace: výsledky neposkytly dostatečně přesvědčivou podporu rozdílu; **jeho existenci nevylučují**

Kdyby skutečný rozdíl byl 3 s, studie by jej v **71 %** případů neodhalila

Častý omyl: nezamítnutí = důkaz, že rozdíl není

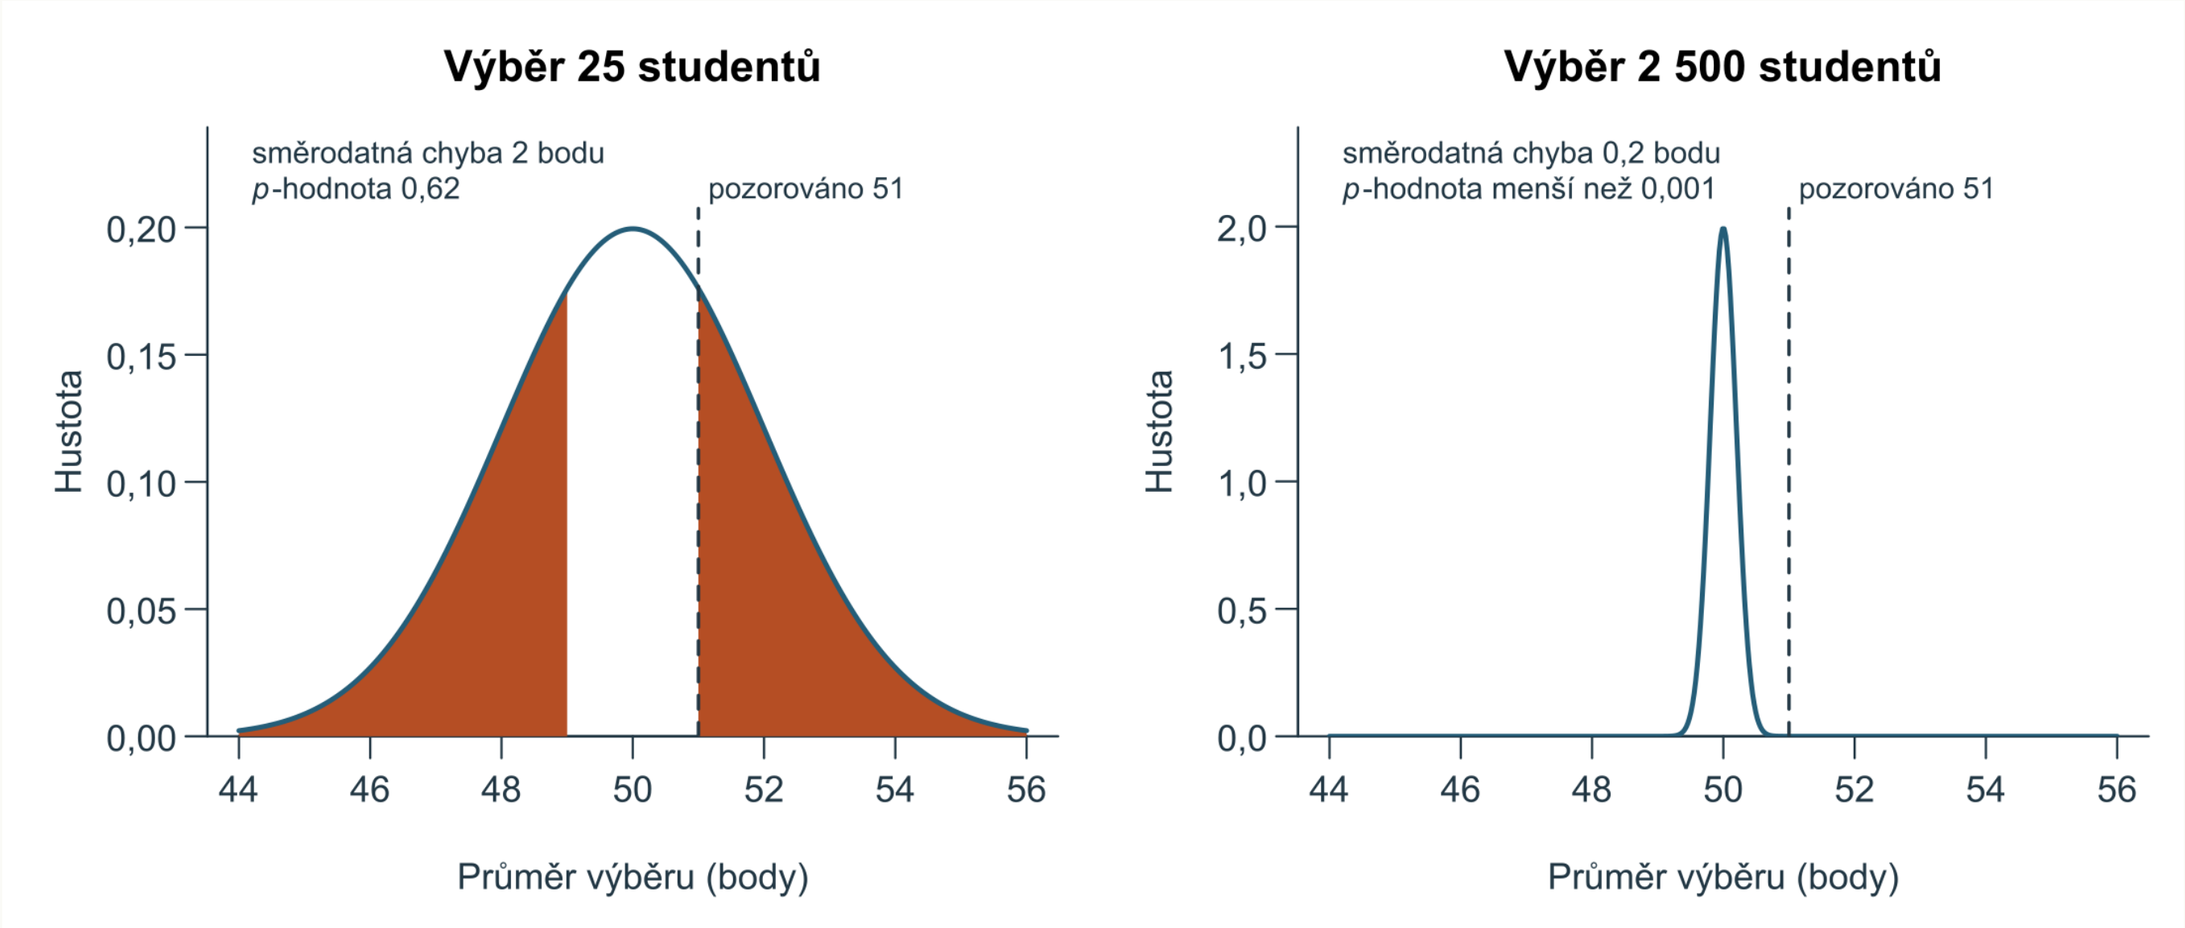
Co výsledek znamená a meze testování

Statistická významnost není velikost účinku

Významnost **statistická** (pravidlo testu) · **věcná** (pro otázku a teorii) · **praktická** (pro praxi)

Velikost účinku v původních jednotkách: 6,88 s, asi pětina doby

Stejný rozdíl 1 bod (σ = 10): $n = 25 \rightarrow p = 0{,}62$; $n = 2\,500 \rightarrow p < 0{,}001$



Stejné kroky, jiná statistika

Krok	Binomický test	*z*-test průměru
Otázka	tipoval student? 10 z 20 správně	nižší pozornost po krátkém spánku? $n = 25$, $m = 46$
Hypotézy, směr	$H_0: \pi \leq 0{,}25$; $H_1: \pi > 0{,}25$	$H_0: \mu \geq 50$; $H_1: \mu < 50$
Statistika a její rozdělení při H_0	počet správných; binomické (20; 0,25)	$z = (46 - 50) / 2 = -2$; normované normální
p-hodnota	$P(X \geq 10) = 0{,}014$	$P(z \leq -2) = 0{,}023$
Kritický obor	9 až 20 (skutečně 0,041)	průměr ≤ 46,71
Rozhodnutí	zamítáme H_0	zamítáme H_0

Společná logika: rozdělení statistiky za H_0 → jak neobvyklý je náš výsledek

Meze testování a poctivé zacházení s testy

$p = 0{,}049$ a $p = 0{,}051$ svědčí téměř stejně: **0,05 je zvyklost**

p-hodnota platí pro **celý model**: náhodný výběr, nezávislost, známá σ

20 testů, všechny H_0 platí: $1 - 0{,}95^{20} \approx$ **0,64**

Hypotézy, směr, velikost výběru a analýzu stanovit **předem**; uvádět **všechny** testy a **velikost** rozdílu

Procvičování

Úloha 1: Kolik stojí oběd

Rok platím za oběd v menze přibližně 120 Kč, plus minus 5 Kč (rozdělení zhruba normální). Dnes jsem zaplatil dvoustovkou, na účtenku se nepodíval a dostal zpět 75 Kč.

a) Načrtněte rozdělení denních útrat. Mám se obávat, že mi naúčtovali víc? Zdůvodněte.

b) Jaká je nulová hypotéza? Co by byla chyba I. a co chyba II. druhu?

c) Popište kritický obor a kritickou hodnotu pro $\alpha = 0{,}05$.

d) Proč by tu dával smysl jednostranný test a který chvost? Co kdybych zvolil nesprávný?

Howell (2013), s. 104, úlohy 4.2–4.6. Česká adaptace.

Úloha 2: Rozdělení, nebo výběrové rozdělení?

a) Čím se liší rozdělení doby spánku studentů od výběrového rozdělení průměrné doby spánku? Co je v každém z nich jedna hodnota?

b) Z populace číslic 0 až 9 ($\mu = 4{,}5$; $\sigma = 2{,}87$) vylosujeme 50 výběrů po 5 číslicích a vykreslíme 50 průměrů. Co se změní, vylosujeme-li 500 výběrů po 5 číslicích? A co při 50 výběrech po 15 číslicích?

c) Vymyslíte novou statistiku „modus děleno rozpětím“. Jak zjistíte její výběrové rozdělení, když pro ně neznáte vzorec?

Howell (2013), s. 105, úlohy 4.10, 4.11 a 4.15; s. 222, úlohy 7.4 a 7.5. Česká adaptace.

Úloha 3: Kapesné chlapců a dívek

Výzkumná hypotéza: chlapci ve 4. třídě dostávají větší kapesné než dívky.

a) Zapište nulovou a alternativní hypotézu. O jakých parametrech mluví?

b) Zvolili byste jednostranný, nebo oboustranný test? Kdy a proč?

c) Jaké výsledky by vedly k zamítnutí nulové hypotézy a jaké ne?

d) Co jednoho byste udělali, aby byla studie přesvědčivější?

e) Uveďte vlastní výzkumnou hypotézu z psychologie a příslušnou nulovou hypotézu.

Howell (2013), s. 105, úlohy 4.17 a 4.23. Česká adaptace.

Úloha 4: Co se stane se silou?

Parkovací test: oboustranně, α = 0,05, 100 řidičů ve skupině; při skutečném rozdílu 5 s je síla 0,65. Jak se změní α, β a síla, když:

a) zvolíme hladinu 0,01;

b) změříme 200 řidičů v každé skupině;

c) přesnějším měřením zmenšíme směrodatnou odchylku dob;

d) skutečný rozdíl je jen 3 s;

e) předem zvolíme jednostranný test „déle“, resp. „kratší“?

Podle Howella (2013), s. 105, úloha 4.16; ostatní vlastní

Úloha 5: Kde je chyba?

a) „p = 0,02, takže nulová hypotéza platí s pravděpodobností 2 %.“

b) „p = 0,30; prokázali jsme, že terapie nemá žádný účinek.“

c) „Rozdíl 0,4 bodu na stobodové škále vyšel u 20 000 lidí s $p < 0{,}001$, je to tedy důležitý objev.“

d) „Ženy a muže jsme porovnali ve 20 vlastnostech, jedna vyšla statisticky významně; v ní se tedy liší.“

e) „Plánovali jsme oboustranný test a vyšlo p = 0,08. Průměr je nad normou, takže použijeme jednostranný: p = 0,04.“

f) „Dotazník vyplnili jen dobrovolníci, ale s 5 000 respondenty je výsledek přesný pro celou populaci.“

Vlastní úlohy pro tuto výuku

Práce v Excelu: doprovodný sešit

kapitola_06_vyberove_rozdeleni_a_testovani_cviceni.xlsx

U1_cislice: 100 číslic a 50 průměrů výběrů po pěti

U2_prumer: jeden uchazeč a průměr skupiny

U3_binom_test: 61 žen ze 100 případů deprese

U4_z_test: program a škála sebeúcty

Howell (2013), s. 104, 106 a 221–222, úlohy 4.7–4.9, 4.27 a 7.1–7.3. Česká adaptace; U4 vlastní.