Interval spolehlivosti, jednovýběrový *t*-test a test ekvivalence

Kapitola 7

Obsah přednášky

1. Od rozhodnutí testu k odhadu
2. Šířka intervalu a *t*-rozdělení
3. Jednovýběrový *t*-test
4. Interval a *p*-hodnota
5. Test ekvivalence
6. Čtyři kombinace a sdělení výsledků
7. Procvičování

Od rozhodnutí testu k odhadu

Co víme po *z*-testu a co ne

25 studentů po krátkém spánku: *m* = 46 bodů, norma 50

z-test (σ = 10): $z = -2$, *p*-hodnota 0,023 → zamítáme $\mu \geq 50$

Test odpověděl: „je populační průměr nižší než 50?“

Neodpověděl: **o kolik**? Pokles o 1 bod, nebo o 8 bodů?

Modelový předpoklad σ = 10 (z norem) × **údaj z dat** *s* = 11 (z výběru)

Bodový a intervalový odhad: obrácení úvahy

Bodový odhad: m = 46, jedno číslo, nejlepší tip pro μ

Intervalový odhad: rozmezí hodnot μ slučitelných s daty

Minule: známe μ → kde leží průměry výběrů?

95 % průměrů leží nejvýše 1,96 × σ_m = 1,96 × 2 = **3,92 bodu** od μ

Dnes: známe *m* → kde asi leží μ?

Vzdálenost je souměrná: je-li *m* nejvýše 3,92 od μ, je i μ nejvýše 3,92 od *m*

Výpočet 95% intervalu při známé σ

$m \pm z_{0,975} \times \sigma_m, \qquad \sigma_m = \frac{\sigma}{\sqrt{n}}$

σ_m = 10 / √25 = 2; **mezní chyba odhadu** 1,96 × 2 = 3,92

Meze: 46 − 3,92 = 42,08 a 46 + 3,92 = 49,92 → **(42,08; 49,92)** bodu

Hladina spolehlivosti 1 − α (zde 95 %); oboustranný interval: kvantil $z_{1-\alpha/2}$

Věcně: s daty jsou slučitelné průměry přibližně od 42 do 50 bodů

Co znamená „95 %“

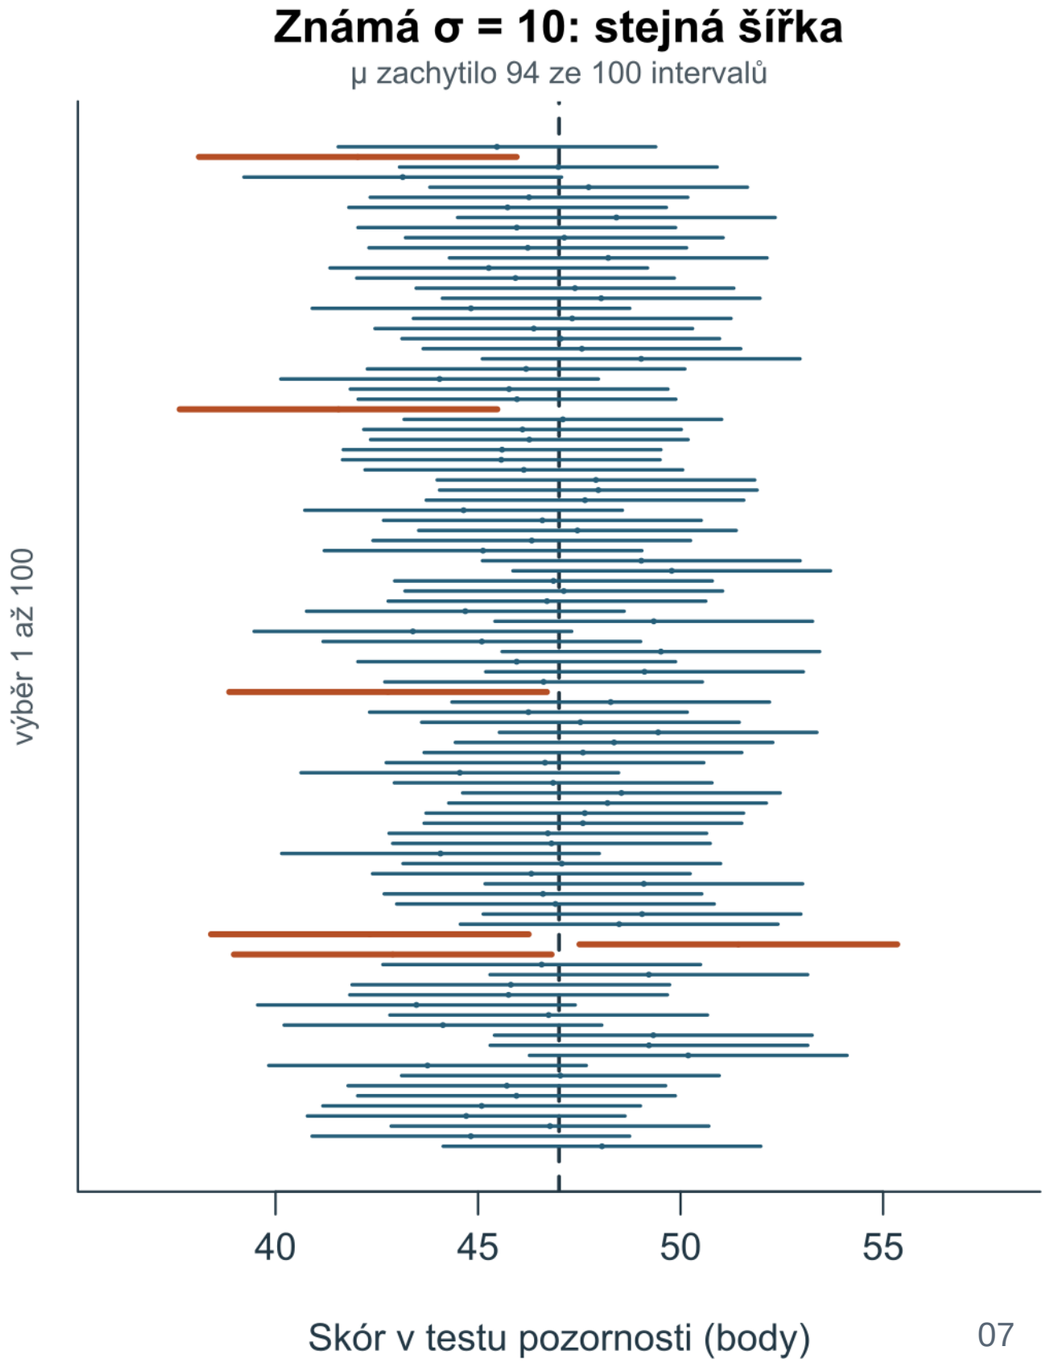
Výukový model μ = 47, σ = 10; 100 výběrů po 25

Stejná šířka 7,84, mění se **poloha**; μ zachytilo **94 ze 100**

95 % = **dlouhodobé pokrytí postupu** při opakování

Jeden interval μ buď obsahuje, nebo ne

Ne: „μ leží v (42,08; 49,92) s pravděpodobností 95 %“



Šířka intervalu a *t*-rozdělení

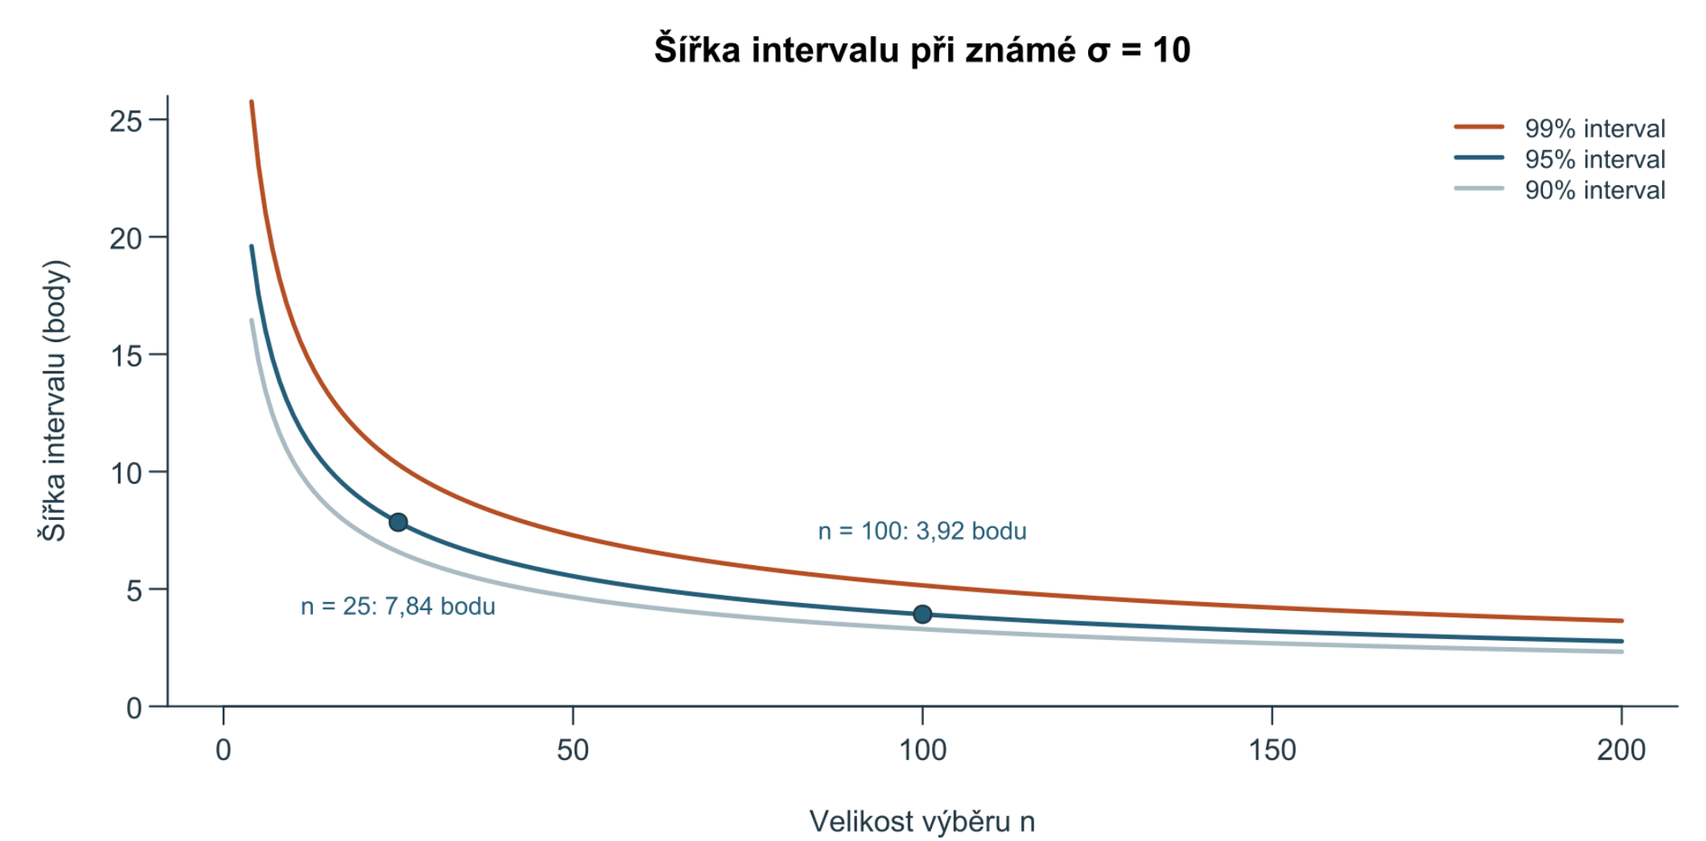
Šířka intervalu: spolehlivost, variabilita, velikost výběru

Šířka 90 %, 95 %, 99 % intervalu:
6,58; 7,84; 10,30

Dvojnásobná σ → dvojnásobná šířka

Čtyřnásobné *n* → poloviční šířka:
pro 100 lidí 3,92

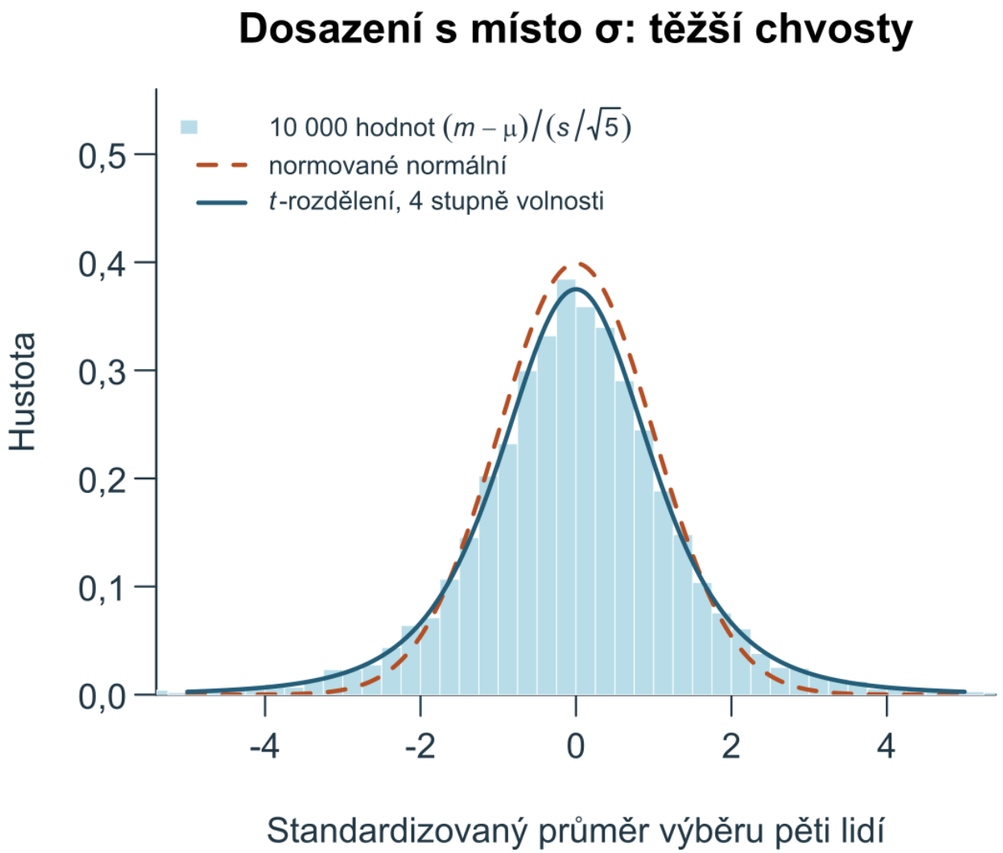
Šířka = přesnost, ne správnost

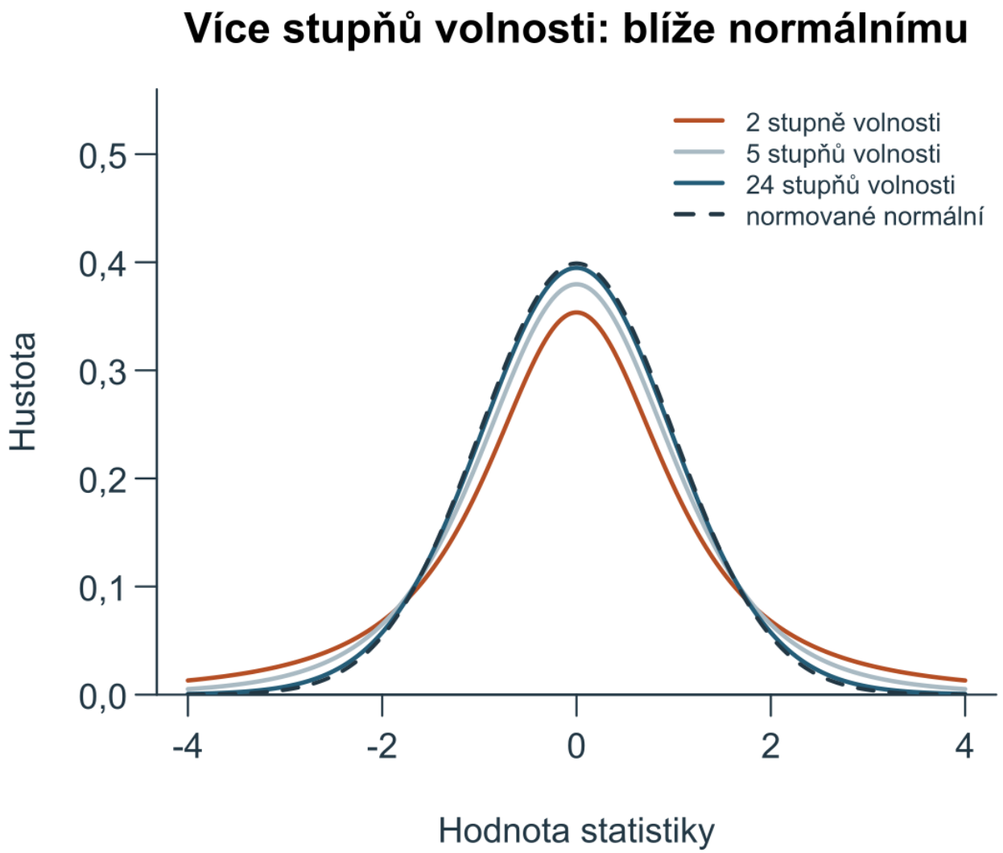


Když dosadíme *s*: *t*-rozdělení

$$t = \frac{m - \mu}{s_m} = \frac{m - \mu}{\frac{s}{\sqrt{n}}}$$

Mimo ±1,96 při σ: 4,8 %; při *s* (výběry po 5): **12,4 %** · **stupně volnosti** *v* = *n* − 1; **těžší chvosty**





Kvantily *t*-rozdělení

$t_{0,975\ (v\,=\,24)}$: kvantil, pod nímž leží 97,5 % *t*-rozdělení s 24 stupni volnosti

Stupně volnosti *v*	**4**	**9**	**24**	**99**	**normální (*z*)**
$t_{0,975\ (v)}$	2,776	2,262	2,064	1,984	1,960

Excel: **T.INV**(0,975; 24) → 2,064

Menší výběr → kvantil dál od nuly → širší interval

Souměrnost: $t_{0,025\ (v\,=\,24)} = -2{,}064$

Interval s *t*-kvantilem v pěti krocích

$m \pm t_{0{,}975\ (v)} \times s_m, \qquad s_m = \frac{s}{\sqrt{n}}$

1. $s_m = 11 / \sqrt{25} = 2{,}2$ 2. $v = 25 - 1 = 24$ 3. $t_{0{,}975\ (v\,=\,24)} \approx 2{,}064$

4. Mezní chyba $2{,}064 \times 2{,}2 \approx 4{,}54$ 5. Meze $46 \pm 4{,}54 \rightarrow$ **(41,46; 50,54)**

O 1,24 bodu širší než (42,08; 49,92): kvantil +0,42, vyšší *s* +0,83

Excel: list Interval_t; ve vzorci =T.INV(1 − (1 − 0,95)/2; *v*)

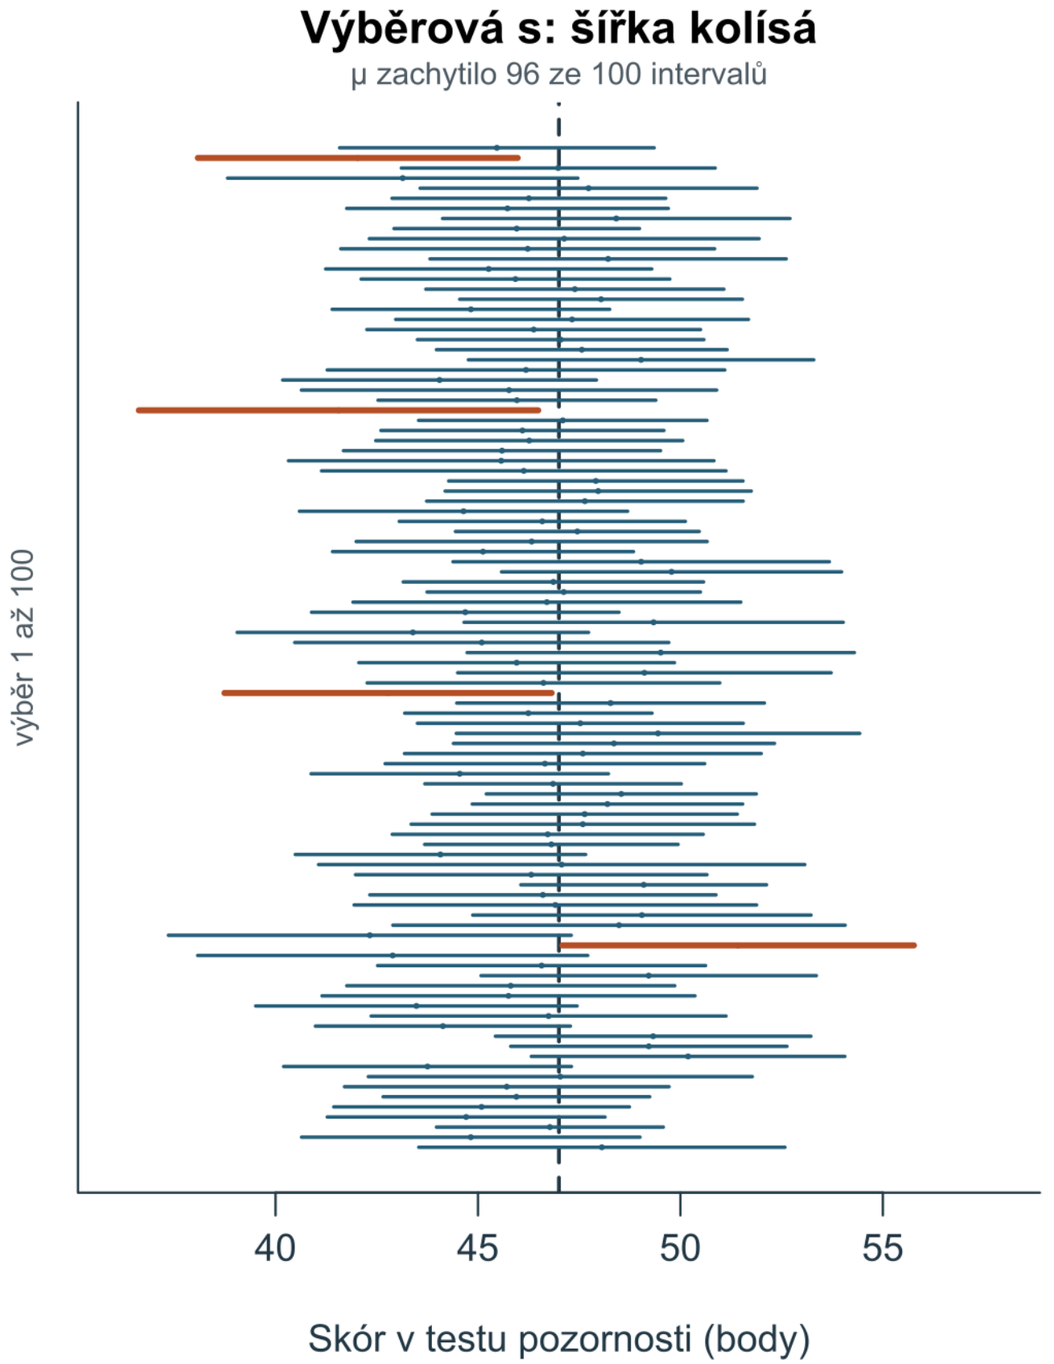
Opakované intervaly s výběrovou *s*

Tytéž výběry,
interval s *t*-kvantilem a *s*

Kolísá i **šířka**: 5,6 až 12,0 bodu;
μ zachytilo **96 ze 100**

Pokrytí postupu opět 95 %

S násobkem 1,96 místo *t*:
pokrytí 93,8 % (*n* = 25),
91,8 % (10),
87,8 % (5)



Normalita, odolnost a nezávislost

Přesné *t*-rozdělení: **nezávislý náhodný výběr** z **normální populace**

Vůči odchylkám od normality **poměrně odolné**, hlavně u větších výběrů a souměrných populací

Šikmost: pokrytí nižší, jednostranný test v jednom směru zamítá příliš často

Souměrné s občasnými odlehlými hodnotami: intervaly zbytečně široké, menší síla

Data prohlédněte: histogram, krabicový graf, Q–Q graf

Nezávislost je důležitější a výpočtem se neopraví

Jednovýběrový *t*-test

Jednovýběrový *t*-test na datech pozornosti

1. Hypotézy (směr stanoven předem): H_1: $\mu < 50$, H_0: $\mu \geq 50$; $\mu_0 = 50$

2. Hladina významnosti $\alpha = 0{,}05$

3. Testová statistika, 24 stupňů volnosti:

$$t = \frac{m - \mu_0}{s_m} = \frac{46 - 50}{2{,}2} \approx -1{,}818$$

4. *p*-hodnota = plocha vlevo od −1,818: =T.DIST(−1,818; 24; PRAVDA) ≈ **0,041**

5. Rozhodnutí testu: zamítáme H_0 (kritická hodnota −1,711)

Věcná interpretace a srovnání se *z*-testem

6. Věcná interpretace

Směr podle hypotézy; odhadovaný pokles **4 body**

90% interval **(42,24; 49,76)**: pokles od asi 0,2 do téměř 8 bodů

Příčinný závěr o spánku závisí na tom, jak se studenti do skupiny dostali

***p*-hodnota: *z*-test 0,023 → *t*, *s* = 10: 0,028 → *t*, *s* = 11: 0,041**

Oboustranně by *p*-hodnota byla 0,082

Skutečná data: psychomotorický vývoj dětí

56 dětí s nízkou porodní hmotností, index PDI v 6 měsících; norma μ = 100

Oboustranný test: H_0: μ = 100, H_1: μ ≠ 100 (opačný směr nelze předem vyloučit)

m = 104,125; *s* = 12,584; s_m ≈ 1,682; *t* ≈ 2,45; 55 st. v.; *p*-hodnota ≈ 0,017

95% interval **(100,75; 107,50)**

Nečekaný směr: v průměru o 4 body nad normou

Howell (2013), s. 186–189; data ze studie Nurcomba et al. (1984)

Interval a *t*-test v Excelu

Funkce	Co vrací	Pozornost (24 st. v.)
=T.INV(0,975; *v*)	kvantil s podílem 0,975 vlevo	2,064
=T.DIST(*t*; *v*; PRAVDA)	plocha vlevo od *t* („menší“)	0,041
=1 − T.DIST(*t*; *v*; PRAVDA)	plocha vpravo od *t* („větší“)	0,959
=T.DIST.2T(ABS(*t*); *v*)	oboustranná *p*-hodnota	0,082
=T.INV.2T(α; *v*)	kladná kritická hodnota oboustranně	2,064

Sešit kapitoly: listy Interval_t a T_test

Interval a *p*-hodnota

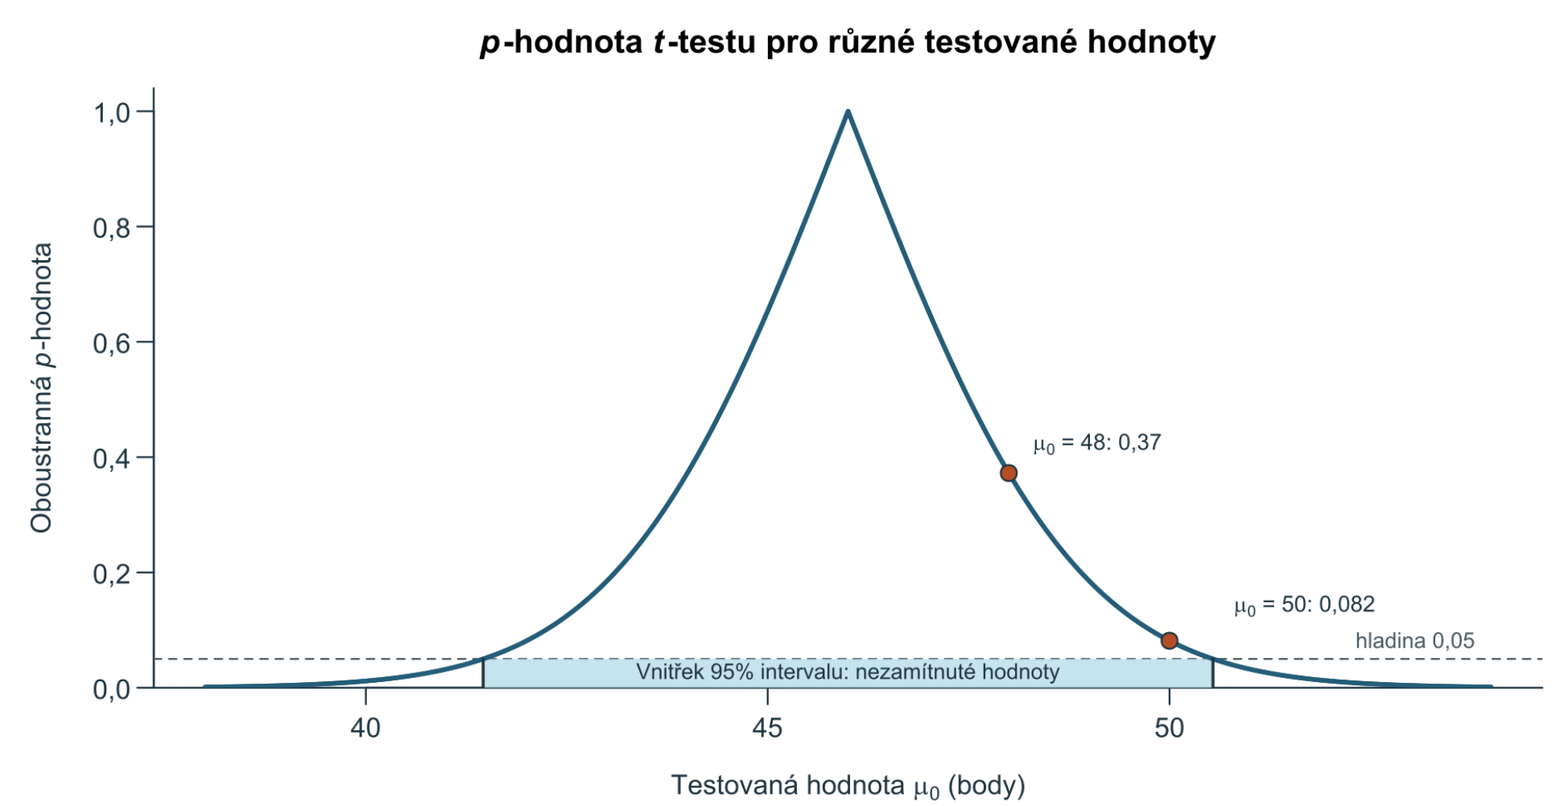
Vnitřek intervalu: hodnoty, které test nezamítá

Oboustranný test pro různá μ_0; vrchol křivky u $m = 46$

Nezamítá hodnoty striktně uvnitř 95% intervalu

Mimo interval a přesně na mezi zamítá (tam $p = 0{,}05$)

Interval navíc: **velikost**, **přesnost** (šířka 9,08) a **slučitelné hodnoty**

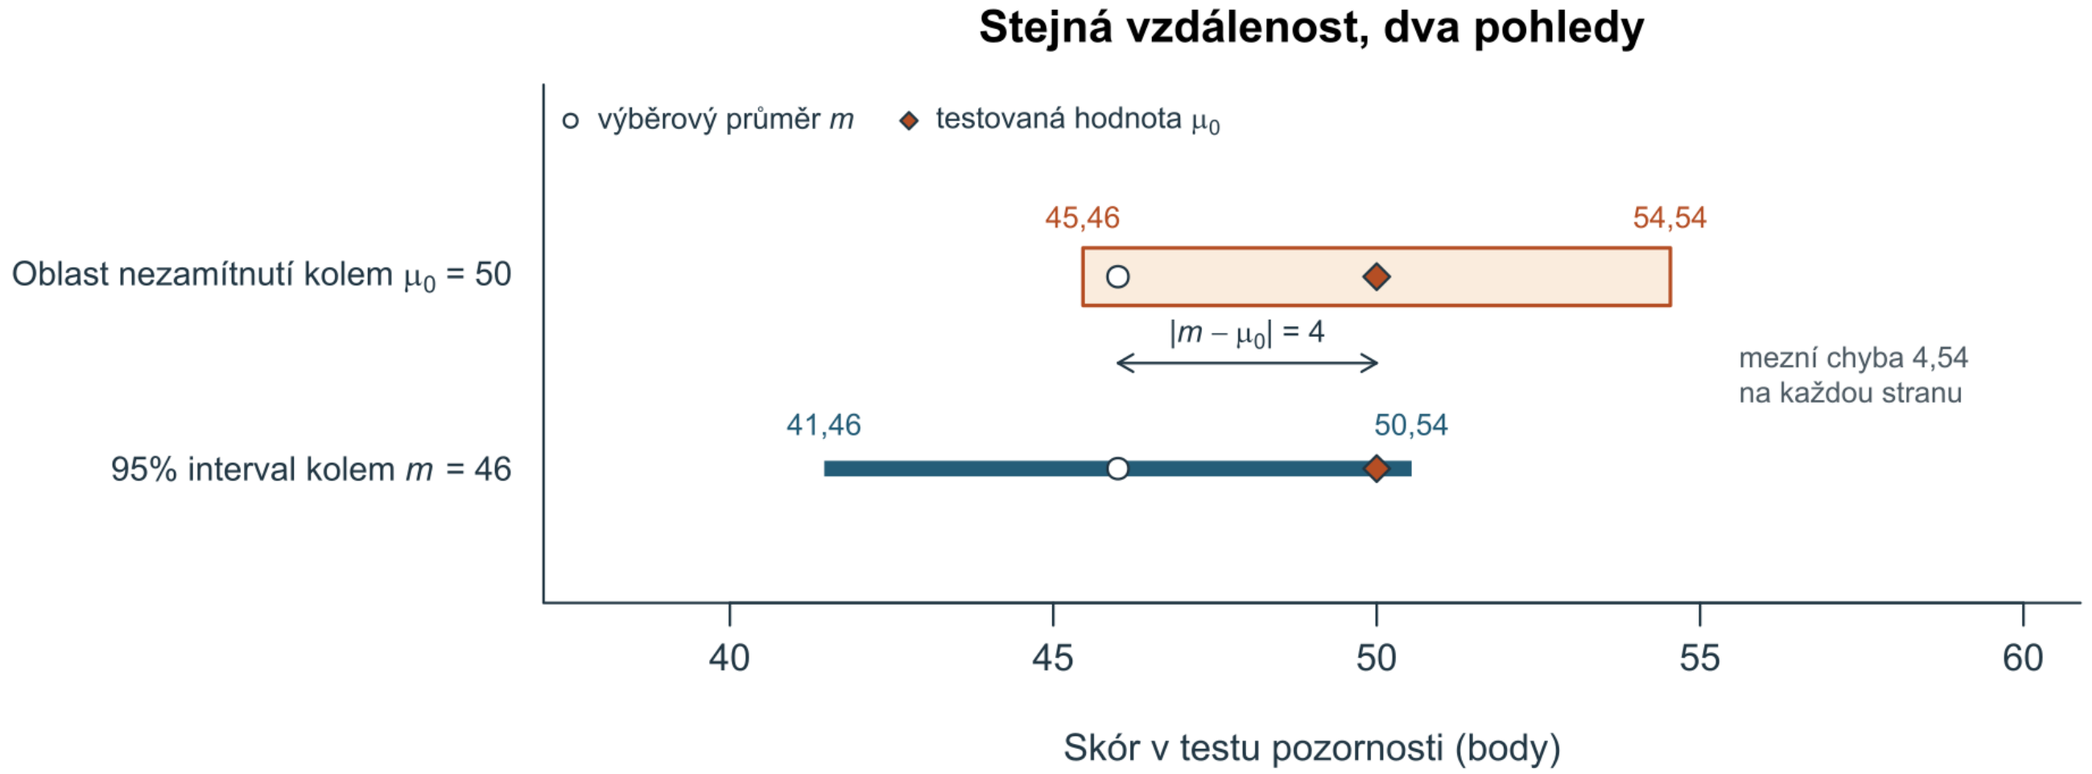


Tři cesty k témuž rozhodnutí

Test: oblast nezamítnutí kolem $\mu_0 = 50$: **45,46 až 54,54**; leží v ní $m = 46$?

Interval kolem $m = 46$: **41,46 až 50,54**; leží v něm $\mu_0 = 50$?

Obojí porovnává $|m - \mu_0| = 4$ s mezní chybou 4,54; třetí cesta: *p*-hodnota > 0,05

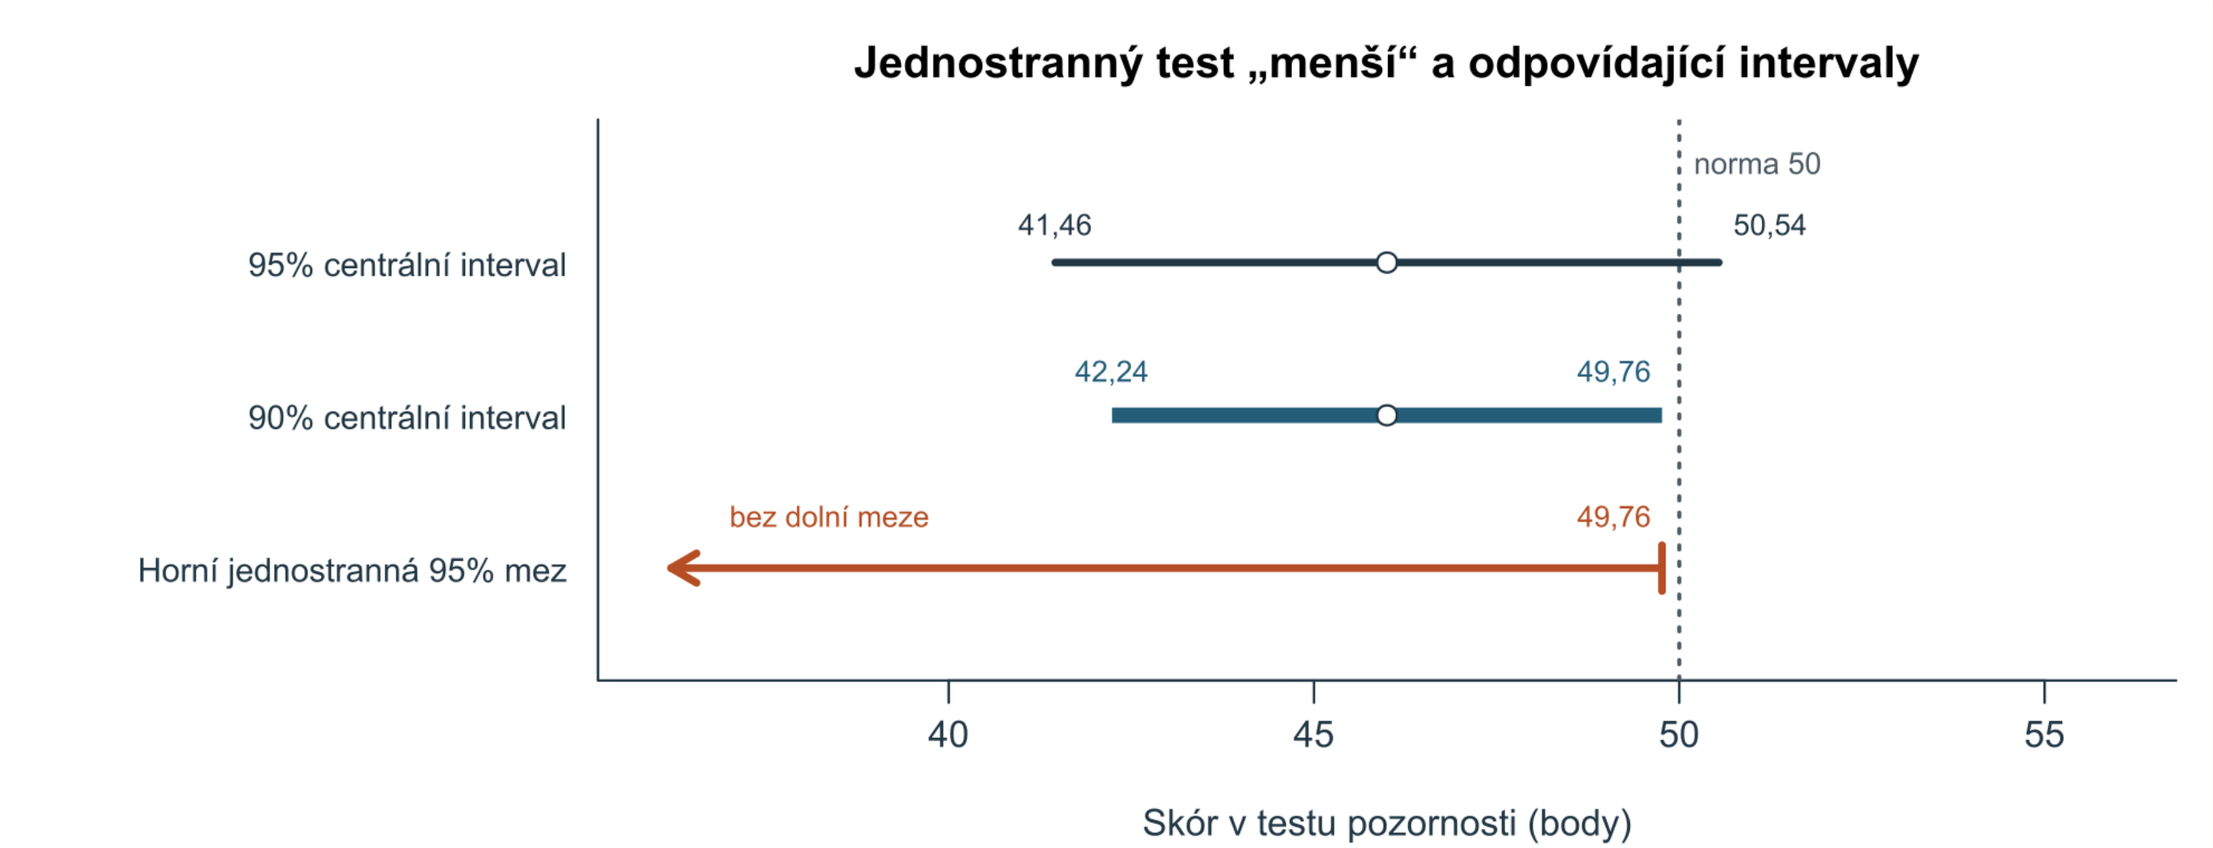


Jednostranný test a 90% interval

Test „menší“ zamítl (p = 0,041), ale 95% interval obsahuje 50: **není to rozpor**

Horní jednostranná 95% mez: 46 + $t_{0,95\ (v\,=\,24)}$ × 2,2 = 46 + 1,711 × 2,2 ≈ **49,76** = horní mez 90% intervalu

Jednostranný test na hladině α ↔ mez centrálního intervalu se spolehlivostí **1 − 2α** (ve správném směru)



Test ekvivalence

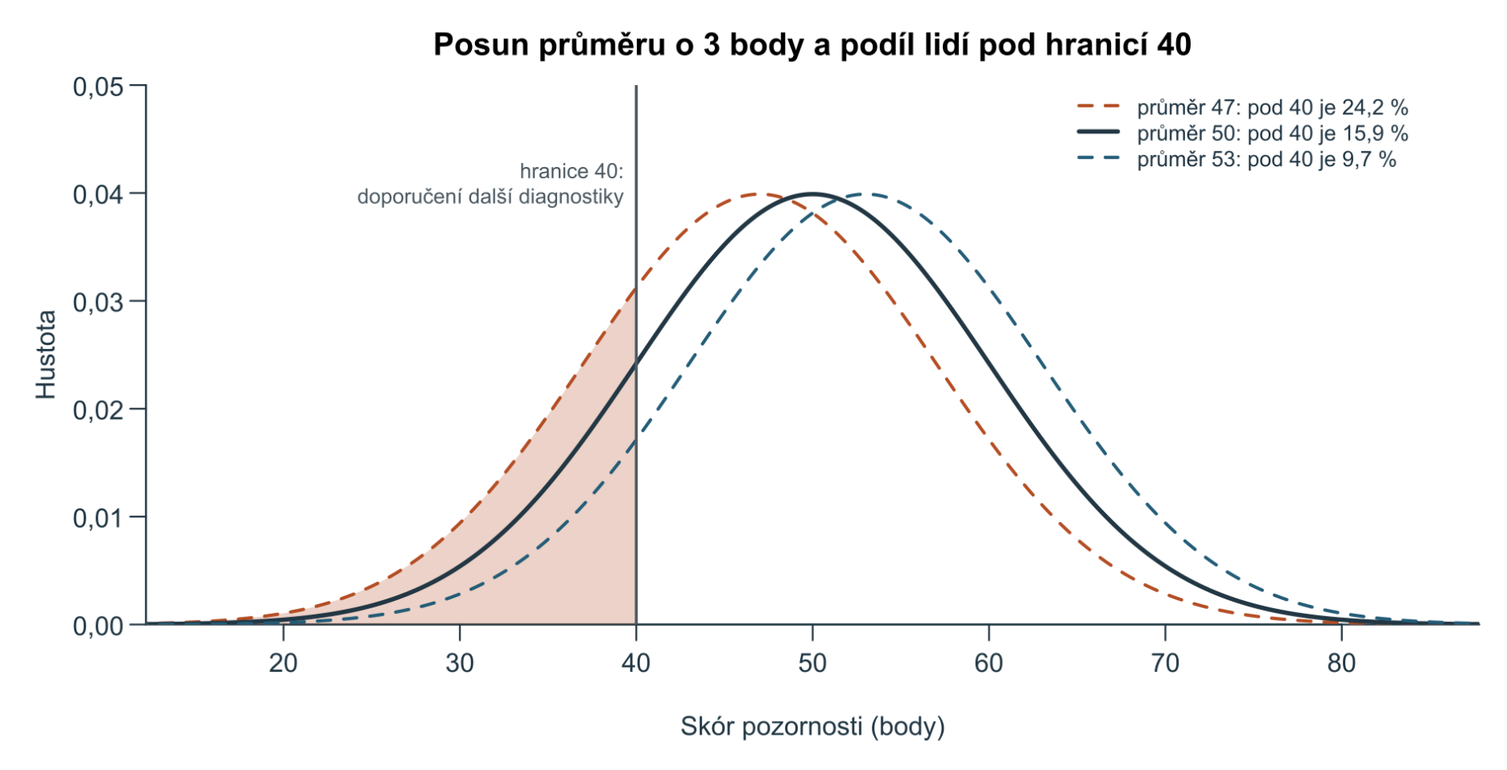
Online verze testu: kde začíná důležitý rozdíl

Platí normy (průměr 50) i pro online verzi?
Nezamítnutí ≠ shoda, zamítnutí ≠ důležitý rozdíl

Nejmenší věcně důležitý rozdíl Δ → hranice ekvivalence $\mu_0 \pm \Delta$

Pod 40 bodů: 15,9 % → posun o 3 body: 24,2 % / 9,7 %

Δ = 3, pásmo 47–53, zvoleno před analýzou

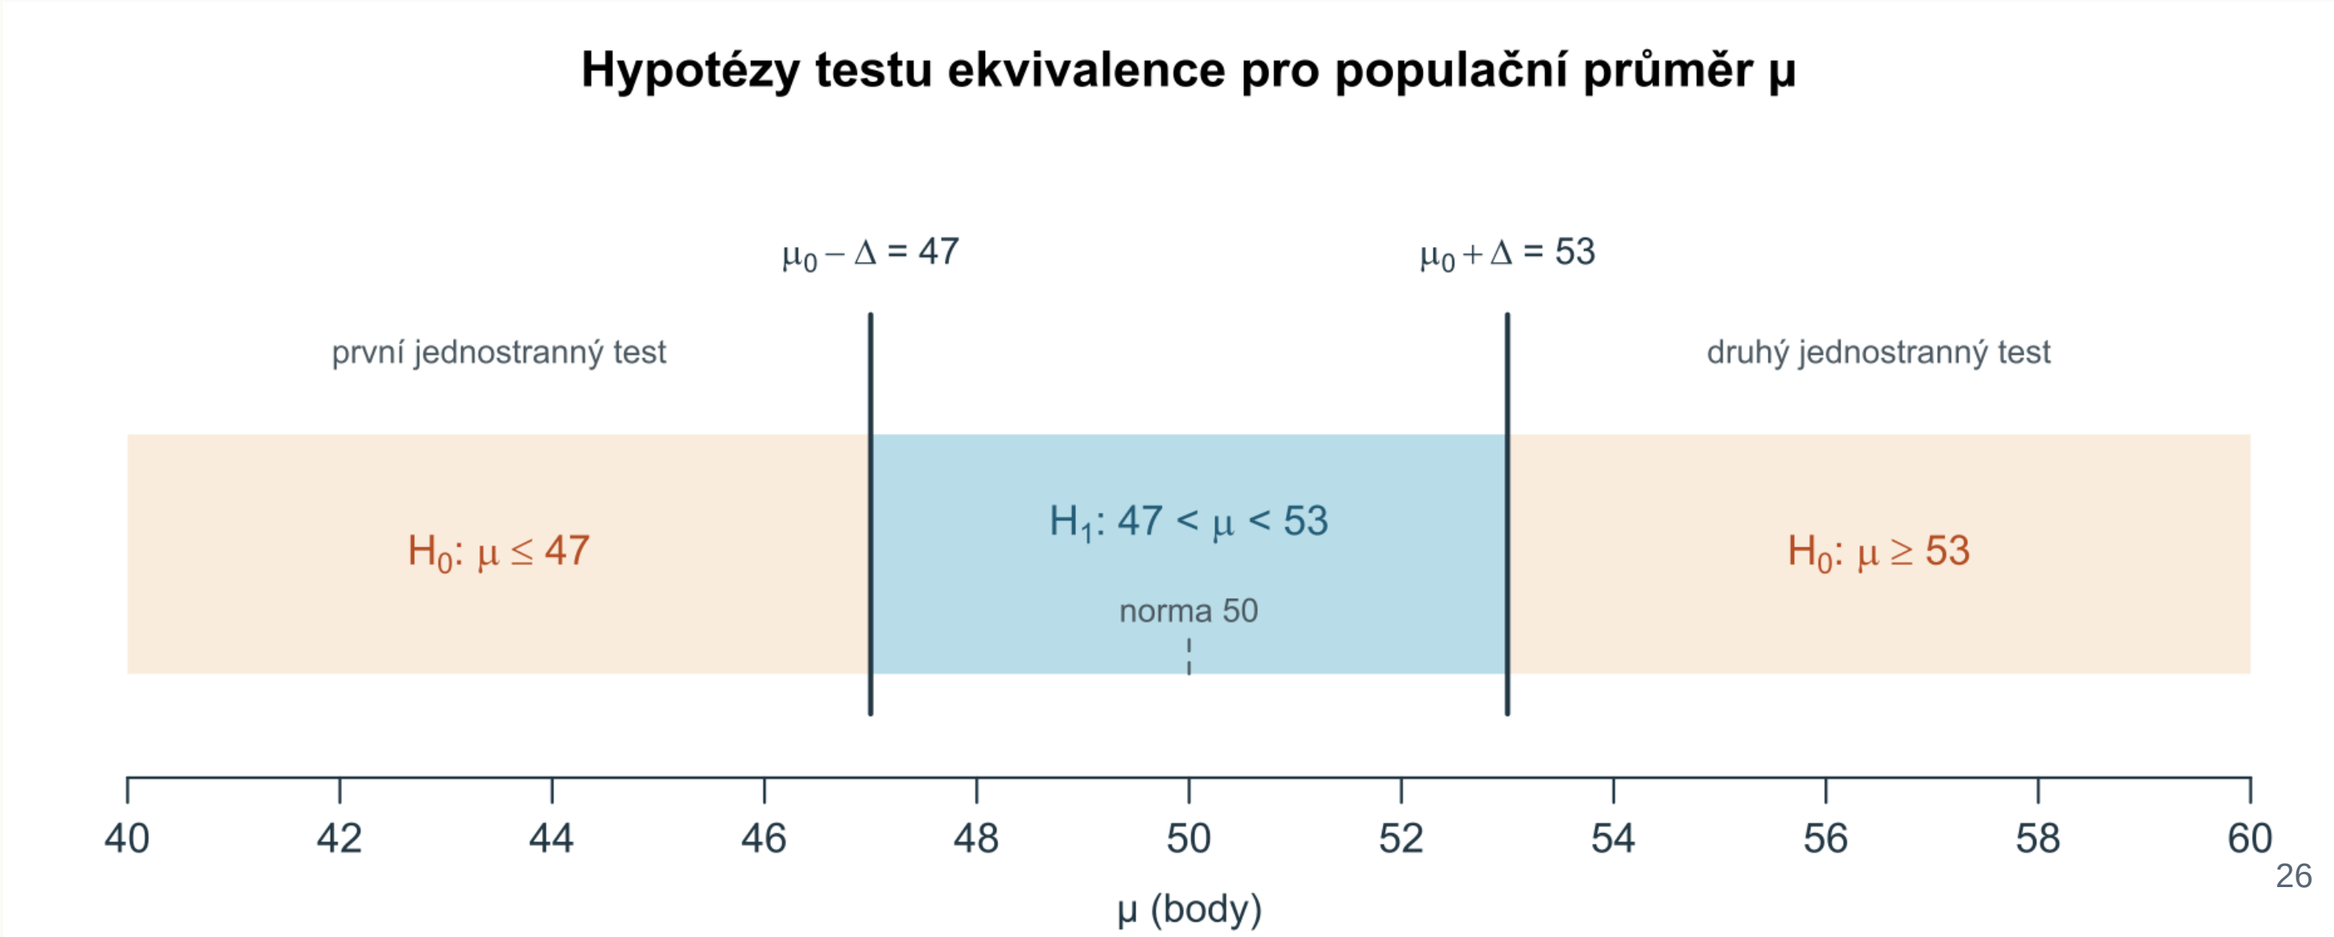


Obrácené hypotézy testu ekvivalence

H_0: $\mu \leq \mu_0 - \Delta$ **nebo** $\mu \geq \mu_0 + \Delta$ · H_1: $\mu_0 - \Delta < \mu < \mu_0 + \Delta$

Online verze: H_0: $\mu \leq 47$ nebo $\mu \geq 53$; H_1: $47 < \mu < 53$

Zamítnutí → průměr v pásmu; nezamítnutí → ekvivalence **nedoložena** (ne „rozdíl je důležitý“)



Dva jednostranné testy a 90% interval

TOST: test vůči 47 (H_1: $\mu > 47$) a test vůči 53 (H_1: $\mu < 53$), každý na hladině 0,05

Ekvivalence doložena, jen když zamítnou oba

Celý test na hladině 0,05: μ nemůže být zároveň pod 47 i nad 53

Dolní mez 90% intervalu ≥ 47 a horní mez ≤ 53 ⇔ oba testy zamítají

Celý 90% interval uvnitř pásma (dotyk stačí) → ekvivalence doložena

Dva intervaly, dvě funkce: **95 %** test rozdílu od 50, **90 %** test ekvivalence

Čtyři kombinace a sdělení výsledků

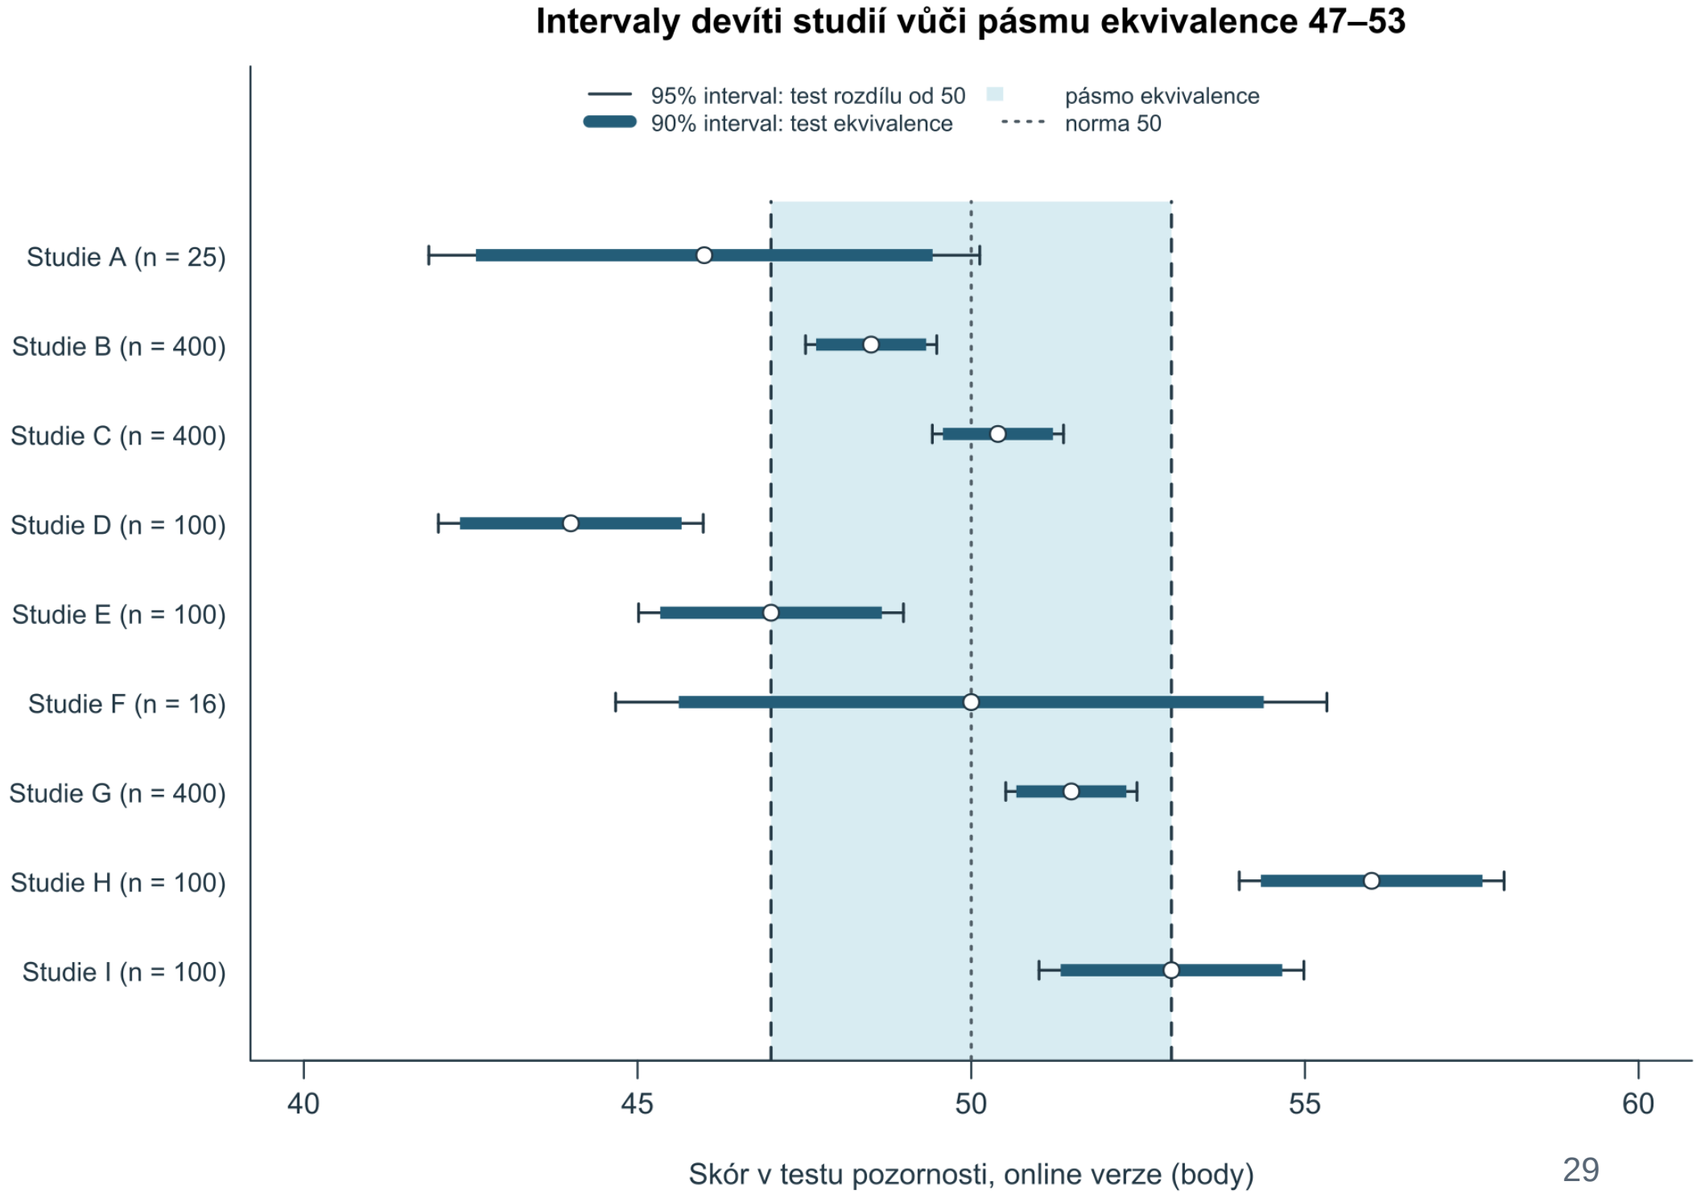
Devět studií vůči pásmu ekvivalence

Norma 50, pásmo 47–53, *s* = 10

Tenká: **95%** interval, test rozdílu

Tlustá: **90%** interval, test ekvivalence

B, C, G v pásmu;
D, H mimo;
A, E, F, I přes hranici



Čtyři kombinace a jejich závěry

Test rozdílu	Ekvivalence	Studie	Závěr
zamítá	doložena	B, G	statisticky, ale ne věcně významný rozdíl
nezamítá	doložena	C	rozdíl menší než hranice
zamítá	nedoložena	D, H; E, I	D, H: rozdíl větší než hranice; E, I: nerozhodnuto
nezamítá	nedoložena	A, F	neprůkazné, studie příliš malá

Omyl: „nezamítli jsme, tedy je to stejné“ (A: $p = 0{,}057$)

Neprokázaná ekvivalence ≠ důležitý rozdíl (doložen jen u D a H)

Co ekvivalence vůči normě dokládá a co ne

Studie C: **populační průměr** online verze leží v pásmu 47–53 kolem **normy 50**

Nedokládá:

• zaměnitelnost verzí (variabilita, tvar, vztah k jiným ukazatelům)

• shodu individuálních výsledků (tytéž lidé oběma verzemi)

• stejnou reliabilitu

Norma jako **pevné číslo**; závěr platí jen pro **zvolené hranice**

Jak výsledky sdělit

Studie B, ukázka podle APA 7 (*M*, *SD*, CI):

„Průměrný skór v online verzi (*n* = 400; *M* = 48,5; *SD* = 10,0) byl statisticky významně nižší než norma 50 (*t*(399) = −3,00; *p* = 0,003; 95% CI [47,52; 49,48]). Hranice ekvivalence ±3 body byly stanoveny před analýzou podle vlivu posunu na podíl osob pod 40 body. Test ekvivalence (dva jednostranné testy) doložil, že rozdíl leží uvnitř těchto hranic (90% CI [47,68; 49,32]; *t*(399) = 3,00; *p* = 0,001 pro větší z obou *p*-hodnot). Rozdíl asi 1,5 bodu je pro použití norem zanedbatelný.“

Odhad a přesnost · test rozdílu · zdůvodněné hranice · test ekvivalence · věcný závěr

Procvičování

Úloha 1: Interval s kalkulačkou

36 dětí z programu pro nadané má v testu pracovní paměti průměr $m = 106$. Normy: $\mu = 100$, $\sigma = 15$; předpokládejte, že $\sigma = 15$ platí i pro tyto děti.

a) Spočítejte 95% interval spolehlivosti ($z_{0,975} = 1,96$).

b) Spočítejte 99% interval ($z_{0,995} = 2,576$).

c) Co z obou intervalů plyne pro oboustranný test $\mu = 100$ na hladinách 0,05 a 0,01?

d) Kolik dětí by bylo potřeba pro poloviční šířku 95% intervalu?

e) Dokládá výsledek, že program paměť zlepšuje?

Vlastní úloha pro tuto výuku

Úloha 2: Co o intervalu platí?

Studie 40 seniorů: 95% interval pro průměrnou dobu reakce je (412; 448) ms. Rozhodněte, zda výrok platí, a chybný opravte.

a) „S pravděpodobností 95 % leží populační průměr mezi 412 a 448 ms.“

b) „95 % seniorů reaguje za 412 až 448 ms.“

c) „Při mnoha opakováních studie by asi 95 % takových intervalů zachytilo populační průměr.“

d) „Senioři se přihlásili v klubu aktivních seniorů; interval je úzký, takže platí pro všechny seniory.“

e) „Oboustranný test na hladině 0,05 by zamítl μ = 450 ms.“

Vlastní úloha pro tuto výuku

Úloha 3: Kdo se přeceňuje?

Jedenáct studentů, jejichž výkon v testu logického uvažování patřil do nejnižší čtvrtiny, odhadlo své umístění v průměru na **68. percentilu**.

a) Zapište hypotézy pro otázku, zda se odhadují nad průměrem (50. percentil). Proč je tu jednostranný test obhajitelný a kdy musí být zvolen?

b) Námitka: „Kdo je u dna, nemůže se moc podcenit, jen přecenit; proto průměrný odhad vychází vysoko.“ Proč nevysvětluje velikost přecenění?

c) Výpočet provedete v sešitu na listu U1_Kruger_Dunning.

Howell (2013), s. 222, úlohy 7.6, 7.7 a 7.9; studie Krugera a Dunninga (1999). Česká adaptace.

Úloha 4: Rozhodnutí z intervalů bez výpočtu

Tři studie škály spokojenosti (norma 50; každá $n = 25$, $s = 10$):

Studie	*m*	95% interval	90% interval
P	53,0	(48,87; 57,13)	(49,58; 56,42)
Q	54,0	(49,87; 58,13)	(50,58; 57,42)
R	55,5	(51,37; 59,63)	(52,08; 58,92)

a) Oboustranný test vůči 50 ($\alpha = 0{,}05$) pro P, Q, R. b) Studie P: zamítne oboustranný test $\mu_0 = 48$, 50, 57?

c) Předem zvolený test „větší“ (H_1: $\mu > 50$) pro P, Q, R. d) Přesná dolní mez 95% intervalu vyjde přesně 50,000: výsledek oboustranného testu?

Vlastní úloha pro tuto výuku

Úloha 5: Hranice ekvivalence pro tabletovou verzi

Poradna chce u tabletové verze testu čtenářského porozumění používat normy papírové verze (průměr 100, *SD* 15). Dítěti pod 85 body se doporučí další vyšetření.

a) Posun průměru o 5 bodů dolů zvýší podíl dětí pod 85 z 15,9 % na 25,2 %, posun nahoru jej sníží na 9,1 %. Jak by z toho poradna mohla odvodit Δ?

b) Posuďte zdůvodnění: (1) „Δ = 3 body, protože 0,2 *SD* je podle konvence malý účinek.“ (2) „Δ zvolíme po pilotáži tak, aby ekvivalence vyšla.“ (3) „Δ = 5, protože větší změnu podílu doporučení neuneseme.“

c) Proč musí být hranice stanoveny před analýzou?

Vlastní úloha pro tuto výuku; navazuje na list U4_tablet_ekvivalence

Úloha 6: Čtyři kombinace

Čtyři studie tabletové verze (norma 100, pásmo 95–105, ve všech $s = 15$):

Studie	*n*	*m*	95% interval	90% interval
W	400	101	(99,53; 102,47)	(99,76; 102,24)
X	400	103	(101,53; 104,47)	(101,76; 104,24)
Y	20	98	(90,98; 105,02)	(92,20; 103,80)
Z	100	92	(89,02; 94,98)	(89,51; 94,49)

a) Výsledek testu rozdílu od 100 a testu ekvivalence u každé studie ($\alpha = 0{,}05$).

b) Zařaďte do čtyř kombinací a zformulujte závěr. c) Opravte: „Studie Y: $p = 0{,}558$, tablet tedy dává stejné výsledky jako papír.“

Vlastní úloha pro tuto výuku

Práce v Excelu: doprovodný sešit

kapitola_07_interval_t_test_a_ekvivalence_cviceni.xlsx

U1_Kruger_Dunning: odhady 11 nejslabších studentů, jednostranný *t*-test, 95% a 90% interval

U2_SAT_bez_textu: odpovídání bez přečtení textu ze souhrnů

U3_lez_skala: škála lži u dětí ve stresu, soulad intervalů s testem

U4_tablet_ekvivalence: test rozdílu a test ekvivalence pro 60 a 15 dětí

Howell (2013), s. 222–223, úlohy 7.6–7.7 a 7.13–7.15. Česká adaptace; U4 vlastní modelová data.